



UNIVERSITY OF
PATRAS
ΠΑΝΕΠΙΣΤΗΜΙΟ ΠΑΤΡΩΝ

Εργαστηριακή Άσκηση 5

PCA, kernel PCA, Autoencoders και Variational Autoencoders

Μαριάνθη Θώδη

Μάιος 2026

Contents

1	Abstract	3
2	Θεωρία	3
2.1	Principal Component Analysis	3
2.1.1	Data Centering	3
2.1.2	Covariance Matrix	4
2.1.3	Principal Components	4
2.1.4	Dimensionality Reduction	5
2.1.5	Image Reconstruction	5
2.1.6	Reconstruction Error	6
2.2	Kernel PCA	6
2.3	Autoencoders	7
2.3.1	Encoder, Latent Space and Decoder	7
2.3.2	Reconstruction Loss	7
2.3.3	Binary Cross Entropy	8
2.3.4	Σχέση Linear Autoencoders και PCA	8
2.4	Variational Autoencoders	8
2.4.1	Reparameterization Trick	9
2.4.2	Loss Function	9
2.4.3	Latent Space Generation	10
3	Part 1 — Principal Component Analysis	10
3.1	Υλοποίηση	10
3.1.1	Dataset Preparation	10
3.1.2	PCA for Individual Digits	11
3.1.3	Global PCA on MNIST	11
3.2	Αποτελέσματα	12
3.2.1	Digits 8 and 0	12
3.2.2	Global PCA on Dataset	14
4	Part 2 - kernel PCA	16
4.1	Υλοποίηση	16
4.2	Αποτελέσματα	16
4.2.1	PCA vs KPCA	18
5	Part 3 - Autoencoders	19
5.1	Linear AE	19
5.1.1	Υλοποίηση	19
5.1.2	Αποτελέσματα	19
5.2	Nonlinear AE	20
5.2.1	Υλοποίηση	20
5.2.2	Αποτελέσματα	21
5.3	Tied Weights AE	22
5.3.1	Υλοποίηση	22
5.3.2	Αποτελέσματα	23

5.4	Pseudo Inverse AE	23
5.4.1	Υλοποίηση	23
5.4.2	Αποτελέσματα	24
5.5	Τελική Σύγκριση των Autoencoders	25
6	Part 4 - Variational Autoencoders	26
6.1	Υλοποίηση	26
6.2	Αποτελέσματα	28
6.2.1	Training Loss	28
6.2.2	Image Reconstructions	28
6.2.3	Noise Generation	29
6.2.4	Latent Space Visualization	30
6.2.5	Σύγκριση με τους προηγούμενους Autoencoders	31

1 Abstract

Η παρούσα εργασία μελετά τεχνικές μείωσης διαστατικότητας και αναπαράστασης εικόνων χρησιμοποιώντας το σύνολο δεδομένων MNIST. Στόχος είναι η κατανόηση και η σύγκριση διαφορετικών μεθόδων συμπίεσης και ανακατασκευής εικόνων. Αρχικά παρουσιάζονται η PCA και η kernel PCA, οι οποίες χρησιμοποιούνται για την εξαγωγή συμπαγών αναπαραστάσεων των δεδομένων. Στη συνέχεια μελετώνται οι Autoencoders, νευρωνικά δίκτυα που μαθαίνουν να συμπιέζουν και να ανακατασκευάζουν εικόνες μέσω ενός latent space. Τέλος, παρουσιάζονται οι Variational Autoencoders (VAE), οι οποίοι χρησιμοποιούν μια πιθανοτική αναπαράσταση του latent χώρου και μπορούν να παράγουν νέα δείγματα. Τα πειράματα πραγματοποιούνται στο MNIST και αξιολογούνται μέσω των ανακατασκευασμένων εικόνων, του reconstruction error και της ποιότητας των παραγόμενων αναπαραστάσεων. Ο πλήρης κώδικας και τα αρχεία της άσκησης διατίθενται σε repository στο GitHub, στον ακόλουθο σύνδεσμο: [GitHub Repository](#).

2 Θεωρία

Στην παρούσα εργασία μελετώνται τέσσερις βασικές τεχνικές μείωσης διαστατικότητας και αναπαράστασης δεδομένων: η PCA, η KPCA, οι AE και οι VAE.

Οι μέθοδοι αυτές χρησιμοποιούνται για τη δημιουργία συμπαγών αναπαραστάσεων δεδομένων υψηλής διάστασης, διατηρώντας παράλληλα όσο το δυνατόν μεγαλύτερο μέρος της αρχικής πληροφορίας. Στο πλαίσιο της εργασίας εφαρμόζονται στο σύνολο δεδομένων MNIST, το οποίο αποτελείται από εικόνες χειρόγραφων ψηφίων διαστάσεων 28×28 pixels.

Κάθε εικόνα μετατρέπεται σε διάνυσμα 784 χαρακτηριστικών και μπορεί να θεωρηθεί ως σημείο σε έναν χώρο 784 διαστάσεων:

$$x \in \mathbb{R}^{784} \quad (1)$$

Η επεξεργασία δεδομένων υψηλής διάστασης είναι υπολογιστικά απαιτητική και δυσκολεύει την ανάλυση των δεδομένων και για τον λόγο αυτό χρησιμοποιούνται τεχνικές dimensionality reduction, οι οποίες επιδιώκουν να περιγράψουν τα δεδομένα χρησιμοποιώντας μικρότερο αριθμό μεταβλητών χωρίς απώλεια πληροφορίας.

2.1 Principal Component Analysis

2.1.1 Data Centering

Πριν εφαρμοστεί η PCA, υπολογίζεται αρχικά η μέση εικόνα του συνόλου δεδομένων. Αν το σύνολο περιέχει M εικόνες, τότε η μέση εικόνα ορίζεται ως:

$$\mu = \frac{1}{M} \sum_{i=1}^M x_i \quad (2)$$

όπου x_i είναι το διάνυσμα που αντιστοιχεί στην i -οστή εικόνα.

Στη συνέχεια, από κάθε εικόνα αφαιρείται η μέση εικόνα ώστε τα δεδομένα να κεντραριστούν γύρω από το μηδέν:

$$\tilde{x}_i = x_i - \mu \quad (3)$$

Ο λόγος είναι ότι η μέθοδος αναζητά τις κατευθύνσεις μέγιστης διακύμανσης των δεδομένων και όχι τη μέση φωτεινότητα ή τη μέση ένταση των εικόνων. Στην περίπτωση του συνόλου δεδομένων MNIST, το κεντράρισμα επιτρέπει στην PCA να επικεντρωθεί στις πραγματικές διαφορές μεταξύ των ψηφίων. Με άλλα λόγια, η μέθοδος δεν προσπαθεί να μάθει τη μέση εικόνα του συνόλου ή τον μέσο φωτισμό των pixels, αλλά τις σημαντικότερες μεταβολές που διαχωρίζουν τα διαφορετικά ψηφία.

2.1.2 Covariance Matrix

Αφού τα δεδομένα κεντραριστούν, υπολογίζεται:

$$C = \frac{1}{M-1}(X - \mu)^T(X - \mu) \quad (4)$$

όπου M είναι το πλήθος των δειγμάτων, X ο πίνακας που περιέχει τις εικόνες και μ το μέσο διάνυσμα του συνόλου δεδομένων.

Το μητρώο συνδιασπορών περιγράφει τον βαθμό συσχέτισης μεταξύ των διαφορετικών διαστάσεων των δεδομένων. Κάθε στοιχείο του εκφράζει το κατά πόσο δύο χαρακτηριστικά μεταβάλλονται ταυτόχρονα.

Στην περίπτωση των εικόνων του MNIST, το μητρώο αυτό αποτυπώνει ποιες περιοχές των εικόνων τείνουν να αλλάζουν μαζί. Για παράδειγμα, αν δύο pixels ενεργοποιούνται συχνά ταυτόχρονα σε πολλές εικόνες, τότε η αντίστοιχη συνδιασπορά θα είναι μεγάλη. Αντίθετα, όταν οι μεταβολές τους είναι ανεξάρτητες, η συνδιασπορά θα είναι μικρή ή κοντά στο μηδέν.

Επομένως, το μητρώο συνδιασπορών περιέχει σημαντική πληροφορία για τη δομή των δεδομένων και αποτελεί τη βάση πάνω στην οποία η PCA εντοπίζει τις σημαντικότερες κατευθύνσεις μεταβλητότητας του συνόλου δεδομένων.

2.1.3 Principal Components

Οι κύριες συνιστώσες προκύπτουν μέσω της eigendecomposition του μητρώου συνδιασπορών. Συγκεκριμένα, αναζητούμε τα ιδιοδιανύσματα και τις αντίστοιχες ιδιοτιμές που ικανοποιούν τη σχέση:

$$Cv = \lambda v \quad (5)$$

όπου:

- v είναι ένα (*eigenvector*),
- λ είναι η αντίστοιχη (*eigenvalue*).

Τα ιδιοδιανύσματα που αντιστοιχούν στις μεγαλύτερες ιδιοτιμές αποτελούν τις κύριες συνιστώσες του συστήματος. Κάθε ιδιοτιμή εκφράζει το ποσοστό της διακύμανσης των δεδομένων που εξηγείται από το αντίστοιχο ιδιοδιάνυσμα.

Η πρώτη principal component αντιστοιχεί στην κατεύθυνση κατά την οποία τα δεδομένα παρουσιάζουν τη μεγαλύτερη διακύμανση. Η δεύτερη principal component περιγράφει τη μεγαλύτερη δυνατή διακύμανση που απομένει και είναι ορθογώνια προς την πρώτη. Η ίδια διαδικασία συνεχίζεται για όλες τις επόμενες συνιστώσες.

Με τον τρόπο αυτό, η πληροφορία οργανώνεται από τη σημαντικότερη προς τη λιγότερο σημαντική, επιτρέποντας τη διατήρηση του μεγαλύτερου μέρους της πληροφορίας χρησιμοποιώντας μόνο ένα μικρό υποσύνολο των διαθέσιμων διαστάσεων.

2.1.4 Dimensionality Reduction

Αντί να χρησιμοποιηθούν και οι 784 διαστάσεις του αρχικού χώρου χαρακτηριστικών, διατηρούνται μόνο οι πρώτες L κύριες συνιστώσες, δηλαδή εκείνες που αντιστοιχούν στις μεγαλύτερες ιδιοτιμές και επομένως περιέχουν το μεγαλύτερο μέρος της πληροφορίας των δεδομένων.

Στην παρούσα εργασία εξετάζονται οι ακόλουθες τιμές του αριθμού συνιστωσών:

$$L = 1, ; 8, ; 16, ; 64, ; 256 \quad (6)$$

καθώς και η περίπτωση:

$$L = 128 \quad (7)$$

για το πείραμα του global PCA.

Η προβολή μιας εικόνας στον χώρο των κύριων συνιστωσών πραγματοποιείται μέσω της σχέσης:

$$z = V_L^T(x - \mu) \quad (8)$$

όπου:

- x είναι η αρχική εικόνα,
- μ η μέση εικόνα του συνόλου εκπαίδευσης,
- V_L ο πίνακας που περιέχει τις πρώτες L principal components,
- z η αναπαράσταση της εικόνας στον PCA χώρο.

Το διάνυσμα z αποτελεί μια συμπιεσμένη περιγραφή της εικόνας, αφού περιέχει μόνο L συντελεστές αντί για τα αρχικά 784 χαρακτηριστικά. Με τον τρόπο αυτό επιτυγχάνεται σημαντική μείωση της διάστασης των δεδομένων, ενώ ταυτόχρονα διατηρείται το μεγαλύτερο μέρος της πληροφορίας που περιέχεται στις αρχικές εικόνες.

2.1.5 Image Reconstruction

Η ανακατασκευή μιας εικόνας από τον χώρο των κύριων συνιστωσών πραγματοποιείται χρησιμοποιώντας τις principal components που έχουν διατηρηθεί. Συγκεκριμένα, αν z είναι η προβολή της εικόνας στον PCA χώρο, τότε η ανακατασκευή δίνεται από:

$$\hat{x} = V_L z + \mu \quad (9)$$

όπου V_L είναι ο πίνακας που περιέχει τις πρώτες L κύριες συνιστώσες και μ η μέση εικόνα του συνόλου δεδομένων.

Αν αντικαταστήσουμε το z από τη σχέση προβολής, προκύπτει η ισοδύναμη μορφή:

$$\hat{x} = V_L V_L^T(x - \mu) + \mu \quad (10)$$

Η σχέση αυτή δείχνει ότι η ανακατασκευή προκύπτει από την προβολή της αρχικής εικόνας στον υποχώρο που ορίζεται από τις πρώτες L principal components και την επαναφορά της μέσης τιμής.

Η ποιότητα της ανακατασκευής εξαρτάται άμεσα από τον αριθμό των συνιστωσών που διατηρούνται. Όταν χρησιμοποιείται μικρός αριθμός principal components, μόνο οι σημαντικότερες δομές της

εικόνας διατηρούνται, ενώ οι λεπτομέρειες χάνονται. Ως αποτέλεσμα, η ανακατασκευασμένη εικόνα εμφανίζεται πιο θολή και λιγότερο πιστή ως προς το αρχικό δείγμα.

Αντίθετα, όσο αυξάνεται η τιμή του L , διατηρείται μεγαλύτερο ποσοστό της συνολικής διακύμανσης των δεδομένων και συνεπώς μειώνεται η απώλεια πληροφορίας. Για αρκετά μεγάλες τιμές του L , η ανακατασκευή προσεγγίζει πολύ καλά την αρχική εικόνα, καθώς ο PCA υποχώρος περιλαμβάνει πλέον σχεδόν όλα τα σημαντικά χαρακτηριστικά του δείγματος.

2.1.6 Reconstruction Error

Για την ποσοτική αξιολόγηση της ποιότητας ανακατασκευής χρησιμοποιείται το μέτρο MSE, το οποίο υπολογίζει τη μέση τετραγωνική διαφορά μεταξύ της αρχικής και της ανακατασκευασμένης εικόνας.

Ορίζεται ως:

$$\text{MSE} = \frac{1}{N} \sum_{i=1}^N (x_i - \hat{x}_i)^2 \quad (11)$$

όπου:

- x_i είναι η τιμή του i -οστού pixel της αρχικής εικόνας,
- $\hat{x}_i$ είναι η αντίστοιχη τιμή του ανακατασκευασμένου pixel,
- N είναι το συνολικό πλήθος των pixels της εικόνας.

Το MSE εκφράζει το μέσο σφάλμα ανακατασκευής ανά pixel. Όσο μικρότερη είναι η τιμή του, τόσο πιο κοντά βρίσκεται η ανακατασκευασμένη εικόνα στην αρχική και συνεπώς τόσο μικρότερη είναι η απώλεια πληροφορίας που προκαλείται από τη διαδικασία συμπίεσης.

Στην περίπτωση του PCA, η τιμή του MSE αναμένεται να μειώνεται καθώς αυξάνεται ο αριθμός των principal components που χρησιμοποιούνται για την αναπαράσταση των δεδομένων. Αυτό συμβαίνει επειδή περισσότερες συνιστώσες διατηρούν μεγαλύτερο ποσοστό της συνολικής διακύμανσης των εικόνων και επιτρέπουν ακριβέστερη ανακατασκευή.

2.2 Kernel PCA

Η κλασική PCA αναζητά γραμμικούς συνδυασμούς των αρχικών χαρακτηριστικών και επομένως λειτουργεί καλύτερα όταν η δομή των δεδομένων μπορεί να περιγραφεί από έναν γραμμικό υποχώρο. Ωστόσο, σε πολλά προβλήματα τα δεδομένα παρουσιάζουν μη γραμμικές σχέσεις, οι οποίες δεν μπορούν να αποτυπωθούν αποτελεσματικά μόνο με γραμμικές principal components.

Για τον λόγο αυτό χρησιμοποιείται η KPCA, η οποία εφαρμόζει την PCA σε έναν νέο χώρο χαρακτηριστικών μέσω ενός μη γραμμικού μετασχηματισμού $\phi(x)$. Αντί όμως να υπολογίζεται ρητά ο μετασχηματισμός αυτός, χρησιμοποιείται μία συνάρτηση πυρήνα:

$$K(x_i, x_j) = \phi(x_i)^T \phi(x_j) \quad (12)$$

η οποία επιτρέπει τον υπολογισμό των εσωτερικών γινομένων στον νέο χώρο χωρίς να απαιτείται η κατασκευή του.

Στην παρούσα εργασία χρησιμοποιήθηκε ο Gaussian RBF kernel:

$$K(x_i, x_j) = \exp(-\gamma |x_i - x_j|^2) \quad (13)$$

όπου η παράμετρος γ ελέγχει πόσο επηρεάζει η απόσταση μεταξύ δύο δειγμάτων την τιμή του kernel.

Μετά τον υπολογισμό του kernel matrix πραγματοποιείται ιδιοανάλυση του πίνακα K , από την οποία προκύπτουν οι principal components στον νέο χώρο χαρακτηριστικών.

2.3 Autoencoders

Σε αντίθεση με την PCA και την kernel PCA, οι autoencoders αποτελούν νευρωνικά δίκτυα που μαθαίνουν απευθείας από τα δεδομένα μια συμπιεσμένη αναπαράστασή τους.

Η βασική ιδέα είναι ότι το δίκτυο λαμβάνει ως είσοδο μια εικόνα και προσπαθεί να ανακατασκευάσει την ίδια εικόνα στην έξοδό του. Κατά τη διαδικασία αυτή αναγκάζεται να συμπιέσει την πληροφορία σε έναν χώρο μικρότερης διάστασης, διατηρώντας μόνο τα χαρακτηριστικά που είναι απαραίτητα για την ανακατασκευή.

Οι ae χρησιμοποιούνται ευρέως σε προβλήματα dimensionality reduction, feature extraction, denoising και γενικότερα σε εφαρμογές όπου απαιτείται η εκμάθηση μιας συμπαγούς αναπαράστασης των δεδομένων χωρίς την ύπαρξη ετικετών.

2.3.1 Encoder, Latent Space and Decoder

Ένας autoencoder αποτελείται από τρία βασικά μέρη: τον encoder, το latent space και τον decoder.

Ο encoder αναλαμβάνει να μετατρέψει τα αρχικά δεδομένα σε μια πιο συμπιεσμένη μορφή. Στην περίπτωση του MNIST, κάθε εικόνα περιγράφεται αρχικά από 784 χαρακτηριστικά, καθώς οι εικόνες έχουν διαστάσεις 28×28 pixels.

Αντί να διατηρηθούν και τα 784 χαρακτηριστικά, ο encoder παράγει ένα νέο διάνυσμα μικρότερης διάστασης:

$$z = f_{\theta}(x)$$

όπου x είναι η αρχική εικόνα και z η συμπιεσμένη αναπαράστασή της.

Το διάνυσμα z ονομάζεται latent representation και περιέχει τις σημαντικότερες πληροφορίες της εικόνας σε πολύ λιγότερες διαστάσεις.

Στην παρούσα εργασία χρησιμοποιήθηκε latent space διάστασης:

$$z \in \mathbb{R}^{128}$$

γεγονός που σημαίνει ότι κάθε εικόνα συμπιέζεται από 784 σε 128 χαρακτηριστικά.

Στη συνέχεια ο decoder λαμβάνει το latent vector και προσπαθεί να ανακατασκευάσει την αρχική εικόνα:

$$\hat{x} = g_{\phi}(z)$$

όπου $\hat{x}$ είναι η ανακατασκευασμένη εικόνα.

Στόχος του δικτύου είναι η ανακατασκευή να είναι όσο το δυνατόν πιο κοντά στην αρχική είσοδο.

2.3.2 Reconstruction Loss

Η εκπαίδευση του ae βασίζεται στη σύγκριση της αρχικής εικόνας με την εικόνα που παράγεται από τον decoder.

Όσο μεγαλύτερη είναι η διαφορά μεταξύ των δύο εικόνων, τόσο μεγαλύτερο θεωρείται το σφάλμα του δικτύου. Κατά τη διάρκεια της εκπαίδευσης οι παράμετροι του encoder και του decoder προσαρμόζονται ώστε το σφάλμα αυτό να μειώνεται σταδιακά.

Με τον τρόπο αυτό το δίκτυο μαθαίνει ποιες πληροφορίες είναι σημαντικές για την περιγραφή των δεδομένων και ποιες μπορούν να αγνοηθούν χωρίς σημαντική απώλεια ποιότητας στην ανακατασκευή.

2.3.3 Binary Cross Entropy

Για την εκπαίδευση χρησιμοποιήθηκε η συνάρτηση κόστους BCE, η οποία ζητείται και από την εκφώνηση της εργασίας.

Η BCE συγκρίνει τις τιμές των pixels της αρχικής εικόνας με τις αντίστοιχες τιμές της ανακατασκευασμένης εικόνας και υπολογίζει το σφάλμα μεταξύ τους.

Μαθηματικά ορίζεται ως:

$$L(x, \hat{x}) = - \sum_i [x_i \log(\hat{x}_i) + (1 - x_i) \log(1 - \hat{x}_i)]$$

όπου x_i είναι η τιμή του i -οστού pixel της αρχικής εικόνας και $\hat{x}_i$ η αντίστοιχη τιμή του ανακατασκευασμένου pixel.

Η συγκεκριμένη συνάρτηση είναι κατάλληλη για το dataset επειδή οι τιμές των pixels έχουν κανονικοποιηθεί στο διάστημα $[0, 1]$. Η BCE χρησιμοποιείται ως objective function κατά την εκπαίδευση, ενώ για τη σύγκριση με τα αποτελέσματα της PCA χρησιμοποιείται επιπλέον το MSE.

2.3.4 Σχέση Linear Autoencoders και PCA

Οι γραμμικοί autoencoders παρουσιάζουν στενή σχέση με την PCA. Όταν ο encoder και ο decoder αποτελούνται μόνο από γραμμικούς μετασχηματισμούς και δεν χρησιμοποιούνται μη γραμμικές συναρτήσεις ενεργοποίησης, το δίκτυο μαθαίνει έναν υποχώρο ο οποίος προσεγγίζει τον υποχώρο που προκύπτει από τις principal components της PCA.

Για τον λόγο αυτό ένας LAE μπορεί να θεωρηθεί ως μία νευρωνική προσέγγιση της PCA. Παρότι οι δύο μέθοδοι δεν υπολογίζονται με τον ίδιο τρόπο, καταλήγουν συχνά σε πολύ παρόμοιες αναπαραστάσεις των δεδομένων.

Η παρατήρηση αυτή είναι ιδιαίτερα σημαντική στην παρούσα εργασία, καθώς ένα από τα ζητούμενα είναι η σύγκριση των βαρών του encoder με τις principal components που υπολογίστηκαν μέσω PCA στο πρώτο μέρος της άσκησης.

2.4 Variational Autoencoders

Οι variational autoencoders (vae) αποτελούν μια πιθανοτική επέκταση των κλασικών autoencoders. Ενώ στους απλούς autoencoders κάθε εικόνα αντιστοιχίζεται σε ένα συγκεκριμένο latent vector, στους vae η αναπαράσταση μιας εικόνας περιγράφεται μέσω μιας κατανομής πιθανότητας μέσα στον latent χώρο.

Στον κλασικό autoencoder ο encoder παράγει απευθείας το latent vector:

$$z = E(x) \tag{14}$$

και στη συνέχεια ο decoder προσπαθεί να ανακατασκευάσει την είσοδο:

$$\hat{x} = D(z) \tag{15}$$

Στον vae η διαδικασία είναι διαφορετική. Ο encoder δεν παράγει ένα μοναδικό latent vector, αλλά τις παραμέτρους μιας Gaussian κατανομής. Πιο συγκεκριμένα υπολογίζει το μέσο διάνυσμα μ και τη λογαριθμική διακύμανση $\log \sigma^2$:

$$q_\phi(z|x) = \mathcal{N}(\mu_\phi(x), \text{diag}(\sigma_\phi^2(x))) \quad (16)$$

Έτσι κάθε εικόνα δεν αντιστοιχεί σε ένα μόνο σημείο αλλά σε μια μικρή περιοχή του latent χώρου. Η προσέγγιση αυτή επιτρέπει στο μοντέλο να δημιουργεί νέα δείγματα δειγματοληπτώντας σημεία από την κατανομή του latent χώρου και όχι μόνο να ανακατασκευάζει εικόνες που έχει ήδη δει.

2.4.1 Reparameterization Trick

Η άμεση δειγματοληψία από την κατανομή

$$z \sim \mathcal{N}(\mu, \sigma^2) \quad (17)$$

δεν μπορεί να χρησιμοποιηθεί απευθείας κατά την εκπαίδευση, καθώς η διαδικασία της δειγματοληψίας εισάγει τυχαιότητα και δεν αποτελεί διαφορίσιμη συνάρτηση ως προς τις παραμέτρους μ και σ και ως αποτέλεσμα, το gradient της loss δεν μπορεί να διαδοθεί κανονικά προς τα πίσω και να ενημερώσει τα βάρη του encoder μέσω backpropagation.

Για τον λόγο αυτό χρησιμοποιείται το reparameterization trick, σύμφωνα με το οποίο το latent vector γράφεται ως:

$$z = \mu + \sigma \odot \varepsilon \quad (18)$$

όπου:

$$\varepsilon \sim \mathcal{N}(0, I) \quad (19)$$

και $\odot$ δηλώνει στοιχειώδη πολλαπλασιασμό.

Με τον τρόπο αυτό η τυχαιότητα μεταφέρεται στη μεταβλητή ε , ενώ οι παράμετροι μ και σ παραμένουν διαφορίσιμες ως προς τα βάρη του encoder. Έτσι το δίκτυο μπορεί να εκπαιδευτεί κανονικά μέσω gradient descent και backpropagation.

2.4.2 Loss Function

Η συνάρτηση κόστους ενός vae αποτελείται από δύο διαφορετικούς όρους.

Ο πρώτος είναι το reconstruction loss, το οποίο μετρά πόσο καλά ο decoder καταφέρνει να ανακατασκευάσει την αρχική εικόνα. Στην παρούσα εργασία χρησιμοποιείται η binary cross entropy (bce):

$$L_{rec} = - \sum_i \left[x_i \log(\hat{x}_i) + (1 - x_i) \log(1 - \hat{x}_i) \right] \quad (20)$$

Ο δεύτερος όρος είναι το KL divergence, το οποίο αναγκάζει τις latent κατανομές να παραμένουν κοντά στην τυπική κανονική κατανομή:

$$p(z) = \mathcal{N}(0, I) \quad (21)$$

και υπολογίζεται ως:

$$D_{KL} = -\frac{1}{2} \sum (1 + \log \sigma^2 - \mu^2 - \sigma^2) \quad (22)$$

Η συνολική loss προκύπτει από το άθροισμα των δύο όρων:

$$L = L_{rec} + D_{KL} \quad (23)$$

Ο reconstruction όρος προσπαθεί να διατηρήσει όσο το δυνατόν περισσότερη πληροφορία από την αρχική εικόνα, ενώ ο όρος KL divergence οργανώνει τον latent χώρο έτσι ώστε να ακολουθεί κανονική κατανομή.

2.4.3 Latent Space Generation

Ένα από τα σημαντικότερα χαρακτηριστικά των vae είναι η δυνατότητα παραγωγής νέων δεδομένων.

Μετά την ολοκλήρωση της εκπαίδευσης μπορούν να δημιουργηθούν νέα latent vectors δειγματοληπτώντας από την κατανομή:

$$z \sim \mathcal{N}(0, I) \quad (24)$$

και στη συνέχεια τα σημεία αυτά να δοθούν ως είσοδος στον decoder:

$$\hat{x} = D(z) \quad (25)$$

Με τον τρόπο αυτό το μοντέλο μπορεί να δημιουργεί νέες εικόνες που δεν υπάρχουν στο αρχικό σύνολο δεδομένων αλλά ακολουθούν παρόμοια χαρακτηριστικά με εκείνα που έχει μάθει κατά την εκπαίδευση. Αυτή ακριβώς η δυνατότητα παραγωγής νέων δειγμάτων αποτελεί και τη βασική διαφορά των vae σε σχέση με τους κλασικούς autoencoders.

3 Part 1 — Principal Component Analysis

3.1 Υλοποίηση

Στο πρώτο μέρος της εργασίας υλοποιήθηκε η μέθοδος PCA με σκοπό τη μελέτη της συμπίεσης και ανακατασκευής εικόνων του συνόλου δεδομένων MNIST.

Η υλοποίηση πραγματοποιήθηκε σε Python χρησιμοποιώντας τις βιβλιοθήκες NumPy, Pandas και Matplotlib. Τα πειράματα χωρίστηκαν σε δύο κατηγορίες. Αρχικά εφαρμόστηκε PCA ξεχωριστά σε δύο επιλεγμένα ψηφία του MNIST και στη συνέχεια εφαρμόστηκε PCA σε ολόκληρο το σύνολο δεδομένων. Τέλος οι principal components υπολογίστηκαν μέσω SVD καθώς η μέθοδος επιτρέπει την άμεση εξαγωγή των principal components από τα δεδομένα χωρίς τον υπολογισμό του πίνακα συνδιακύμανσης.

3.1.1 Dataset Preparation

Το σύνολο δεδομένων MNIST περιλαμβάνει εικόνες χειρόγραφων ψηφίων διαστάσεων 28×28 pixels. Κάθε εικόνα μετατράπηκε σε διάνυσμα 784 χαρακτηριστικών, ώστε να μπορεί να εφαρμοστεί η Principal Component Analysis.

Οι τιμές των pixels κανονικοποιήθηκαν στο διάστημα $[0, 1]$. Η κανονικοποίηση διευκολύνει την επεξεργασία των δεδομένων, καθώς όλα τα χαρακτηριστικά βρίσκονται στην ίδια αριθμητική κλίμακα και αποφεύγονται προβλήματα που σχετίζονται με μεγάλες διαφορές στις τιμές των μεταβλητών.

Στη συνέχεια υπολογίστηκε η μέση εικόνα του συνόλου εκπαίδευσης και πραγματοποιήθηκε κεντράρισμα των δεδομένων, αφαιρώντας τη μέση τιμή από κάθε δείγμα. Η διαδικασία αυτή είναι απαραίτητη για την PCA, καθώς επιτρέπει τον υπολογισμό των κύριων συνιστωσών με βάση τη διακύμανση των δεδομένων γύρω από τη μέση τιμή τους.

3.1.2 PCA for Individual Digits

Για τη μελέτη της συμπεριφοράς της PCA σε δεδομένα που ανήκουν στην ίδια κατηγορία, επιλέχθηκαν τα ψηφία 0 και 8 από το σύνολο δεδομένων MNIST και για κάθε κατηγορία δημιουργήθηκε ξεχωριστό υποσύνολο δεδομένων που περιείχε μόνο εικόνες του αντίστοιχου ψηφίου. Στη συνέχεια υπολογίστηκε η μέση εικόνα, οι principal components και οι ανακατασκευές των δειγμάτων για διαφορετικές τιμές του αριθμού συνιστωσών L .

Συγκεκριμένα εξετάστηκαν οι τιμές:

$$L = 1, 8, 16, 64, 256$$

ώστε να μελετηθεί η επίδραση της διάστασης του PCA στην ποιότητα ανακατασκευής.

Για κάθε ψηφίο υπολογίστηκαν:

- η μέση εικόνα (mean digit),
- οι πρώτες οκτώ principal components,
- ανακατασκευές εικόνων,
- ιστογράμματα reconstruction error,
- καμπύλες μέσης τιμής του MSE.

3.1.3 Global PCA on MNIST

Έπειτα υλοποιήθηκε ένα PCA μοντέλο χρησιμοποιώντας ολόκληρο το training set του dataset. Σε αυτή την περίπτωση οι principal components υπολογίστηκαν από όλα τα διαθέσιμα ψηφία και όχι από δύο μόνο κατηγορίες. Ως αποτέλεσμα, οι principal components περιγράφουν τις σημαντικότερες μεταβολές ολόκληρου του συνόλου δεδομένων.

Για το συγκεκριμένο πείραμα επιλέχθηκε:

$$L = 128$$

principal components.

Η επιλογή αυτή μειώνει τη διάσταση των δεδομένων από 784 χαρακτηριστικά σε 128, διατηρώντας παράλληλα το μεγαλύτερο μέρος της διαθέσιμης πληροφορίας.

Το PCA basis υπολογίστηκε από το training set και στη συνέχεια χρησιμοποιήθηκε για την ανακατασκευή εικόνων εκπαίδευσης και για την ανακατασκευή εικόνων του test set.

Με τον τρόπο αυτό αξιολογείται η δυνατότητα γενίκευσης του PCA μοντέλου σε νέα δείγματα που δεν χρησιμοποιήθηκαν κατά τον υπολογισμό των principal components.

3.2 Αποτελέσματα

3.2.1 Digits 8 and 0

Mean Images



Figure 1: Mean images for digits 8 and 0.

Η Εικόνα 1 παρουσιάζει τις μέσες εικόνες των ψηφίων 8 και 0. Οι εικόνες προκύπτουν από τον μέσο όρο όλων των δειγμάτων κάθε κατηγορίας και αποτυπώνουν τα βασικά χαρακτηριστικά των αντίστοιχων ψηφίων. Οι φωτεινότερες περιοχές αντιστοιχούν σε pixels που ενεργοποιούνται συχνότερα, ενώ οι θολές περιοχές υποδηλώνουν μεγαλύτερη μεταβλητότητα μεταξύ των δειγμάτων.

Παρατηρείται ότι και στις δύο περιπτώσεις διατηρείται η χαρακτηριστική μορφή του ψηφίου. Ωστόσο, η μέση εικόνα του ψηφίου 8 εμφανίζει μεγαλύτερη θόλωση σε σχέση με το ψηφίο 0, γεγονός που σημαίνει μεγαλύτερη ποικιλία στον τρόπο γραφής του. Αντίθετα, το μέσο ψηφίο 0 παρουσιάζει πιο καθαρό σχήμα, κάτι που δείχνει ότι τα αντίστοιχα δείγματα είναι περισσότερο συγκεντρωμένα γύρω από μία κοινή μορφή.

Principal Components




Figure 2: First eight principal components for digits 8 and 0.

Οι Εικόνες 2a και 2b παρουσιάζουν τις πρώτες principal components που υπολογίστηκαν για κάθε κατηγορία, που περιγράφουν τις σημαντικότερες μεταβολές μεταξύ των διαφορετικών ψηφίων.

Οι πρώτες components περιγράφουν τις σημαντικότερες μεταβολές που εμφανίζονται μεταξύ διαφορετικών δειγμάτων του ίδιου ψηφίου, ενώ οι επόμενες components αποτυπώνουν πιο λεπτές διαφοροποιήσεις.

Επιπλέον, οι principal components του ψηφίου 8 εμφανίζονται πιο σύνθετες σε σχέση με αυτές του ψηφίου 0, κάτι που είναι αναμενόμενο λόγω της μεγαλύτερης μεταβλητότητας που παρουσιάζει το ψηφίο 8 στο σύνολο δεδομένων.

Reconstructions



Figure 3: Reconstructions for different values of L .

Οι Εικόνες 3a και 3b παρουσιάζουν παραδείγματα ανακατασκευής εικόνων χρησιμοποιώντας διαφορετικό αριθμό principal components.

Για μικρές τιμές του L , όπως $L=1$ και $L=8$, διατηρείται μόνο η βασική δομή του ψηφίου, ενώ αρκετές λεπτομέρειες χάνονται. Καθώς αυξάνεται ο αριθμός των συνιστωσών, η ποιότητα της ανακατασκευής βελτιώνεται σταδιακά και οι εικόνες γίνονται οπτικά πιο κοντά στις αρχικές.

Για $L=64$ η ανακατασκευή είναι ήδη πολύ καλή, ενώ για $L=256$ η διαφορά από την αρχική εικόνα είναι πρακτικά αμελητέα. Το αποτέλεσμα αυτό δείχνει ότι ένα σχετικά μικρό υποσύνολο των principal components αρκεί για να περιγράψει το μεγαλύτερο μέρος της πληροφορίας που περιέχεται στα δεδομένα.

Reconstruction Error Histograms




Figure 4: Histograms of reconstruction error.

Τα ιστογράμματα παρουσιάζουν την κατανομή του reconstruction error για όλα τα δείγματα κάθε κατηγορίας και για διαφορετικές τιμές του αριθμού συνιστωσών L .

Παρατηρείται ότι όσο αυξάνεται το L , οι κατανομές μετατοπίζονται προς μικρότερες τιμές σφάλματος. Για $L=1$ το reconstruction error είναι σχετικά μεγάλο για το μεγαλύτερο μέρος των δειγμάτων, ενώ για $L=64$ και ιδιαίτερα για $L=256$ οι περισσότερες εικόνες εμφανίζουν πολύ μικρό σφάλμα ανακατασκευής.

Η συμπεριφορά αυτή είναι αναμενόμενη, καθώς η προσθήκη περισσότερων principal components επιτρέπει τη διατήρηση μεγαλύτερου ποσοστού της αρχικής πληροφορίας.

Mean Reconstruction Error




Figure 5: Mean reconstruction error as a function of L .

Η Εικόνα 5 παρουσιάζει τη μέση τιμή του reconstruction error ως συνάρτηση του αριθμού των principal components.

Παρατηρείται σημαντική μείωση του σφάλματος για τις πρώτες τιμές του L , γεγονός που δείχνει ότι οι πρώτες principal components περιέχουν το μεγαλύτερο μέρος της χρήσιμης πληροφορίας.

3.2.2 Global PCA on Dataset

Σε αυτό το πείραμα η PCA εφαρμόστηκε σε ολόκληρο το σύνολο εκπαίδευσης του dataset, χωρίς διαχωρισμό ανά κατηγορία ψηφίου. Επομένως, οι principal components που προκύπτουν περιγράφουν τη συνολική μεταβλητότητα όλων των χειρόγραφων ψηφίων και όχι τα χαρακτηριστικά μιας συγκεκριμένης κλάσης.

Κάθε εικόνα του MNIST αναπαρίσταται αρχικά από 784 pixels. Μετά την εφαρμογή της PCA, κάθε εικόνα προβάλλεται σε έναν υποχώρο 128 διαστάσεων και αναπαρίσταται από 128 συντελεστές.

Training Set Reconstructions




Figure 6: Original and reconstructed images from the training set using Global PCA with $L = 128$.

Η Εικόνα 6 παρουσιάζει παραδείγματα αρχικών και ανακατασκευασμένων εικόνων από το training set.

Παρατηρείται ότι όλα τα ψηφία παραμένουν εύκολα αναγνωρίσιμα μετά την ανακατασκευή. Παρότι η διάσταση έχει μειωθεί σημαντικά από 784 σε 128 χαρακτηριστικά, τα βασικά μορφολογικά χαρακτηριστικά κάθε ψηφίου διατηρούνται σε πολύ μεγάλο βαθμό.

Οι reconstructed εικόνες εμφανίζονται ελαφρώς πιο ομαλές σε σχέση με τις αρχικές. Οι ακμές είναι λιγότερο έντονες και ορισμένες λεπτές λεπτομέρειες χάνονται, γεγονός που είναι αναμενόμενο αφού η ανακατασκευή βασίζεται μόνο στις σημαντικότερες principal components.

Παρατηρούνται επίσης αχνά γκρι pixels γύρω από ορισμένα ψηφία. Τα στοιχεία αυτά αποτελούν τυπικά PCA artifacts και οφείλονται στο γεγονός ότι η εικόνα προσεγγίζεται μέσω γραμμικού συνδυασμού principal components.

Επιπλέον, στο δείγμα εμφανίζονται περισσότερες από μία φορές ορισμένες κατηγορίες ψηφίων, όπως τα ψηφία 1 και 4. Αυτό είναι φυσιολογικό, καθώς τα δείγματα επιλέχθηκαν τυχαία από το dataset. Η παρατήρηση αυτή είναι χρήσιμη, καθώς δείχνει ότι η PCA ανακατασκευάζει ικανοποιητικά διαφορετικά στυλ γραφής του ίδιου ψηφίου.

Test Set Reconstructions




Figure 7: Original and reconstructed images from the test set using global PCA with $L = 128$.

Η Εικόνα 7 παρουσιάζει αντίστοιχα παραδείγματα από το test set. Για την ανακατασκευή χρησιμοποιήθηκαν η μέση εικόνα και οι principal components που υπολογίστηκαν αποκλειστικά από το training set.

Η ποιότητα των reconstructed εικόνων είναι πολύ παρόμοια με αυτή που παρατηρήθηκε στο training set. Τα ψηφία παραμένουν πλήρως αναγνωρίσιμα και δεν παρατηρείται κάποια εμφανής υποβάθμιση στην ανακατασκευή.

Το αποτέλεσμα αυτό δείχνει ότι οι principal components που υπολογίστηκαν από τα δεδομένα εκπαίδευσης περιγράφουν αποτελεσματικά και νέα δείγματα που δεν χρησιμοποιήθηκαν κατά την εκπαίδευση. Οι βασικές κατευθύνσεις διακύμανσης που μαθαίνει η PCA από το training set επαρκούν και για την περιγραφή των εικόνων του test set. Αυτό είναι αναμενόμενο για το MNIST, καθώς τα training και test δεδομένα προέρχονται από την ίδια κατανομή και περιέχουν παρόμοια χαρακτηριστικά.

Η πολύ μικρή διαφορά μεταξύ training και test reconstructions υποδηλώνει ότι η PCA δεν έχει προσαρμοστεί σε συγκεκριμένα δείγματα εκπαίδευσης, αλλά έχει μάθει γενικότερα χαρακτηριστικά των χειρόγραφων ψηφίων.

4 Part 2 - kernel PCA

4.1 Υλοποίηση

Στο δεύτερο μέρος της εργασίας εφαρμόστηκε kernel PCA στα ψηφία 0 και 8 του συνόλου δεδομένων MNIST, ώστε τα αποτελέσματα να μπορούν να συγκριθούν άμεσα με εκείνα του κλασικού PCA που παρουσιάστηκαν προηγουμένως.

Οι εικόνες του MNIST έχουν διαστάσεις 28×28 pixels και αναπαραστάθηκαν ως διανύσματα 784 χαρακτηριστικών. Πριν την εφαρμογή του αλγορίθμου, οι ιμές των pixels κανονικοποιήθηκαν στο διάστημα $[0, 1]$, ώστε όλα τα χαρακτηριστικά να βρίσκονται στην ίδια κλίμακα τιμών κατά τον υπολογισμό του kernel.

Λόγω του αυξημένου υπολογιστικού κόστους του kernel PCA χρησιμοποιήθηκαν τα πρώτα 1000 δείγματα από κάθε κατηγορία. Ως συνάρτηση πυρήνα επιλέχθηκε ο Gaussian RBF kernel με παράμετρο

$$\gamma = 10^{-3}$$

τιμή που παρείχε ικανοποιητικά αποτελέσματα στις ανακατασκευές χωρίς να οδηγεί σε υπερβολικά τοπική ή υπερβολικά γενικευμένη περιγραφή των δεδομένων.

Για την υλοποίηση χρησιμοποιήθηκε η κλάση `kernelPCA` της βιβλιοθήκης `scikit-learn` με ενεργοποιημένο τον υπολογισμό του `inverse transform`, ώστε να είναι δυνατή η ανακατασκευή των εικόνων από τον χώρο των `kernel principal components`. Σε αντίθεση με την κλασική PCA, στο KPCA δεν υπάρχει γενικά κλειστή μορφή για την αντίστροφη απεικόνιση από τον χώρο των `kernel principal components` προς τον αρχικό χώρο των εικόνων. Για τον λόγο αυτό χρησιμοποιήθηκε η επιλογή `fit_inverse_transform=True`, ώστε η βιβλιοθήκη να υπολογίζει μία προσεγγιστική αντίστροφη συνάρτηση και να είναι δυνατή η ανακατασκευή των εικόνων μέσω της διαδικασίας `inverse_transform()`.

Επίσης η KPCA παρουσιάζει σημαντικά μεγαλύτερο υπολογιστικό κόστος από την κλασική PCA, καθώς απαιτεί τον υπολογισμό ενός `kernel matrix` διαστάσεων $N \times N$, όπου N είναι ο αριθμός των δειγμάτων. Η μνήμη και ο χρόνος εκτέλεσης αυξάνονται περίπου τετραγωνικά ως προς το πλήθος των δειγμάτων και για τον περιορισμό του υπολογιστικού κόστους χρησιμοποιήθηκαν τα πρώτα 1000 δείγματα από κάθε κατηγορία.

Η ανακατασκευή πραγματοποιήθηκε χρησιμοποιώντας

[L = 1,;8,;16,;64,;256]

`principal components`, ενώ για κάθε τιμή του L υπολογίστηκε το μέσο τετραγωνικό σφάλμα ανακατασκευής

$$\text{MSE} = \frac{1}{N} \sum_{i=1}^N (x_i - \hat{x}_i)^2 \quad (26)$$

4.2 Αποτελέσματα

Reconstructions




Figure 8: kernel PCA reconstructions for different values of L .

Οι Εικόνες 8a και 8b παρουσιάζουν παραδείγματα ανακατασκευής εικόνων χρησιμοποιώντας διαφορετικό αριθμό kernel principal components.

Η γενική συμπεριφορά είναι παρόμοια με εκείνη που παρατηρήθηκε στην κλασική PCA. Για μικρές τιμές του L , όπως $L = 1$ και $L = 8$, διατηρείται κυρίως η βασική μορφή των ψηφίων, ενώ αρκετές λεπτομέρειες εμφανίζονται θολές. Καθώς αυξάνεται ο αριθμός των συνιστωσών, οι ανακατασκευές γίνονται σταδιακά πιο πιστές ως προς τις αρχικές εικόνες.

Για $L = 64$ η ποιότητα της ανακατασκευής είναι ήδη αρκετά υψηλή και τα βασικά χαρακτηριστικά των ψηφίων διατηρούνται σχεδόν πλήρως. Για $L = 256$ η βελτίωση είναι μικρότερη αλλά εξακολουθεί να οδηγεί σε πιο ακριβή προσέγγιση της αρχικής εικόνας.

Σε αντίθεση με το κλασικό PCA, παρατηρούνται αχνά artifacts στο background των reconstructed εικόνων. Τα στοιχεία αυτά οφείλονται στην προσεγγιστική inverse transformation του KPCA.

Reconstruction Error Histograms





Figure 9: kernel PCA reconstruction error histograms.

Τα ιστογράμματα παρουσιάζουν την κατανομή του reconstruction error για όλα τα δείγματα των δύο κατηγοριών και για διαφορετικές τιμές του L .


Παρατηρείται ότι όσο αυξάνεται ο αριθμός των kernel principal components, οι κατανομές μετατοπίζονται προς μικρότερες τιμές MSE όπως έχουμε αναφέρει και στο PCA παραπάνω.

Παράλληλα, οι κατανομές γίνονται πιο στενές καθώς αυξάνεται το L , γεγονός που υποδηλώνει μικρότερη διασπορά του reconstruction error.

Mean Reconstruction Error



(a) Digit 8



(b) Digit 0

Figure 10: Mean reconstruction error as a function of L .

Η Εικόνα 10 παρουσιάζει τη μέση τιμή του reconstruction error ως συνάρτηση του αριθμού των kernel principal components.

Η μεγαλύτερη βελτίωση εμφανίζεται από $L = 1$ έως περίπου $L = 64$, ενώ στη συνέχεια οι καμπύλες τείνουν να σταθεροποιηθούν.

4.2.1 PCA vs KPCA

Συγκρίνοντας τα αποτελέσματα των δύο μεθόδων, παρατηρείται ότι το kernel PCA παρουσιάζει αρκετά παρόμοια συμπεριφορά με την κλασική PCA ως προς την ποιότητα ανακατασκευής των εικόνων.

Για μικρές τιμές του αριθμού συνιστωσών, όπως $L = 1$, $L = 8$ και $L = 16$, οι δύο μέθοδοι δίνουν παρόμοια αποτελέσματα τόσο οπτικά όσο και ως προς το reconstruction error. Και στις δύο περιπτώσεις η ποιότητα της ανακατασκευής βελτιώνεται σταδιακά όσο αυξάνεται το L , καθώς διατηρείται μεγαλύτερο ποσοστό της πληροφορίας των δεδομένων.

Για μεγαλύτερες τιμές του L , η κλασική PCA εμφανίζει ελαφρώς μικρότερο reconstruction error σε σχέση με το KPCA. Τα συγκεκριμένα δεδομένα, φαίνεται να μπορούν να περιγραφούν αρκετά καλά ακόμη και μέσα από ένα γραμμικό μοντέλο. Για τον λόγο αυτό, η επιπλέον πολυπλοκότητα που εισάγει το kernel PCA δεν οδηγεί σε κάποια σημαντική βελτίωση της ανακατασκευής.

Παρατηρείται επίσης ότι στις reconstructed εικόνες του KPCA εμφανίζονται ορισμένα αχνά artifacts στο background, τα οποία δεν εμφανίζονται τόσο έντονα στην κλασική PCA. Αυτό οφείλεται στο γεγονός ότι η ανακατασκευή στο kernel PCA βασίζεται σε μια προσεγγιστική inverse transformation.

Συνολικά, για τα δύο ψηφία που εξετάστηκαν στην παρούσα εργασία, οι διαφορές μεταξύ PCA και KPCA είναι σχετικά μικρές. Τα αποτελέσματα δείχνουν ότι η κλασική PCA είναι ήδη αρκετά αποτελεσματική για την αναπαράσταση των συγκεκριμένων δεδομένων.

5 Part 3 - Autoencoders

5.1 Linear AE

5.1.1 Υλοποίηση

Για το συγκεκριμένο πείραμα υλοποιήθηκε ένας linear autoencoder χρησιμοποιώντας τη βιβλιοθήκη pytorch.

Οι εικόνες του MNIST αναπαραστάθηκαν ως διανύσματα 784 χαρακτηριστικών και οι τιμές των pixels διατηρήθηκαν στο διάστημα $([0,1])$. Η αρχιτεκτονική του δικτύου αποτελείται από έναν encoder και έναν decoder με διάσταση latent χώρου ίση με 128:

$$\mathbb{R}^{784} \rightarrow \mathbb{R}^{128} \rightarrow \mathbb{R}^{784} \quad (27)$$

Ο encoder και ο decoder υλοποιήθηκαν ως γραμμικά χωρίς μη γραμμικές συναρτήσεις ενεργοποίησης μεταξύ τους. Στην έξοδο χρησιμοποιήθηκε sigmoid ώστε οι reconstructed εικόνες να παραμένουν στην ίδια κλίμακα τιμών με τα αρχικά δεδομένα.

Η εκπαίδευση πραγματοποιήθηκε για 40 epochs με batch size 250 χρησιμοποιώντας BCE loss και Adam optimizer με learning rate (10^{-3}) .

Μετά την ολοκλήρωση της εκπαίδευσης πραγματοποιήθηκαν έγιναν εικόνων του test set και υπολογίστηκε το reconstruction error μέσω MSE ώστε να είναι δυνατή η άμεση σύγκριση με τα αποτελέσματα του global PCA που παρουσιάστηκαν στο πρώτο μέρος της εργασίας.

5.1.2 Αποτελέσματα

Training Loss




Figure 11: Training loss of the Linear Autoencoder.

Η Εικόνα 11 παρουσιάζει την εξέλιξη της BCE loss κατά τη διάρκεια της εκπαίδευσης.

Παρατηρείται ότι το loss μειώνεται γρήγορα στα πρώτα epochs και στη συνέχεια σταθεροποιείται σταδιακά. Η τελική τιμή μετά από 40 epochs είναι περίπου 0.080, γεγονός που δείχνει ότι το μοντέλο έχει συγχλίνει.

Image Reconstructions




Figure 12: Original images and Linear Autoencoder reconstructions.

Η Εικόνα 12 παρουσιάζει παραδείγματα ανακατασκευής εικόνων από το test set.

Παρά τη μείωση της διάστασης από 784 σε 128 χαρακτηριστικά, τα ψηφία παραμένουν εύκολα αναγνωρίσιμα και η συνολική μορφή τους διατηρείται σε μεγάλο βαθμό. Οι reconstructed εικόνες εμφανίζονται ελαφρώς πιο ομαλές από τις αρχικές και σε ορισμένες περιπτώσεις παρατηρείται μικρός θόρυβος στο background.

Reconstruction Error

Για την ποσοτική αξιολόγηση της ανακατασκευής υπολογίστηκε το mean squared error στο test set.

Η τιμή που προέκυψε ήταν:

$$\text{MSE} = 0.004925 \quad (28)$$

Η χαμηλή τιμή του σφάλματος επιβεβαιώνει ότι το μοντέλο ανακατασκευάζει αποτελεσματικά τις εικόνες του dataset χρησιμοποιώντας λιγότερες διαστάσεις από τις αρχικές.

5.2 Nonlinear AE

5.2.1 Υλοποίηση

Μετά την υλοποίηση του linear autoencoder, έγινε η χρήση ενός βαθύτερου νευρωνικού δικτύου με μη γραμμικές συναρτήσεις ενεργοποίησης, ώστε να μελετηθεί κατά πόσο μπορεί να επιτευχθεί καλύτερη αναπαράσταση και ανακατασκευή των εικόνων του dataset.

Έτσι λοποιήθηκε ένας nonlinear autoencoder αποτελούμενος από έναν encoder και έναν decoder. Ο encoder μειώνει σταδιακά τη διάσταση των δεδομένων από τα 784 χαρακτηριστικά της αρχικής εικόνας σε έναν latent χώρο διάστασης 128, ενώ ο decoder πραγματοποιεί την αντίστροφη διαδικασία με στόχο την ανακατασκευή της αρχικής εικόνας.

Η αρχιτεκτονική του encoder είναι:

$$784 \rightarrow 512 \rightarrow 256 \rightarrow 128 \quad (29)$$

ενώ η αρχιτεκτονική του decoder είναι:

$$128 \rightarrow 256 \rightarrow 512 \rightarrow 784 \quad (30)$$

Στα ενδιάμεσα επίπεδα χρησιμοποιήθηκε η συνάρτηση ενεργοποίησης ReLU, ενώ στο τελευταίο επίπεδο χρησιμοποιήθηκε sigmoid ώστε οι τιμές των pixels να παραμένουν στο διάστημα $[0, 1]$ και η εκπαίδευση έγινε στο training set του MNIST για 40 epochs με batch size ίσο με 250. Ως συνάρτηση κόστους χρησιμοποιήθηκε η BCE loss και η βελτιστοποίηση έγινε με τον αλγόριθμο Adam και learning rate 10^{-3} . Το μοντέλο περιέχει συνολικά 1,130,496 εκπαιδευσιμες παραμέτρους.

5.2.2 Αποτελέσματα

Training Loss

Η εξέλιξη της BCE loss κατά τη διάρκεια της εκπαίδευσης παρουσιάζεται στην Εικόνα 13.




Figure 13: Training loss του nonlinear autoencoder.

Παρατηρείται ότι η τιμή της loss μειώνεται σημαντικά ήδη από τα πρώτα epochs και στη συνέχεια συνεχίζει να μειώνεται με πιο αργό ρυθμό μέχρι το τέλος της εκπαίδευσης. Η καμπύλη εμφανίζει ομαλή συμπεριφορά χωρίς απότομες μεταβολές ή αστάθειες, γεγονός που δείχνει ότι η διαδικασία εκπαίδευσης εξελίχθηκε κανονικά. Η τελική τιμή της BCE loss μετά από 40 epochs είναι 0.074433.

Image Reconstructions

Για την αξιολόγηση του μοντέλου εξετάστηκαν οι ανακατασκευές εικόνων από το test set.




Figure 14: Original και reconstructed εικόνες από τον nonlinear autoencoder.

Στην Εικόνα 14 παρουσιάζονται χαρακτηριστικά παραδείγματα αρχικών και ανακατασκευασμένων εικόνων και οι περισσότερες είναι κοντά στις αρχικές εικόνες. Τα βασικά χαρακτηριστικά κάθε ψηφίου παραμένουν αναλλοίωτα και τα δείγματα μπορούν να αναγνωριστούν.

Επίσης υπάρχουν artifacts στο υπόβαθρο των εικόνων, κυρίως γύρω από τις περιοχές όπου υπάρχουν έντονες μεταβολές φωτεινότητας.

Reconstruction Error

Για την ποσοτική αξιολόγηση της απόδοσης του μοντέλου υπολογίστηκε το mse στο test set.

$$\text{MSE} = 0.004680 \quad (31)$$

Η τιμή αυτή αντιστοιχεί σε αρκετά μικρό reconstruction error και δείχνει ότι ο nonlinear autoencoder καταφέρνει να ανακατασκευάζει με ακρίβεια τις εικόνες που δεν χρησιμοποιήθηκαν κατά την εκπαίδευση.

5.3 Tied Weights AE

5.3.1 Υλοποίηση

Στη συνέχεια υλοποιήθηκε ένας tied weights autoencoder παρόμοιας αρχιτεκτονικής με τον nonlinear autoencoder. Η βασική διαφορά είναι ότι σε αυτή την περίπτωση ο decoder δεν διαθέτει δικά του ανεξάρτητα βάρη, αλλά χρησιμοποιεί τα transpose βάρη του encoder. Η προσέγγιση αυτή ακολουθεί περισσότερο τη λογική της PCA, όπου η διαδικασία της ανακατασκευής συνδέεται άμεσα με τον μετασχηματισμό που χρησιμοποιήθηκε κατά τη συμπίεση των δεδομένων.

Η αρχιτεκτονική του encoder είναι:

$$784 \rightarrow 512 \rightarrow 256 \rightarrow 128 \quad (32)$$

ενώ ο decoder ακολουθεί την αντίστροφη πορεία:

$$128 \rightarrow 256 \rightarrow 512 \rightarrow 784 \quad (33)$$

Αν τα βάρη του encoder συμβολιστούν ως:

$$W_1, W_2, W_3$$

τότε τα αντίστοιχα βάρη του decoder δεν εκπαιδεύονται ανεξάρτητα αλλά υπολογίζονται ως:

$$W_4 = W_3^T \quad (34)$$

$$W_5 = W_2^T \quad (35)$$

$$W_6 = W_1^T \quad (36)$$

Με τον τρόπο αυτό εκπαιδεύονται μόνο τα βάρη του encoder και συνεπώς ο συνολικός αριθμός των trainable parameters μειώνεται σημαντικά σε σχέση με τον nonlinear autoencoder.

Η ιδέα αυτή σχετίζεται άμεσα με τη λογική της PCA. Στην PCA η προβολή των δεδομένων στον χώρο των principal components πραγματοποιείται μέσω της σχέσης:

$$z = V^T x \quad (37)$$

ενώ η ανακατασκευή γίνεται μέσω:

$$\hat{x} = Vz \quad (38)$$

δηλαδή χρησιμοποιώντας το transpose του πίνακα προβολής. Με παρόμοιο τρόπο, στον tied weights autoencoder η πληροφορία κωδικοποιείται μέσω των βαρών του encoder και ανακατασκευάζεται μέσω των transpose βαρών του.

Σύμφωνα με την εκφώνηση εξετάστηκε επίσης η χρήση Leaky ReLU στον encoder με slope ίσο με 0.2. Για να προσεγγίζεται καλύτερα η αντίστροφη διαδικασία στον decoder, χρησιμοποιήθηκε Leaky ReLU με slope:

$$\frac{1}{0.2} = 5 \quad (39)$$

στο αρνητικό τμήμα της συνάρτησης. Έτσι χρησιμοποιήθηκε Leaky ReLU με slope 0.2 στον encoder και slope 5 στον decoder, ενώ στο τελευταίο επίπεδο χρησιμοποιήθηκε sigmoid ώστε οι τιμές των reconstructed pixels να παραμένουν στο διάστημα $[0, 1]$.

Η εκπαίδευση πραγματοποιήθηκε για 40 epochs με batch size ίσο με 250 χρησιμοποιώντας BCE loss και Adam optimizer με learning rate 10^{-3} . Το μοντέλο περιέχει συνολικά

$$565248 \quad (40)$$

trainable parameters, δηλαδή περίπου τις μισές παραμέτρους από εκείνες του nonlinear autoencoder.

5.3.2 Αποτελέσματα

Reconstruction Error

Για την ποσοτική αξιολόγηση της απόδοσης του μοντέλου υπολογίστηκε το reconstruction error στο test set μέσω του MSE.

$$\text{MSE} = 0.002641 \quad (41)$$

Η τιμή αυτή είναι η μικρότερη που έχει παρατηρηθεί μέχρι στιγμής στις μεθόδους που εξετάστηκαν. Παρότι ο tied weights autoencoder χρησιμοποιεί λιγότερες παραμέτρους από τον nonlinear autoencoder, καταφέρνει να πετύχει καλύτερη ανακατασκευή και μικρότερο reconstruction error στο test set.

5.4 Pseudo Inverse AE

5.4.1 Υλοποίηση

Στο τελευταίο πείραμα υλοποιήθηκε ένας pseudo inverse autoencoder με στόχο να μελετηθεί μια διαφορετική προσέγγιση για την ανακατασκευή των δεδομένων. Σε αντίθεση με τον nonlinear autoencoder, όπου ο decoder διαθέτει δικά του trainable weights, αλλά και σε αντίθεση με τον tied weights autoencoder όπου χρησιμοποιούνται τα transpose βάρη του encoder, εδώ η διαδικασία της ανακατασκευής βασίζεται στον Moore Penrose των πινάκων βαρών του encoder.

Η αρχιτεκτονική του encoder είναι ίδια με εκείνη που χρησιμοποιήθηκε στα προηγούμενα μοντέλα:

$$784 \rightarrow 512 \rightarrow 256 \rightarrow 128 \quad (42)$$

ενώ στα ενδιάμεσα επίπεδα χρησιμοποιούνται ενεργοποιήσεις Leaky ReLU.

Αν τα βάρη του encoder συμβολιστούν ως:

$$W_1, W_2, W_3$$

τότε κατά τη διαδικασία της αποκωδικοποίησης χρησιμοποιούνται οι αντίστοιχοι Moore-Penrose pseudo inverses:

$$W_3^+, W_2^+, W_1^+$$

όπου το σύμβολο $+$ δηλώνει τον pseudo inverse.

Μπορεί να θεωρηθεί ως μια γενίκευση του κλασικού αντίστροφου πίνακα και έχει το πλεονέκτημα ότι μπορεί να υπολογιστεί ακόμη και όταν ένας πίνακας δεν είναι τετραγωνικός. Αυτό είναι απαραίτητο στη συγκεκριμένη περίπτωση, καθώς τα βάρη του encoder έχουν διαστάσεις:

$$512 \times 784, \quad 256 \times 512, \quad 128 \times 256$$

και επομένως δεν διαθέτουν κανονικό αντίστροφο πίνακα.

Η βασική ιδέα πίσω από τη χρήση του pseudo inverse είναι ότι παρέχει προσέγγιση της αντίστροφης απεικόνισης με την έννοια των ελαχίστων τετραγώνων. Με άλλα λόγια, για μια δεδομένη latent αναπαράσταση προσπαθεί να βρει την εικόνα που ανακατασκευάζεται με το μικρότερο δυνατό σφάλμα.

Όπως και στον tied weights autoencoder, μόνο τα βάρη του encoder εκπαιδεύονται. Ο decoder υπολογίζεται δυναμικά από τους pseudo inverses των βαρών του encoder και συνεπώς ο συνολικός αριθμός των trainable parameters παραμένει:

$$565248$$

δηλαδή περίπου ο μισός από τον αντίστοιχο αριθμό παραμέτρων του nonlinear autoencoder.

Η εκπαίδευση πραγματοποιήθηκε για 40 epochs με batch size ίσο με 250 χρησιμοποιώντας BCE loss και Adam optimizer με learning rate 10^{-3} .

5.4.2 Αποτελέσματα

Training Loss

Η Εικόνα 15 παρουσιάζει την εξέλιξη της BCE loss κατά τη διάρκεια της εκπαίδευσης.




Figure 15: Training loss του pseudo-inverse autoencoder.

Παρατηρείται ότι η loss μειώνεται γρήγορα στα πρώτα epochs και στη συνέχεια συνεχίζει να μειώνεται με πιο αργό ρυθμό μέχρι το τέλος της εκπαίδευσης. Η καμπύλη παραμένει ομαλή σε όλη τη διάρκεια της διαδικασίας και δεν εμφανίζει έντονες διακυμάνσεις, γεγονός που δείχνει ότι η εκπαίδευση του μοντέλου παραμένει σταθερή.

Η τελική τιμή της BCE loss μετά από 40 epochs είναι:

0.070196

τιμή η οποία είναι χαμηλή και δείχνει ότι το μοντέλο έχει συγκλίνει σε μια καλή λύση.

Image Reconstructions

Για την αξιολόγηση του μοντέλου εξετάστηκαν οι ανακατασκευές εικόνων από το test set.




Figure 16: Original και reconstructed εικόνες από τον pseudo-inverse autoencoder.

Στην Εικόνα 16 παρουσιάζονται χαρακτηριστικά παραδείγματα αρχικών και reconstructed εικόνων.

Παρατηρείται ότι οι reconstructed εικόνες είναι ιδιαίτερα κοντά στις αρχικές και όλα τα ψηφία παραμένουν εύκολα αναγνωρίσιμα. Οι καμπύλες, τα περιγράμματα και τα βασικά μορφολογικά χαρακτηριστικά των ψηφίων διατηρούνται.

Reconstruction Error

Για την ποσοτική αξιολόγηση της απόδοσης του μοντέλου υπολογίστηκε το MSE στο test set.

$$\text{MSE} = 0.002878 \quad (43)$$

Η τιμή αυτή είναι μικρότερη από εκείνες που επιτεύχθηκαν από τον linear autoencoder και τον nonlinear autoencoder, γεγονός που δείχνει ότι η χρήση του pseudo inverse στον decoder οδηγεί σε αρκετά ακριβείς ανακατασκευές.

5.5 Τελική Σύγκριση των Autoencoders

Μετά την υλοποίηση όλων των autoencoders πραγματοποιήθηκε μια συνολική σύγκριση των αποτελεσμάτων τους. Όλα τα μοντέλα εκπαιδεύτηκαν στο ίδιο σύνολο δεδομένων χρησιμοποιώντας 40 epochs, batch size ίσο με 250 και BCE loss. Για την ποσοτική αξιολόγηση χρησιμοποιήθηκε το reconstruction error μέσω του MSE στο test set.

Method	Trainable Parameters	Test MSE
PCA ($L = 128$)	-	0.003402
Linear AE	200704	0.005106
Nonlinear AE	1130496	0.004680
Tied Weights AE	565248	0.002641
Pseudo-Inverse AE	565248	0.002878

Table 1: Συγκεντρωτική σύγκριση των μεθόδων ανακατασκευής.

Από τα αποτελέσματα του Πίνακα 1 φαίνεται αρχικά ότι ο linear autoencoder παρουσιάζει το μεγαλύτερο reconstruction error από όλους τους autoencoders που υλοποιήθηκαν καθώς το μοντέλο βασίζεται αποκλειστικά σε γραμμικούς μετασχηματισμούς. Παρότι χρησιμοποιεί latent space διάστασης 128, η συνολική συνάρτηση που μαθαίνει παραμένει γραμμική και επομένως η δυνατότητα αναπαράστασης πιο σύνθετων δομών των δεδομένων είναι περιορισμένη.

Η εισαγωγή μη γραμμικών ενεργοποιήσεων στον nonlinear autoencoder οδηγεί σε μείωση του reconstruction error. Οι ReLU ενεργοποιήσεις επιτρέπουν στο δίκτυο να μάθει πιο σύνθετους μετασχηματισμούς και να εκμεταλλευτεί καλύτερα τη δομή των δεδομένων. Ως αποτέλεσμα οι ανακατασκευές βελτιώνονται και το MSE μειώνεται σε σχέση με τον linear autoencoder.

Τα καλύτερα αποτελέσματα προέκυψαν από τα δύο μοντέλα στα οποία ο decoder δεν διαθέτει ανεξάρτητα βάρη. Ο tied weights autoencoder παρουσιάζει τη μικρότερη τιμή MSE από όλα τα μοντέλα που εξετάστηκαν, παρότι χρησιμοποιεί περίπου τις μισές παραμέτρους από τον nonlinear autoencoder. Το αποτέλεσμα αυτό δείχνει ότι ο περιορισμός που επιβάλλουν τα tied weights λειτουργεί σαν μια μορφή regularization και αναγκάζει το δίκτυο να μάθει πιο συνεπείς και σταθερές latent αναπαραστάσεις.

Πολύ κοντά βρίσκεται και ο pseudo inverse autoencoder, ο οποίος παρουσιάζει παρόμοια συμπεριφορά. Και σε αυτή την περίπτωση ο decoder δεν εκπαιδεύεται ανεξάρτητα, αλλά προκύπτει από τους Moore-Penrose των βαρών του encoder. Το reconstruction error παραμένει χαμηλό και διαφέρει ελάχιστα από εκείνο του tied weights autoencoder, γεγονός που δείχνει ότι και οι δύο προσεγγίσεις οδηγούν σε αποτελεσματικές ανακατασκευές.

Το αποτέλεσμα αυτό δείχνει ότι οι μη γραμμικές αναπαραστάσεις που μαθαίνουν τα νευρωνικά δίκτυα μπορούν να περιγράψουν αποτελεσματικότερα τη δομή των εικόνων του MNIST σε σχέση με έναν αποκλειστικά γραμμικό υποχώρο.

Συνολικά, τα αποτελέσματα δείχνουν ότι η αύξηση του αριθμού των παραμέτρων δεν οδηγεί απαραίτητα σε καλύτερη απόδοση.

6 Part 4 - Variational Autoencoders

6.1 Υλοποίηση

Για την υλοποίηση του vae χρησιμοποιήθηκε πλήρως συνδεδεμένη αρχιτεκτονική παρόμοια με εκείνες των προηγούμενων autoencoders, ώστε τα αποτελέσματα να μπορούν να συγκριθούν πιο εύκολα με τα αντίστοιχα των προηγούμενων μοντέλων.

Ο encoder αποτελείται από τρία διαδοχικά επίπεδα:

$$784 \rightarrow 512 \rightarrow 256 \rightarrow 128 \quad (44)$$

με συναρτήσεις ενεργοποίησης ReLU μεταξύ των επιπέδων. Από την έξοδο των 128 χαρακτηριστικών δεν παράγεται απευθείας το latent vector, αλλά δύο ξεχωριστά διανύσματα που αντιστοιχούν στο μ και στο $\log \sigma^2$. Τα διανύσματα αυτά υπολογίζονται μέσω δύο ανεξάρτητων fully connected επιπέδων και χρησιμοποιούνται για τον ορισμό της Gaussian κατανομής κάθε δείγματος στον latent χώρο.

Σύμφωνα με τις απαιτήσεις της εκφώνησης χρησιμοποιήθηκε latent χώρος διάστασης:

$$L = 2 \quad (45)$$

ώστε να είναι δυνατή η απεικόνιση των λανθανουσών αναπαραστάσεων σε δύο διαστάσεις και η μελέτη της δομής του latent χώρου.

Ο decoder ακολουθεί συμμετρική αρχιτεκτονική:

$$2 \rightarrow 128 \rightarrow 256 \rightarrow 512 \rightarrow 784 \quad (46)$$

χρησιμοποιώντας ReLU στα ενδιάμεσα επίπεδα και sigmoid στο τελευταίο επίπεδο, ώστε οι τιμές των reconstructed pixels να παραμένουν στο διάστημα $[0, 1]$.

Η εκπαίδευση πραγματοποιήθηκε με τη συνάρτηση κόστους του vae, η οποία συνδυάζει τον όρο ανακατασκευής με τον όρο KL divergence. Για τον υπολογισμό του reconstruction loss χρησιμοποιήθηκε binary cross entropy με επιλογής `reduction="sum"` έχει ως αποτέλεσμα το reco loss να υπολογίζεται ως άθροισμα του σφάλματος σε όλα τα pixels του batch και όχι ως μέσος όρος. Για τον λόγο αυτό οι τιμές της loss εμφανίζονται σημαντικά μεγαλύτερες από εκείνες των προηγούμενων autoencoders

Η εκπαίδευση εκτελέστηκε για 100 epochs με batch size ίσο με 250 και Adam optimizer με learning rate:

$$10^{-3} \quad (47)$$

Το μοντέλο περιέχει συνολικά:

$$1131264 \quad (48)$$

εκπαιδύσιμες παραμέτρους.

Για την αξιολόγηση της generative ικανότητας του μοντέλου δημιουργήθηκε ένα σταθερό σύνολο latent vectors από την κατανομή:

$$z \sim \mathcal{N}(0, I) \quad (49)$$

Τα ίδια ακριβώς δείγματα δόθηκαν στον decoder μετά τα epochs 1, 50 και 100, ώστε να παρατηρηθεί πώς εξελίσσεται η ποιότητα των παραγόμενων εικόνων κατά τη διάρκεια της εκπαίδευσης.

Μετά την ολοκλήρωση της εκπαίδευσης δημιουργήθηκαν επίσης ανακατασκευές εικόνων από το test set, καθώς και η δισδιάστατη απεικόνιση του latent χώρου. Για τη δημιουργία του scatter plot χρησιμοποιήθηκαν οι τιμές του διανύσματος μ , καθώς αυτό εκφράζει το κέντρο της gaussian κατανομής που αντιστοιχεί σε κάθε εικόνα.

6.2 Αποτελέσματα

6.2.1 Training Loss




Figure 17: Training loss του vae.

Η Εικόνα 17 παρουσιάζει την εξέλιξη της συνολικής loss κατά τη διάρκεια της εκπαίδευσης του vae.

Παρατηρείται ότι η loss μειώνεται αρκετά γρήγορα στα πρώτα epochs και στη συνέχεια συνεχίζει να μειώνεται με πιο αργό ρυθμό μέχρι το τέλος της εκπαίδευσης. Η μεγάλη βελτίωση εμφανίζεται περίπου στα πρώτα 20 epochs, ενώ μετά το epoch 50 η καμπύλη αρχίζει να σταθεροποιείται σταδιακά.

Έπειτα ,μικρές διακυμάνσεις εμφανίζονται κατά τη διάρκεια της εκπαίδευσης λόγω της στοχαστικής φύσης του vae, της τυχαίας δειγματοληψίας στο latent space και της εκπαίδευσης με mini batches.

Η τελική τιμή της loss μετά από 100 epochs είναι περίπου:

$$\mathcal{L} = 145.64 \quad (50)$$

Η τιμή αυτή είναι μεγαλύτερη από εκείνες που παρατηρήθηκαν στους προηγούμενους autoencoders, καθώς η loss του vae περιλαμβάνει όχι μόνο το reconstruction loss αλλά και τον όρο KL divergence, ο οποίος λειτουργεί ως regularization και αναγκάζει τις latent κατανομές να παραμένουν κοντά στην $\mathcal{N}(0, I)$.

6.2.2 Image Reconstructions




Figure 18: Original και reconstructed εικόνες από τον vae.

Η Εικόνα 18 παρουσιάζει παραδείγματα αρχικών και reconstructed εικόνων από το test set.

Παρατηρείται ότι ο vae καταφέρνει να διατηρήσει τη γενική μορφή των ψηφίων και οι περισσότερες εικόνες παραμένουν αναγνωρίσιμες. Ωστόσο, οι ανακατασκευές εμφανίζονται πιο θολές σε σχέση με εκείνες των προηγούμενων autoencoders και αρκετές λεπτομέρειες χάνονται κατά τη συμπίεσης. Οι λεπτές γραμμές και τα πιο τοπικά χαρακτηριστικά γίνονται πιο αχνά, ενώ σε ορισμένες περιπτώσεις εμφανίζονται μικρές αλλοιώσεις στο σχήμα των ψηφίων.

Η αυτό συμβαίνει γιατί ο vae δεν προσπαθεί μόνο να πετύχει καλή ανακατασκευή, αλλά ταυτόχρονα να οργανώσει τον latent χώρο ώστε να ακολουθεί μια κανονική κατανομή. Επιπλέον, στην παρούσα υλοποίηση χρησιμοποιήθηκε latent space δύο διαστάσεων ($L = 2$), γεγονός που περιορίζει την ποσότητα πληροφορίας που μπορεί να αποθηκευτεί για κάθε εικόνα.

Το φαινόμενο αυτό είναι εμφανές σε ορισμένα δείγματα, όπως στα ψηφία 4 και 5, τα οποία στις ανακατασκευές μοιάζουν περισσότερο με 9 και 8 αντίστοιχα. Κατά τη συμπίεση της πληροφορίας χάνονται χαρακτηριστικά που διαφοροποιούν καθαρά τις κλάσεις, με αποτέλεσμα ο decoder να δημιουργεί σχήματα που βρίσκονται μεταξύ παρόμοιων ψηφίων στο latent space.

6.2.3 Noise Generation

Σύμφωνα με την εκφώνηση, δημιουργήθηκε ένα σταθερό batch θορύβου από την κατανομή:

$$z \sim \mathcal{N}(0, I) \quad (51)$$

και το ίδιο batch χρησιμοποιήθηκε μετά τα epochs 1, 50 και 100.




Figure 19: Generated samples after epoch 1.

Epoch 1 Στην αρχή της εκπαίδευσης ο decoder δεν έχει ακόμη μάθει τη σχέση μεταξύ latent χώρου και εικόνων. Για τον λόγο αυτό τα παραγόμενα δείγματα εμφανίζονται κυρίως ως θόρυβος και δεν θυμίζουν ακόμη πραγματικά ψηφία.




Figure 20: Generated samples after epoch 50.

Epoch 50 Μετά από 50 epochs η εικόνα είναι αρκετά διαφορετική. Πολλά από τα παραγόμενα δείγματα αρχίζουν να αποκτούν μορφή που θυμίζει πραγματικά ψηφία και μπορούν να αναγνωριστούν χαρακτηριστικά σχήματα.

Αυτό δείχνει ότι ο decoder έχει ήδη μάθει μέρος της δομής του latent χώρου και μπορεί να μετατρέψει τυχαία σημεία σε λογικές εικόνες.




Figure 21: Generated samples after epoch 100.

Epoch 100 Μετά την ολοκλήρωση της εκπαίδευσης τα περισσότερα δείγματα αντιστοιχούν πλέον σε αναγνωρίσιμα ψηφία. Παρότι ορισμένες εικόνες εξακολουθούν να εμφανίζουν θόλωση, η γενική μορφή τους είναι σαφής.

6.2.4 Latent Space Visualization




Figure 22: Latent space representation of the test set.

Η Εικόνα 22 παρουσιάζει τη διδιάστατη λανθάνουσα αναπαράσταση των εικόνων του test set. Κάθε σημείο αντιστοιχεί σε ένα δείγμα και το χρώμα του δείχνει την πραγματική κλάση του ψηφίου. Παρατηρείται ότι τα δεδομένα οργανώνονται σε διακριτές περιοχές του χώρου, κάτι που δείχνει ότι ο encoder έχει μάθει να τοποθετεί κοντά μεταξύ τους ψηφία με παρόμοια χαρακτηριστικά.

Οι περισσότερες κλάσεις σχηματίζουν σχετικά ξεχωριστές ομάδες, ωστόσο υπάρχουν και περιοχές όπου διαφορετικά ψηφία επικαλύπτονται, καθώς ορισμένες κλάσεις του dataset παρουσιάζουν σημαντικές οπτικές ομοιότητες. Για παράδειγμα, τα ψηφία 4 και 9 εμφανίζονται σε γειτονικές περιοχές, ενώ αντίστοιχα τα 3, 5 και 8 παρουσιάζουν μεγαλύτερη επικάλυψη λόγω των καμπύλων σχημάτων που τα χαρακτηρίζουν.

Η συμπεριφορά αυτή συνδέεται και με τα αποτελέσματα των ανακατασκευών. Σε ορισμένες περιπτώσεις, κάποια 4 ανακατασκευάζονται με μορφή που θυμίζει 9, ενώ ορισμένα 5 αποκτούν χαρακτηριστικά πιο κοντά στο 8. Οι περιοχές επικάλυψης του latent χώρου επομένως αντανακλούν πραγματικές ομοιότητες των δεδομένων και εξηγούν γιατί ορισμένες ανακατασκευές εμφανίζονται πιο αμφίσημες.

6.2.5 Σύγκριση με τους προηγούμενους Autoencoders

Σε σύγκριση με τους προηγούμενους autoencoders, ο vae ακολουθεί μια αρκετά διαφορετική προσέγγιση. Τα μοντέλα που εξετάστηκαν στα προηγούμενα μέρη της εργασίας είχαν ως βασικό στόχο την όσο το δυνατόν καλύτερη ανακατασκευή των εικόνων. Αντίθετα, ο vae δεν ενδιαφέρεται μόνο για την ποιότητα της ανακατασκευής, αλλά προσπαθεί ταυτόχρονα να οργανώσει τον latent χώρο έτσι ώστε να ακολουθεί μια συγκεκριμένη πιθανοτική κατανομή.

Η διαφορά αυτή φαίνεται άμεσα στα αποτελέσματα. Οι reconstructed εικόνες του vae εμφανίζονται πιο ομαλές και πιο θολές σε σχέση με εκείνες των προηγούμενων autoencoders, ενώ αρκετές λεπτομέρειες χάνονται κατά τη διαδικασία της συμπίεσης. Η συμπεριφορά αυτή οφείλεται κυρίως στον όρο KL divergence, ο οποίος περιορίζει την πληροφορία που μπορεί να αποθηκευτεί στο latent vector και λειτουργεί σαν μια επιπλέον μορφή regularization.

Παρότι η ανακατασκευή δεν είναι τόσο ακριβής όσο στους προηγούμενους autoencoders, ο vae προσφέρει ένα σημαντικό πλεονέκτημα που τα υπόλοιπα μοντέλα δεν διαθέτουν. Μετά την εκπαίδευση μπορεί να δημιουργεί νέα δείγματα ξεκινώντας μόνο από τυχαία σημεία του latent χώρου, χωρίς να χρειάζεται κάποια εικόνα ως είσοδο. Η δυνατότητα αυτή είναι ουσιαστικά το βασικό χαρακτηριστικό που κάνει τον generative μοντέλο.

Επιπλέον, η δισδιάστατη αναπαράσταση του latent χώρου δείχνει ότι το μοντέλο οργανώνει αυτόματα τα δεδομένα με τρόπο που έχει νόημα. Παρόμοια ψηφία τείνουν να τοποθετούνται κοντά μεταξύ τους, ενώ διαφορετικές κατηγορίες σχηματίζουν ξεχωριστές περιοχές του χώρου. Το αποτέλεσμα αυτό προκύπτει χωρίς να χρησιμοποιούνται οι ετικέτες των δεδομένων κατά την εκπαίδευση και δείχνει ότι ο vae έχει μάθει μια οργανωμένη αναπαράσταση των εικόνων.