



UNIVERSITY OF
PATRAS
ΠΑΝΕΠΙΣΤΗΜΙΟ ΠΑΤΡΩΝ

Εργαστηριακή Άσκηση 6

CNNs Ανίχνευση & Εντοπισμός Αντικειμένων

Μαριάνθη Θώδη

Μάιος 2026

Contents

1	Abstract	2
2	Θεωρία	2
2.1	Ανίχνευση και Εντοπισμός Αντικειμένων	2
2.2	Συνελικτικά Νευρωνικά Δίκτυα	2
2.3	Από το R-CNN στο Faster R-CNN	3
2.4	Fast R-CNN και ROI Pooling	3
2.5	Faster R-CNN	4
2.6	SSD (Single Shot Detector)	5
2.7	Intersection over Union	6
2.8	Non-Maximum Suppression	6
2.9	Μετρικές Αξιολόγησης	7
3	Dataset	8
3.1	COCO Dataset	8
3.2	Annotations και Ground Truth Bounding Boxes	8
4	Υλοποίηση	9
4.1	Dataset Loader	9
4.2	Metric Computation	9
4.3	Model Evaluation	10
4.4	Precision-Recall Curves	10
5	Faster R-CNN	10
5.1	Αποτελέσματα	10
6	SSD	12
6.1	Αποτελέσματα	12
7	Σύγκριση Faster R-CNN και SSD	13
7.1	Ταχύτητα Εκτέλεσης	14

1 Abstract

Η παρούσα εργασία ασχολείται με τη μελέτη και την εφαρμογή τεχνικών ανίχνευσης και εντοπισμού αντικειμένων με χρήση συνελικτικών νευρωνικών δικτύων. Αρχικά παρουσιάζονται οι βασικές αρχές λειτουργίας των CNNs, τα οποία αποτελούν τη βάση των περισσότερων σύγχρονων συστημάτων υπολογιστικής όρασης.

Στη συνέχεια μελετώνται οι region-based μέθοδοι ανίχνευσης αντικειμένων και συγκεκριμένα οι R-CNN, Fast R-CNN και Faster R-CNN, με έμφαση στον τρόπο δημιουργίας των προτεινόμενων περιοχών ενδιαφέροντος, στη διαδικασία ταξινόμησης των αντικειμένων και στον εντοπισμό τους μέσω bounding boxes.

Έπειτα παρουσιάζεται η μέθοδος SSD, η οποία πραγματοποιεί ανίχνευση και εντοπισμό αντικειμένων σε ένα μόνο πέρασμα του δικτύου, επιτυγχάνοντας εγαλύτερη ταχύτητα εκτέλεσης.

Τα πειράματα πραγματοποιούνται σε σύνολα δεδομένων εικόνων που περιέχουν αντικείμενα πολλαπλών κατηγοριών και αξιολογούνται τόσο ως προς την ικανότητα αναγνώρισης των αντικειμένων όσο και ως προς την ακρίβεια εντοπισμού τους. Τέλος, πραγματοποιείται σύγκριση μεταξύ των διαφορετικών αρχιτεκτονικών ως προς την ακρίβεια, την ταχύτητα και τη συνολική τους απόδοση. Ο πλήρης κώδικας και τα αρχεία της άσκησης διατίθενται σε repository στο GitHub, στον ακόλουθο σύνδεσμο: [GitHub Repository](#).

2 Θεωρία

2.1 Ανίχνευση και Εντοπισμός Αντικειμένων

Σε αντίθεση με την απλή ταξινόμηση εικόνων, όπου το ζητούμενο είναι να αναγνωριστεί το περιεχόμενο μιας εικόνας, στην ανίχνευση αντικειμένων απαιτείται επιπλέον να προσδιοριστεί και η θέση κάθε αντικειμένου μέσα στην εικόνα.

Ένα σύστημα object detection καλείται επομένως να επιλύσει ταυτόχρονα δύο διαφορετικά προβλήματα. Το πρώτο είναι το classification, δηλαδή η αναγνώριση της κατηγορίας στην οποία ανήκει ένα αντικείμενο, ενώ το δεύτερο είναι το localization, δηλαδή ο προσδιορισμός της θέσης του αντικειμένου μέσα στην εικόνα.

Η θέση αυτή περιγράφεται συνήθως μέσω ενός bounding box, το οποίο μπορεί να αναπαρασταθεί από το διάνυσμα:

$$b = (x, y, w, h)$$

όπου (x, y) είναι οι συντεταγμένες της πάνω αριστερής γωνίας του πλαισίου, ενώ τα w και h αντιστοιχούν στο πλάτος και στο ύψος του αντίστοιχα.

Στα σύγχρονα συστήματα ανίχνευσης η εξαγωγή χαρακτηριστικών πραγματοποιείται με τη χρήση συνελικτικών νευρωνικών δικτύων. Τα δίκτυα αυτά μπορούν να μάθουν αυτόματα χαρακτηριστικά από τις εικόνες.

2.2 Συνελικτικά Νευρωνικά Δίκτυα

Τα συνελικτικά νευρωνικά δίκτυα (CNNs) αποτελούν αρχιτεκτονικές βαθιάς μάθησης που έχουν σχεδιαστεί ειδικά για την επεξεργασία εικόνων. Η βασική τους ιδέα είναι ότι μπορούν να εκμεταλλευτούν τη χωρική δομή των εικόνων και να αναγνωρίσουν χαρακτηριστικά ανεξάρτητα από τη θέση τους.

Η σημαντικότερη πράξη ενός CNN είναι η συνέλιξη. Έστω μία εικόνα εισόδου $I(x, y)$ και ένας πυρήνας συνέλιξης $K(i, j)$. Η έξοδος της συνέλιξης δίνεται από τη σχέση:

$$S(x, y) = \sum_i \sum_j I(x + i, y + j) K(i, j)$$

Ο πυρήνας μετακινείται πάνω στην εικόνα και σε κάθε θέση υπολογίζει ένα σταθμισμένο άθροισμα των γειτονικών pixels. Το αποτέλεσμα είναι ένας νέος χάρτης χαρακτηριστικών (feature map), ο οποίος αναδεικνύει συγκεκριμένα μοτίβα της εικόνας, όπως ακμές, γωνίες ή περιοχές με έντονες μεταβολές φωτεινότητας.

Μετά από κάθε επίπεδο συνέλιξης εφαρμόζεται συνήθως μία μη γραμμική συνάρτηση ενεργοποίησης. Η πιο συνηθισμένη επιλογή είναι η ReLU:

$$f(x) = \max(0, x)$$

η οποία επιτρέπει στο δίκτυο να μαθαίνει μη γραμμικές σχέσεις.

Καθώς αυξάνεται το βάθος του δικτύου, τα πρώτα επίπεδα μαθαίνουν απλά χαρακτηριστικά, όπως γραμμές και ακμές, ενώ τα βαθύτερα επίπεδα συνδυάζουν τις πληροφορίες αυτές και αναγνωρίζουν πιο σύνθετα σχήματα. Το τμήμα του CNN που είναι υπεύθυνο για την εξαγωγή χαρακτηριστικών ονομάζεται backbone network.

2.3 Από το R-CNN στο Faster R-CNN

Η οικογένεια των ανιχνευτών R-CNN αποτέλεσε μία από τις πρώτες προσπάθειες συνδυασμού CNNs και object detection. Η βασική ιδέα ήταν να χρησιμοποιηθεί ένα CNN για την εξαγωγή χαρακτηριστικών από περιοχές της εικόνας που πιθανόν περιέχουν αντικείμενα.

Η εξέλιξη αυτής της οικογένειας μπορεί να συνοψιστεί ως:

$$R-CNN \rightarrow Fast\ R-CNN \rightarrow Faster\ R-CNN$$

Στο αρχικό R-CNN χρησιμοποιούνταν ένας αλγόριθμος selective search, ο οποίος παρήγαγε περίπου 2000 υποψήφιες ROIs για κάθε εικόνα. Κάθε μία από αυτές τις περιοχές γίνεται multi-scale σταθερού μεγέθους και στη συνέχεια δινόταν ξεχωριστά ως είσοδος σε ένα CNN.

Η προσέγγιση αυτή πέτυχε ακρίβεια εντοπισμού, ωστόσο παρουσίαζε πολύ μεγάλο υπολογιστικό κόστος, καθώς το CNN έπρεπε να εκτελεστεί χιλιάδες φορές για κάθε εικόνα. Το πρόβλημα αυτό οδήγησε στην ανάπτυξη των Fast R-CNN και Faster R-CNN, τα οποία βελτίωσαν σημαντικά την ταχύτητα εκτέλεσης χωρίς να θυσιάσουν την ακρίβεια ανίχνευσης.

2.4 Fast R-CNN και ROI Pooling

Το Fast R-CNN αναπτύχθηκε με στόχο να αντιμετωπίσει το βασικό μειονέκτημα του R-CNN, δηλαδή το πολύ μεγάλο υπολογιστικό κόστος. Στο R-CNN το συνελικτικό δίκτυο εκτελείται ξεχωριστά για κάθε υποψήφια περιοχή ενδιαφέροντος, γεγονός που καθιστά τη διαδικασία αργή.

Η βασική ιδέα του Fast R-CNN είναι ότι το CNN εφαρμόζεται μία μόνο φορά σε ολόκληρη την εικόνα. Από την επεξεργασία αυτή προκύπτει ένας χάρτης χαρακτηριστικών:

$$F \in \mathbb{R}^{H \times W \times C}$$

ο οποίος περιέχει τη χρήσιμη πληροφορία της εικόνας σε συμπιεσμένη μορφή.

Οι περιοχές ενδιαφέροντος δεν επεξεργάζονται πλέον απευθείας πάνω στην αρχική εικόνα αλλά προβάλλονται πάνω στον χάρτη χαρακτηριστικών. Επειδή κάθε περιοχή μπορεί να έχει διαφορετικό μέγεθος, απαιτείται ένας μηχανισμός που να μετατρέπει όλες τις περιοχές σε αναπαράστασεις σταθερών διαστάσεων. Για τον σκοπό αυτό χρησιμοποιείται το ROI pooling.

Το ROI pooling χωρίζει κάθε περιοχή σε ένα πλέγμα σταθερού μεγέθους, συνήθως:

$$7 \times 7$$

και εφαρμόζει max pooling σε κάθε υποπεριοχή. Αν συμβολίσουμε με R_{ij} την αντίστοιχη υποπεριοχή, τότε η έξοδος υπολογίζεται ως:

$$y_{ijc} = \max_{(u,v) \in R_{ij}} F(u, v, c)$$

Με τον τρόπο αυτό όλες οι περιοχές μετατρέπονται σε διανύσματα ίδιων διαστάσεων και μπορούν να χρησιμοποιηθούν από τα πλήρως συνδεδεμένα επίπεδα του δικτύου.

Η σημαντικότερη βελτίωση του Fast R-CNN είναι ότι το μεγαλύτερο μέρος των υπολογισμών πραγματοποιείται μόνο μία φορά ανά εικόνα, γεγονός που οδηγεί σε αύξηση της ταχύτητας σε σχέση με το αρχικό R-CNN.

2.5 Faster R-CNN

Παρότι το Fast R-CNN βελτίωσε σημαντικά την ταχύτητα εκτέλεσης, εξακολουθούσε να εξαρτάται από τον αλγόριθμο selective search για την παραγωγή των περιοχών ενδιαφέροντος. Η διαδικασία αυτή παρέμενε σχετικά αργή και αποτελούσε το βασικό σημείο συμφόρησης του συστήματος.

Ο Faster R-CNN λύνει το πρόβλημα αυτό εισάγοντας το region proposal network (RPN), το οποίο παράγει αυτόματα τις υποψήφιες περιοχές απευθείας πάνω στους χάρτες χαρακτηριστικών του backbone δικτύου.

Για κάθε θέση του feature map δημιουργούνται προκαθορισμένα πλαίσια διαφορετικών διαστάσεων και αναλογιών, τα οποία είναι γνωστά ως anchor boxes. Για κάθε anchor το δίκτυο προβλέπει δύο πράγματα:

- την πιθανότητα να περιέχει κάποιο αντικείμενο,
- διορθώσεις στις συντεταγμένες του πλαισίου.

Οι διορθώσεις αυτές υπολογίζονται μέσω των μεταβλητών:

$$t_x = \frac{x_g - x}{w}$$

$$t_y = \frac{y_g - y}{h}$$

$$t_w = \log \left(\frac{w_g}{w} \right)$$

$$t_h = \log \left(\frac{h_g}{h} \right)$$

όπου (x, y, w, h) αντιστοιχούν στο αρχικό anchor box και (x_g, y_g, w_g, h_g) στο αντίστοιχο ground truth πλαίσιο.

Οι περιοχές που παράγονται από το RPN προωθούνται στο δεύτερο στάδιο του δικτύου, όπου πραγματοποιείται η τελική ταξινόμηση των αντικειμένων και η περαιτέρω βελτίωση των bounding boxes.

Η συνολική συνάρτηση κόστους του Faster R-CNN περιλαμβάνει έναν όρο ταξινόμησης και έναν όρο εντοπισμού:

$$L = L_{cls} + \lambda L_{loc}$$

όπου L_{cls} είναι το classification loss και L_{loc} το localization loss.

Ο όρος L_{cls} αντιστοιχεί στο σφάλμα ταξινόμησης και υπολογίζεται μέσω της συνάρτησης cross entropy. Αν p_{true} είναι η πιθανότητα που αποδίδει το δίκτυο στη σωστή κλάση, τότε:

$$L_{cls} = -\log(p_{true})$$

Η συνάρτηση αυτή παίρνει μικρή τιμή όταν το δίκτυο δίνει μεγάλη πιθανότητα στη σωστή κλάση και μεγάλη τιμή όταν η πιθανότητα αυτή είναι μικρή.

Ο όρος L_{loc} αφορά την ακρίβεια εντοπισμού των bounding boxes και για τον σκοπό αυτό χρησιμοποιείται η smooth L1 loss:

$$SL_1(x) = \begin{cases} x^2, & |x| < 1 \\ |x| - \frac{1}{2}, & |x| \geq 1 \end{cases}$$

Η smooth L1 loss συμπεριφέρεται σαν τετραγωνικό σφάλμα για μικρές αποκλίσεις και σαν απόλυτο σφάλμα για μεγάλες αποκλίσεις. Έτσι επιτρέπεται διόρθωση μικρών λαθών, ενώ ταυτόχρονα είναι λιγότερο ευαίσθητη σε πολύ μεγάλα σφάλματα ή outliers.

Η αρχιτεκτονική αυτή θεωρείται detector δύο σταδίων (two-stage detector), καθώς η διαδικασία παραγωγής περιοχών και η τελική ταξινόμηση πραγματοποιούνται σε δύο διαδοχικά βήματα. Το κύριο πλεονέκτημά της είναι η ακρίβεια εντοπισμού, ιδιαίτερα σε μικρά αντικείμενα ή σε σύνθετες σκηνές.

2.6 SSD (Single Shot Detector)

Σε αντίθεση με τον Faster R-CNN, ο SSD ανήκει στην κατηγορία των one-stage detectors. Η βασική του φιλοσοφία είναι ότι η ανίχνευση και η ταξινόμηση πραγματοποιούνται ταυτόχρονα σε ένα μόνο πέρασμα του δικτύου, χωρίς να προηγείται ξεχωριστό στάδιο παραγωγής περιοχών ενδιαφέροντος.

Για να μπορεί να εντοπίζει αντικείμενα διαφορετικών μεγεθών, ο SSD αξιοποιεί πολλαπλούς χάρτες χαρακτηριστικών διαφορετικής ανάλυσης, όπως:

$$38 \times 38, 19 \times 19, 10 \times 10, 5 \times 5, 3 \times 3, 1 \times 1$$

Οι χάρτες υψηλής ανάλυσης χρησιμοποιούνται κυρίως για μικρά αντικείμενα, ενώ οι χάρτες χαμηλότερης ανάλυσης είναι καταλληλότεροι για μεγαλύτερα αντικείμενα.

Σε κάθε θέση των feature maps ορίζονται προκαθορισμένα πλαίσια, γνωστά ως default boxes. Για κάθε πλαίσιο το δίκτυο προβλέπει τόσο τις πιθανότητες των κλάσεων όσο και τις διορθώσεις των συντεταγμένων του bounding box.

Η συνολική συνάρτηση κόστους γράφεται ως:

$$L = \frac{1}{N} (L_{conf} + \alpha L_{loc})$$

όπου L_{conf} αντιστοιχεί στο classification loss, L_{loc} στο localization loss και N στο πλήθος των θετικών αντιστοιχίσεων.

Το σημαντικότερο πλεονέκτημα του SSD είναι η υψηλή ταχύτητα εκτέλεσης, γεγονός που τον καθιστά κατάλληλο για real time applications.

2.7 Intersection over Union

Για να μπορέσουμε να αξιολογήσουμε πόσο σωστά εντοπίζει ένα μοντέλο τη θέση ενός αντικειμένου, δεν αρκεί να γνωρίζουμε μόνο αν αναγνώρισε τη σωστή κατηγορία. Είναι εξίσου σημαντικό να εξετάσουμε και το πόσο καλά συμπίπτει το προβλεπόμενο bounding box με το πραγματικό bounding box του αντικειμένου.

Η πιο διαδεδομένη μετρική για τον σκοπό αυτό είναι η Intersection over Union (IoU). Η μετρική αυτή συγκρίνει το προβλεπόμενο πλαίσιο με το αντίστοιχο ground truth πλαίσιο και μετρά το ποσοστό επικάλυψης μεταξύ τους.

Αν A είναι το προβλεπόμενο bounding box και B το ground truth bounding box, τότε το IoU ορίζεται ως:

$$IoU = \frac{A \cap B}{A \cup B}$$

όπου ο αριθμητής αντιστοιχεί στην περιοχή τομής των δύο πλαισίων και ο παρονομαστής στη συνολική περιοχή που καλύπτουν μαζί.

Η τιμή του IoU παίρνει τιμές στο διάστημα:

$$0 \leq IoU \leq 1$$

Τιμές κοντά στο μηδέν σημαίνουν ότι τα δύο πλαίσια σχεδόν δεν επικαλύπτονται, ενώ τιμές κοντά στο 1 υποδηλώνουν σχεδόν τέλεια ταύτιση.

Στην πράξη χρησιμοποιείται συνήθως ένα κατώφλι αποδοχής, για παράδειγμα:

$$IoU \geq 0.5$$

ώστε μία ανίχνευση να θεωρηθεί επιτυχής. Αν η επικάλυψη είναι μικρότερη από το κατώφλι, τότε η πρόβλεψη θεωρείται λανθασμένη ακόμη και αν η κατηγορία του αντικειμένου έχει προβλεφθεί σωστά.

2.8 Non-Maximum Suppression

Κατά τη διαδικασία ανίχνευσης ένα αντικείμενο να ανιχνεύεται από πολλά διαφορετικά bounding boxes με παρόμοιες συντεταγμένες.

Για την απομάχρυνση των πλεοναζόντων πλαισίων χρησιμοποιείται ο αλγόριθμος non-maximum suppression (NMS).

Αρχικά επιλέγεται το bounding box με το μεγαλύτερο confidence score και στη συνέχεια υπολογίζεται το IoU του με όλα τα υπόλοιπα bounding boxes της ίδιας κατηγορίας.

Αν:

$$IoU > T$$

όπου T ένα προκαθορισμένο κατώφλι, τότε το αντίστοιχο πλαίσιο απορρίπτεται.

Η διαδικασία επαναλαμβάνεται μέχρι να παραμείνουν μόνο τα σημαντικότερα πλαίσια ανίχνευσης.

Με τον τρόπο αυτό αποφεύγεται η πολλαπλή ανίχνευση του ίδιου αντικειμένου.

2.9 Μετρικές Αξιολόγησης

Η αξιολόγηση ενός ανιχνευτή αντικειμένων δεν βασίζεται μόνο στο πλήθος των σωστών προβλέψεων αλλά και στην ικανότητά του να εντοπίζει όσο το δυνατόν περισσότερα αντικείμενα χωρίς να παράγει μεγάλο αριθμό λανθασμένων ανιχνεύσεων.

Για τον λόγο αυτό χρησιμοποιούνται διάφορες μετρικές αξιολόγησης, με σημαντικότερες τις precision, recall, F1-score και mean average precision (mAP).

Η μετρική precision εκφράζει το ποσοστό των ανιχνεύσεων που είναι πραγματικά σωστές και ορίζεται ως:

$$Precision = \frac{TP}{TP + FP}$$

όπου TP είναι τα True positives και FP τα false positives.

Μεγάλη τιμή precision σημαίνει ότι το μοντέλο παράγει λίγες λανθασμένες ανιχνεύσεις και συνεπώς οι προβλέψεις του είναι πιο αξιόπιστες.

Αντίστοιχα, η recall μετρά το ποσοστό των πραγματικών αντικειμένων που κατάφερε να εντοπίσει το σύστημα:

$$Recall = \frac{TP}{TP + FN}$$

όπου FN είναι τα false Negatives, δηλαδή τα αντικείμενα που υπάρχουν στην εικόνα αλλά δεν ανιχνεύθηκαν.

Μεγάλη τιμή recall σημαίνει ότι το μοντέλο χάνει λίγα αντικείμενα και επομένως έχει καλή ικανότητα εντοπισμού.

Στην πράξη οι δύο αυτές μετρικές συχνά βρίσκονται σε ανταγωνισμό. Ένα μοντέλο μπορεί να αυξήσει το recall ανιχνεύοντας περισσότερα αντικείμενα, αλλά αυτό συνήθως συνοδεύεται από αύξηση των false positives και επομένως από μείωση του precision.

Για τον λόγο αυτό χρησιμοποιείται συχνά η μετρική F1-score, η οποία συνδυάζει precision και recall σε μία ενιαία τιμή:

$$F_1 = 2 \frac{precision \cdot recall}{precision + recall}$$

Η τιμή της F1-score γίνεται μεγάλη μόνο όταν και οι δύο προηγούμενες μετρικές έχουν υψηλές τιμές.

Επίσης η μετρική average precision (AP), υπολογίζεται από την καμπύλη precision-recall που προκύπτει μεταβάλλοντας το confidence threshold του ανιχνευτή.

Η average precision αντιστοιχεί ουσιαστικά στο εμβαδόν κάτω από την καμπύλη precision-recall:

$$AP = \int_0^1 precision(r), dr$$

όπου r είναι το recall.

Όταν το πρόβλημα περιλαμβάνει πολλές διαφορετικές κατηγορίες αντικειμένων, υπολογίζεται η average precision για κάθε κατηγορία ξεχωριστά και στη συνέχεια λαμβάνεται ο μέσος όρος όλων των τιμών.

Η μετρική αυτή ονομάζεται mean average precision (mAP):

$$mAP = \frac{1}{C} \sum_{i=1}^C AP_i$$

όπου C είναι το πλήθος των κατηγοριών.

3 Dataset

3.1 COCO Dataset

Για την αξιολόγηση των αλγορίθμων ανίχνευσης αντικειμένων χρησιμοποιήθηκε το COCO , το οποίο περιλαμβάνει εικόνες πραγματικών σκηνών με αριθμό αντικειμένων, διαφορετικές κατηγορίες, μεταβολές φωτισμού, αντικείμενα διαφορετικών μεγεθών και αρκετά σύνθετο υπόβαθρο.

Στην παρούσα εργασία χρησιμοποιήθηκε το σύνολο `val2017`, το οποίο περιέχει συνολικά 5000 εικόνες αξιολόγησης. Κάθε εικόνα συνοδεύεται από annotations που περιγράφουν τόσο την κατηγορία όσο και τη θέση των αντικειμένων που εμφανίζονται σε αυτή.

Οι εικόνες βρίσκονται στον φάκελο:

`val2017/`

ενώ τα annotations παρέχονται μέσω του αρχείου:

`instances_val2017.json`

Για τη μείωση του χρόνου εκτέλεσης χρησιμοποιήθηκε υποσύνολο του `val2017`. Το ίδιο ακριβώς σύνολο εικόνων χρησιμοποιήθηκε τόσο για τον Faster R-CNN όσο και για τον SSD, ώστε η σύγκριση των δύο μοντέλων να πραγματοποιηθεί κάτω από τις ίδιες συνθήκες.

3.2 Annotations και Ground Truth Bounding Boxes

Η αξιολόγηση των μοντέλων βασίστηκε στα ground truth annotations του COCO dataset.

Κάθε annotation αντιστοιχεί σε ένα αντικείμενο και περιέχει πληροφορίες σχετικά με την κατηγορία του καθώς και τη θέση του μέσα στην εικόνα. Η θέση περιγράφεται μέσω ενός bounding box της μορφής:

$$(x, y, w, h)$$

όπου (x, y) είναι οι συντεταγμένες της πάνω αριστερής γωνίας, ενώ w και h αντιστοιχούν στο πλάτος και το ύψος του πλαισίου.

Κατά τη φόρτωση των δεδομένων τα bounding boxes μετατρέπονται στη μορφή:

$$(x_{min}, y_{min}, x_{max}, y_{max})$$

η οποία χρησιμοποιείται από τα μοντέλα object detection της pyTorch.

Για κάθε εικόνα δημιουργείται επίσης το αντίστοιχο σύνολο labels, το οποίο περιέχει την κατηγορία κάθε αντικειμένου που εμφανίζεται σε αυτή. Με τον τρόπο αυτό κάθε εικόνα συνοδεύεται από όλα τα απαραίτητα ground truth δεδομένα για την αξιολόγηση των προβλέψεων των μοντέλων.

Κατά την ανάγνωση των annotations αγνοούνται αντικείμενα που έχουν επισημανθεί ως `iscrowd`, καθώς και μη έγκυρα bounding boxes με μηδενικό πλάτος ή ύψος.

Τα ground truth bounding boxes χρησιμοποιούνται στη συνέχεια για τον υπολογισμό των μετρικών αξιολόγησης, συγκρίνοντας τις προβλέψεις των μοντέλων με τις πραγματικές θέσεις των αντικειμένων μέσω του δείκτη intersection over union (IoU).

4 Υλοποίηση

Για την υλοποίηση της εργασίας αναπτύχθηκε ένα κοινό πλαίσιο αξιολόγησης σε python με χρήση των βιβλιοθηκών pytorch και torchvision. Ο κώδικας οργανώθηκε σε επιμέρους υποσυστήματα, ώστε η φόρτωση των δεδομένων, ο υπολογισμός των μετρικών και η αξιολόγηση των μοντέλων να πραγματοποιούνται μέσω κοινών συναρτήσεων.

Η προσέγγιση αυτή επιτρέπει την επαναχρησιμοποίηση του ίδιου κώδικα από διαφορετικούς ανιχνευτές, ενώ παράλληλα εξασφαλίζει ότι όλα τα μοντέλα αξιολογούνται με τον ίδιο τρόπο και κάτω από τις ίδιες συνθήκες.

Για τη μείωση του συνολικού χρόνου εκτέλεσης χρησιμοποιήθηκε υποσύνολο 100 εικόνων από το COCO val2017. Η επιλογή αυτή έγινε επειδή η αξιολόγηση εκτελέστηκε τοπικά σε σύστημα με επεξεργαστή Intel Core i5-1335U και χωρίς χρήση εξειδικευμένης GPU. Επιπλέον, για κάθε μοντέλο η διαδικασία αξιολόγησης δεν περιλαμβάνει μόνο ένα απλό πέρασμα στο dataset, αλλά και επαναλαμβανόμενη εκτέλεση για διαφορετικά confidence thresholds, ώστε να παραχθεί η precision-recall curve, καθώς και επιπλέον πέρασμα για τον υπολογισμό του mAP. Επομένως, η χρήση ολόκληρου του COCO val2017 θα οδηγούσε σε πολύ μεγάλο συνολικό χρόνο εκτέλεσης.

4.1 Dataset Loader

Η φόρτωση των δεδομένων του COCO υλοποιήθηκε μέσω ειδικής κλάσης, η οποία αναλαμβάνει την ανάγνωση των εικόνων, τη συσχέτισή τους με τα αντίστοιχα annotations και την προετοιμασία των δεδομένων πριν αυτά δοθούν στα μοντέλα.

Για κάθε εικόνα επιστρέφεται η εικόνα εισόδου, τα αντίστοιχα ground truth αντικείμενα καθώς και το όνομα του αρχείου. Με τον τρόπο αυτό όλα τα μοντέλα χρησιμοποιούν κοινή μορφή δεδομένων ανεξάρτητα από την εσωτερική οργάνωση του dataset.

Παρέχεται επίσης η δυνατότητα επιλογής συγκεκριμένου αριθμού εικόνων από το σύνολο αξιολόγησης, διευκολύνοντας την εκτέλεση πειραμάτων διαφορετικής κλίμακας χωρίς τροποποίηση του υπόλοιπου κώδικα.

4.2 Metric Computation

Ο υπολογισμός των μετρικών υλοποιήθηκε σε ξεχωριστό υποσύστημα, ανεξάρτητο από τον εκάστοτε ανιχνευτή.

Οι προβλέψεις κάθε μοντέλου συγκρίνονται με τα αντίστοιχα ground truth annotations και από τη διαδικασία αυτή υπολογίζονται τα true positives, false positives και false negatives που χρησιμοποιούνται για την εξαγωγή των τελικών μετρικών αξιολόγησης.

Η υλοποίηση είναι κοινή για όλα τα μοντέλα, επιτρέποντας τη δίκαιη σύγκριση των αποτελεσμάτων και διατηρώντας ενιαία διαδικασία αξιολόγησης σε όλα τα πειράματα.

4.3 Model Evaluation

Για την αξιολόγηση των μοντέλων αναπτύχθηκε κοινή διαδικασία inference πάνω στο σύνολο δεδομένων.

Η διαδικασία αυτή εκτελεί διαδοχικά το μοντέλο σε όλες τις εικόνες του dataset, συλλέγει τις προβλέψεις και ενημερώνει τις συνολικές μετρικές αξιολόγησης. Παράλληλα καταγράφεται ο χρόνος εκτέλεσης κάθε inference, ώστε να είναι δυνατός ο υπολογισμός του μέσου χρόνου επεξεργασίας ανά εικόνα.

4.4 Precision-Recall Curves

Για τη δημιουργία των καμπυλών precision-recall υλοποιήθηκε ξεχωριστή διαδικασία αξιολόγησης, κατά την οποία το μοντέλο εκτελείται για διαφορετικές τιμές του confidence threshold.

Για κάθε τιμή υπολογίζονται οι αντίστοιχες τιμές precision και recall, οι οποίες αποθηκεύονται και χρησιμοποιούνται στη συνέχεια για τη δημιουργία των διαγραμμάτων.

Οι καμπύλες παράγονται με τον ίδιο τρόπο για όλα τα μοντέλα και αποθηκεύονται αυτόματα σε αρχεία εικόνες, ώστε να χρησιμοποιηθούν στην παρουσίαση και σύγκριση των πειραματικών αποτελεσμάτων.

5 Faster R-CNN

Η φόρτωση του μοντέλου πραγματοποιήθηκε μέσω της βιβλιοθήκης torchvision με χρήση των προεκπαιδευμένων βαρών που παρέχονται για το COCO dataset.

Κατά την αξιολόγηση εφαρμόστηκε confidence threshold ίσο με 0.5 ώστε να απορρίπτονται προβλέψεις με χαμηλή βεβαιότητα. Για τον υπολογισμό των true positives, false positives και false negatives χρησιμοποιήθηκε κατώφλι IoU ίσο με 0.5.

Εκτός από τις βασικές μετρικές αξιολόγησης, υπολογίστηκε επίσης το mAP μέσω της βιβλιοθήκης torchmetrics, ενώ δημιουργήθηκε και η αντίστοιχη καμπύλη precision-recall μεταβάλλοντας το confidence threshold του μοντέλου.

5.1 Αποτελέσματα

Τα αποτελέσματα της αξιολόγησης παρουσιάζονται στον παρακάτω Πίνακα.

Table 1: Αποτελέσματα Faster R-CNN

Μετρική	Τιμή
Precision	0.498
Recall	0.720
F1-score	0.589
mAP	0.446
mAP@50	0.633
mAP@75	0.506
Inference Time (sec/image)	1.996

Παρατηρείται ότι το μοντέλο πέτυχε recall περίπου 72%, γεγονός που δείχνει ότι εντόπισε το μεγαλύτερο μέρος των αντικειμένων που υπάρχουν στις εικόνες του συνόλου αξιολόγησης. Αντίθετα,

το precision είναι χαμηλότερο και βρίσκεται κοντά στο 50%, κάτι που σημαίνει ότι αρκετές από τις ανιχνεύσεις αντιστοιχούν σε false positives.

Η τιμή του f1-score είναι 0.589 και εκφράζει τη συνολική ισορροπία μεταξύ precision και recall. Η σχετικά υψηλή τιμή recall δείχνει ότι το μοντέλο προτιμά να διατηρεί περισσότερες προβλέψεις ώστε να μην χάνει πραγματικά αντικείμενα, ακόμη και αν αυτό οδηγεί σε αύξηση των λανθασμένων ανιχνεύσεων.

Η τιμή mAP@50 είναι 0.633, γεγονός που δείχνει αρκετά καλή απόδοση όταν χρησιμοποιείται κατώφλι IoU ίσο με 0.5. Όταν το κατώφλι γίνει αυστηρότερο και αυξηθεί σε 0.75, η επίδοση μειώνεται σε mAP@75 ίσο με 0.506. Η διαφορά αυτή δείχνει ότι πολλές προβλέψεις εντοπίζουν σωστά το αντικείμενο, χωρίς όμως το bounding box να συμπίπτει πλήρως με το αντίστοιχο ground truth πλαίσιο.

Τέλος, ο μέσος χρόνος εκτέλεσης ήταν περίπου δύο δευτερόλεπτα ανά εικόνα. Το αποτέλεσμα αυτό δείχνει ότι το μοντέλο προσφέρει καλή ακρίβεια εντοπισμού, αλλά με σχετικά αυξημένο υπολογιστικό κόστος σε σχέση με ταχύτερους one-stage detectors όπως ο SSD.

Precision-Recall Curve




Figure 1: Precision-recall curve του Faster RCNN

Για μικρές τιμές του confidence threshold διατηρούνται περισσότερες προβλέψεις, με αποτέλεσμα υψηλό recall αλλά χαμηλότερο precision. Καθώς το threshold αυξάνεται, απορρίπτονται οι λιγότερο βέβαιες ανιχνεύσεις και το precision βελτιώνεται, ενώ το recall μειώνεται.

Η μετάβαση μεταξύ των διαφορετικών περιοχών της καμπύλης είναι σχετικά ομαλή, γεγονός που δείχνει σταθερή συμπεριφορά του μοντέλου για διαφορετικές τιμές threshold. Το εμβαδόν κάτω από την καμπύλη συνδέεται άμεσα με την average precision και εξηγεί τις τιμές mAP που παρατηρήθηκαν κατά την αξιολόγηση.

6 SSD

Στο δεύτερο μέρος των πειραμάτων αξιολογήθηκε ο ανιχνευτής SSD χρησιμοποιώντας το προεκπαιδευμένο μοντέλο `ssd300_vgg16` της βιβλιοθήκης `torchvision`.

Όπως και στην περίπτωση του Faster RCNN, το μοντέλο χρησιμοποιήθηκε χωρίς επιπλέον εκπαίδευση και εφαρμόστηκε απευθείας στις εικόνες του COCO validation set και με χρήση των προεκπαιδευμένων βαρών που παρέχονται για το COCO dataset.

Για τη διαδικασία αξιολόγησης χρησιμοποιήθηκε confidence threshold ίσο με 0.5, ενώ μια ανίχνευση θεωρήθηκε επιτυχής όταν η επικάλυψη μεταξύ του προβλεπόμενου και του πραγματικού bounding box ήταν μεγαλύτερη από $\text{IoU} = 0.5$.

Η ίδια ακριβώς διαδικασία αξιολόγησης που χρησιμοποιήθηκε για τον FRCNN εφαρμόστηκε και στον SSD.

6.1 Αποτελέσματα

Table 2: Αποτελέσματα SSD

Μετρική	Τιμή
Precision	0.838
Recall	0.335
F1-score	0.479
mAP	0.365
mAP@50	0.543
mAP@75	0.368
Inference Time (sec/image)	0.289

Το πρώτο χαρακτηριστικό που ξεχωρίζει είναι η υψηλή τιμή precision, η οποία φτάνει περίπου στο 84%. Το αποτέλεσμα αυτό δείχνει ότι οι περισσότερες ανιχνεύσεις που διατηρεί το μοντέλο είναι σωστές και συνεπώς οι προβλέψεις του μπορούν να θεωρηθούν αξιόπιστες.

Αντίθετα, το recall είναι σημαντικά χαμηλότερο με περίπου 33%. Αυτό σημαίνει ότι το μοντέλο δεν καταφέρνει να εντοπίσει μεγάλο μέρος των αντικειμένων που υπάρχουν στις εικόνες του συνόλου αξιολόγησης δηλαδή, ο SSD παράγει σχετικά λίγα false positives αλλά ταυτόχρονα χάνει αρκετά πραγματικά αντικείμενα.

Η συμπεριφορά αυτή αποτυπώνεται και στην τιμή του F1-score, η οποία είναι 0.479. Παρότι το precision είναι υψηλό, η χαμηλή τιμή recall περιορίζει τη συνολική απόδοση του μοντέλου.

Η τιμή mAP@50 είναι 0.543, γεγονός που δείχνει καλή απόδοση όταν χρησιμοποιείται κατώφλι IoU ίσο με 0.5. Όταν το κατώφλι αυξάνεται σε 0.75, η επίδοση μειώνεται σε mAP@75 ίσο με 0.368, κάτι που δείχνει ότι αρκετές προβλέψεις εντοπίζουν σωστά το αντικείμενο χωρίς όμως το bounding box να συμπίπτει με μεγάλη ακρίβεια με το αντίστοιχο ground truth πλαίσιο.

Η συνολική τιμή mAP είναι 0.365 και είναι χαμηλότερη από εκείνη του Faster RCNN.

Precision-Recall Curve




Figure 2: Precision-recall curve του SSD

Για περίπου το μισό εύρος τιμών του confidence threshold το precision παραμένει υψηλό, γεγονός που δείχνει ότι το μοντέλο διατηρεί κυρίως προβλέψεις για τις οποίες έχει μεγάλη βεβαιότητα.

Καθώς μειώνεται το threshold, αυξάνεται ο αριθμός των ανιχνεύσεων και συνεπώς βελτιώνεται το recall. Παράλληλα όμως αυξάνεται και ο αριθμός των false positives, με αποτέλεσμα το precision να μειώνεται σταδιακά. Δηλαδή ο SSD προτιμά να απορρίψει αμφίβολες προβλέψεις παρά να πραγματοποιήσει λανθασμένες ανιχνεύσεις.

Το σημαντικότερο πλεονέκτημα του μοντέλου είναι η ταχύτητα εκτέλεσης. Ο μέσος χρόνος επεξεργασίας ήταν περίπου 0.29 δευτερόλεπτα ανά εικόνα, τιμή σχεδόν επτά φορές μικρότερη από εκείνη του FRCNN. Το αποτέλεσμα αυτό δείχνει ότι ο SSD θυσιάζει μέρος της ακρίβειας εντοπισμού προκειμένου να πετύχει σημαντικά ταχύτερη εκτέλεση.

7 Σύγκριση Faster R-CNN και SSD

Table 3: Σύγκριση Faster R-CNN και SSD

Μετρική	Faster R-CNN	SSD
Precision	0.498	0.838
Recall	0.720	0.335
F1-score	0.589	0.479
mAP	0.446	0.365
mAP@50	0.633	0.543
mAP@75	0.506	0.368
Inference Time (sec/image)	1.996	0.289

Από τα αποτελέσματα του Πίνακα 3 φαίνεται ότι ο faster r-cnn παρουσιάζει καλύτερη συνολική απόδοση ως προς τις περισσότερες μετρικές αξιολόγησης. Συγκεκριμένα, πετυχαίνει υψηλότερο recall, f1-score και mAP, γεγονός που δείχνει ότι καταφέρνει να εντοπίζει μεγαλύτερο ποσοστό των πραγματικών αντικειμένων και να διατηρεί καλύτερη συνολική ισορροπία μεταξύ σωστών και λανθασμένων ανιχνεύσεων.

Αντίθετα, ο SSD εμφανίζει υψηλότερο precision. Η τιμή αυτή δείχνει ότι όταν το μοντέλο πραγματοποιεί μία ανίχνευση, η πρόβλεψή του είναι συνήθως σωστή. Ωστόσο, το χαμηλότερο recall δείχνει ότι αρκετά αντικείμενα δεν ανιχνεύονται, με αποτέλεσμα η συνολική του απόδοση να είναι μικρότερη σε σχέση με τον faster r-cnn.

Η διαφορά αυτή φαίνεται και στις τιμές mAP. Ο faster r-cnn πετυχαίνει mAP ίσο με 0.446 έναντι 0.365 του ssd, ενώ αντίστοιχη εικόνα παρατηρείται τόσο στο mAP@50 όσο και στο mAP@75. Ιδιαίτερα για IoU ίσο με 0.75 η διαφορά γίνεται μεγαλύτερη, γεγονός που δείχνει ότι τα bounding boxes του faster r-cnn τοποθετούνται γενικά με μεγαλύτερη ακρίβεια πάνω στα αντικείμενα.

Η διαφορά αυτή συνδέεται άμεσα με τη two-stage αρχιτεκτονική του Faster R-CNN. Το πρώτο στάδιο του μοντέλου παράγει υποψήφιες περιοχές μέσω του region proposal network, ενώ το δεύτερο στάδιο επεξεργάζεται αναλυτικότερα αυτές τις περιοχές. Έτσι, το μοντέλο έχει μεγαλύτερη πιθανότητα να εντοπίσει αντικείμενα που είναι μικρά, μερικώς καλυμμένα ή βρίσκονται σε σύνθετες σκηνές.

7.1 Ταχύτητα Εκτέλεσης

Η πιο σημαντική υπεροχή του ssd εμφανίζεται στον χρόνο εκτέλεσης όπου ο μέσος χρόνος επεξεργασίας είναι περίπου 0.289 δευτερόλεπτα ανά εικόνα, ενώ για τον faster r-cnn φτάνει τα 1.996 δευτερόλεπτα.

Αυτό σημαίνει ότι ο ssd είναι περίπου επτά φορές ταχύτερος:

$$\frac{1.996}{0.289} \approx 6.9$$

Ο Faster R-CNN ακολουθεί αρχιτεκτονική δύο σταδίων. Αρχικά, το RPN παράγει ένα σύνολο υποψήφιων περιοχών που ενδέχεται να περιέχουν αντικείμενα και στη συνέχεια οι περιοχές αυτές επεξεργάζονται εκ νέου για την τελική ταξινόμηση και τη βελτίωση των bounding boxes. Η επιπλέον αυτή διαδικασία επιτρέπει στο μοντέλο να εξετάζει λεπτομερέστερα κάθε πιθανό αντικείμενο, οδηγώντας συνήθως σε μεγαλύτερη ακρίβεια και καλύτερο εντοπισμό.

Αντίθετα, ο SSD ακολουθεί αρχιτεκτονική ενός σταδίου, όπου η ταξινόμηση των αντικειμένων και η πρόβλεψη των bounding boxes πραγματοποιούνται ταυτόχρονα απευθείας πάνω στους χάρτες χαρακτηριστικών του δικτύου. Καθώς δεν απαιτείται ξεχωριστό στάδιο παραγωγής και αξιολόγησης προτεινόμενων περιοχών, το υπολογιστικό κόστος μειώνεται ο χρόνος εκτέλεσης είναι πολύ μικρότερος. Ωστόσο, η απλούστερη αυτή διαδικασία συνήθως οδηγεί σε χαμηλότερη συνολική ακρίβεια σε σχέση με τον Faster R-CNN, ιδιαίτερα σε σύνθετες σκηνές ή σε μικρά αντικείμενα.