



UNIVERSITY OF
PATRAS
ΠΑΝΕΠΙΣΤΗΜΙΟ ΠΑΤΡΩΝ

Εργαστηριακή Άσκηση 6

CNNs Ανίχνευση & Εντοπισμός Αντικειμένων

Μαριάνθη Θώδη

Μάιος 2026

Contents

1	Abstract	2
2	Θεωρία	2
2.1	Ανίχνευση και Εντοπισμός Αντικειμένων	2
2.2	Συνελικτικά Νευρωνικά Δίκτυα	2
2.3	Από το R-CNN στο Faster R-CNN	3
2.4	Fast R-CNN και ROI Pooling	3
2.5	Faster R-CNN	4
2.6	SSD (Single Shot Detector)	5
2.7	Intersection over Union	6
2.8	Non-Maximum Suppression	6
2.9	Μετρικές Αξιολόγησης	7

1 Abstract

Η παρούσα εργασία ασχολείται με τη μελέτη και την εφαρμογή τεχνικών ανίχνευσης και εντοπισμού αντικειμένων με χρήση συνελικτικών νευρωνικών δικτύων. Αρχικά παρουσιάζονται οι βασικές αρχές λειτουργίας των CNNs, τα οποία αποτελούν τη βάση των περισσότερων σύγχρονων συστημάτων υπολογιστικής όρασης.

Στη συνέχεια μελετώνται οι region-based μέθοδοι ανίχνευσης αντικειμένων και συγκεκριμένα οι R-CNN, Fast R-CNN και Faster R-CNN, με έμφαση στον τρόπο δημιουργίας των προτεινόμενων περιοχών ενδιαφέροντος, στη διαδικασία ταξινόμησης των αντικειμένων και στον εντοπισμό τους μέσω bounding boxes.

Έπειτα παρουσιάζεται η μέθοδος SSD, η οποία πραγματοποιεί ανίχνευση και εντοπισμό αντικειμένων σε ένα μόνο πέρασμα του δικτύου, επιτυγχάνοντας εγαλύτερη ταχύτητα εκτέλεσης.

Τα πειράματα πραγματοποιούνται σε σύνολα δεδομένων εικόνων που περιέχουν αντικείμενα πολλαπλών κατηγοριών και αξιολογούνται τόσο ως προς την ικανότητα αναγνώρισης των αντικειμένων όσο και ως προς την ακρίβεια εντοπισμού τους. Τέλος, πραγματοποιείται σύγκριση μεταξύ των διαφορετικών αρχιτεκτονικών ως προς την ακρίβεια, την ταχύτητα και τη συνολική τους απόδοση. Ο πλήρης κώδικας και τα αρχεία της άσκησης διατίθενται σε repository στο GitHub, στον ακόλουθο σύνδεσμο: [GitHub Repository](#).

2 Θεωρία

2.1 Ανίχνευση και Εντοπισμός Αντικειμένων

Σε αντίθεση με την απλή ταξινόμηση εικόνων, όπου το ζητούμενο είναι να αναγνωριστεί το περιεχόμενο μιας εικόνας, στην ανίχνευση αντικειμένων απαιτείται επιπλέον να προσδιοριστεί και η θέση κάθε αντικειμένου μέσα στην εικόνα.

Ένα σύστημα object detection καλείται επομένως να επιλύσει ταυτόχρονα δύο διαφορετικά προβλήματα. Το πρώτο είναι το classification, δηλαδή η αναγνώριση της κατηγορίας στην οποία ανήκει ένα αντικείμενο, ενώ το δεύτερο είναι το localization, δηλαδή ο προσδιορισμός της θέσης του αντικειμένου μέσα στην εικόνα.

Η θέση αυτή περιγράφεται συνήθως μέσω ενός bounding box, το οποίο μπορεί να αναπαρασταθεί από το διάνυσμα:

$$b = (x, y, w, h)$$

όπου (x, y) είναι οι συντεταγμένες της πάνω αριστερής γωνίας του πλαισίου, ενώ τα w και h αντιστοιχούν στο πλάτος και στο ύψος του αντίστοιχα.

Στα σύγχρονα συστήματα ανίχνευσης η εξαγωγή χαρακτηριστικών πραγματοποιείται με τη χρήση συνελικτικών νευρωνικών δικτύων. Τα δίκτυα αυτά μπορούν να μάθουν αυτόματα χαρακτηριστικά από τις εικόνες.

2.2 Συνελικτικά Νευρωνικά Δίκτυα

Τα συνελικτικά νευρωνικά δίκτυα (CNNs) αποτελούν αρχιτεκτονικές βαθιάς μάθησης που έχουν σχεδιαστεί ειδικά για την επεξεργασία εικόνων. Η βασική τους ιδέα είναι ότι μπορούν να εκμεταλλευτούν τη χωρική δομή των εικόνων και να αναγνωρίσουν χαρακτηριστικά ανεξάρτητα από τη θέση τους.

Η σημαντικότερη πράξη ενός CNN είναι η συνέλιξη. Έστω μία εικόνα εισόδου $I(x, y)$ και ένας πυρήνας συνέλιξης $K(i, j)$. Η έξοδος της συνέλιξης δίνεται από τη σχέση:

$$S(x, y) = \sum_i \sum_j I(x + i, y + j) K(i, j)$$

Ο πυρήνας μετακινείται πάνω στην εικόνα και σε κάθε θέση υπολογίζει ένα σταθμισμένο άθροισμα των γειτονικών pixels. Το αποτέλεσμα είναι ένας νέος χάρτης χαρακτηριστικών (feature map), ο οποίος αναδεικνύει συγκεκριμένα μοτίβα της εικόνας, όπως ακμές, γωνίες ή περιοχές με έντονες μεταβολές φωτεινότητας.

Μετά από κάθε επίπεδο συνέλιξης εφαρμόζεται συνήθως μία μη γραμμική συνάρτηση ενεργοποίησης. Η πιο συνηθισμένη επιλογή είναι η ReLU:

$$f(x) = \max(0, x)$$

η οποία επιτρέπει στο δίκτυο να μαθαίνει μη γραμμικές σχέσεις.

Καθώς αυξάνεται το βάθος του δικτύου, τα πρώτα επίπεδα μαθαίνουν απλά χαρακτηριστικά, όπως γραμμές και ακμές, ενώ τα βαθύτερα επίπεδα συνδυάζουν τις πληροφορίες αυτές και αναγνωρίζουν πιο σύνθετα σχήματα. Το τμήμα του CNN που είναι υπεύθυνο για την εξαγωγή χαρακτηριστικών ονομάζεται backbone network.

2.3 Από το R-CNN στο Faster R-CNN

Η οικογένεια των ανιχνευτών R-CNN αποτέλεσε μία από τις πρώτες προσπάθειες συνδυασμού CNNs και object detection. Η βασική ιδέα ήταν να χρησιμοποιηθεί ένα CNN για την εξαγωγή χαρακτηριστικών από περιοχές της εικόνας που πιθανόν περιέχουν αντικείμενα.

Η εξέλιξη αυτής της οικογένειας μπορεί να συνοψιστεί ως:

$$R-CNN \rightarrow Fast\ R-CNN \rightarrow Faster\ R-CNN$$

Στο αρχικό R-CNN χρησιμοποιούνταν ένας αλγόριθμος selective search, ο οποίος παρήγαγε περίπου 2000 υποψήφιες ROIs για κάθε εικόνα. Κάθε μία από αυτές τις περιοχές γίνεται multi-scale σταθερού μεγέθους και στη συνέχεια δινόταν ξεχωριστά ως είσοδος σε ένα CNN.

Η προσέγγιση αυτή πέτυχε ακρίβεια εντοπισμού, ωστόσο παρουσίαζε πολύ μεγάλο υπολογιστικό κόστος, καθώς το CNN έπρεπε να εκτελεστεί χιλιάδες φορές για κάθε εικόνα. Το πρόβλημα αυτό οδήγησε στην ανάπτυξη των Fast R-CNN και Faster R-CNN, τα οποία βελτίωσαν σημαντικά την ταχύτητα εκτέλεσης χωρίς να θυσιάσουν την ακρίβεια ανίχνευσης.

2.4 Fast R-CNN και ROI Pooling

Το Fast R-CNN αναπτύχθηκε με στόχο να αντιμετωπίσει το βασικό μειονέκτημα του R-CNN, δηλαδή το πολύ μεγάλο υπολογιστικό κόστος. Στο R-CNN το συνελικτικό δίκτυο εκτελείται ξεχωριστά για κάθε υποψήφια περιοχή ενδιαφέροντος, γεγονός που καθιστά τη διαδικασία αργή.

Η βασική ιδέα του Fast R-CNN είναι ότι το CNN εφαρμόζεται μία μόνο φορά σε ολόκληρη την εικόνα. Από την επεξεργασία αυτή προκύπτει ένας χάρτης χαρακτηριστικών:

$$F \in \mathbb{R}^{H \times W \times C}$$

ο οποίος περιέχει τη χρήσιμη πληροφορία της εικόνας σε συμπιεσμένη μορφή.

Οι περιοχές ενδιαφέροντος δεν επεξεργάζονται πλέον απευθείας πάνω στην αρχική εικόνα αλλά προβάλλονται πάνω στον χάρτη χαρακτηριστικών. Επειδή κάθε περιοχή μπορεί να έχει διαφορετικό μέγεθος, απαιτείται ένας μηχανισμός που να μετατρέπει όλες τις περιοχές σε αναπαράστασεις σταθερών διαστάσεων. Για τον σκοπό αυτό χρησιμοποιείται το ROI pooling.

Το ROI pooling χωρίζει κάθε περιοχή σε ένα πλέγμα σταθερού μεγέθους, συνήθως:

$$7 \times 7$$

και εφαρμόζει max pooling σε κάθε υποπεριοχή. Αν συμβολίσουμε με R_{ij} την αντίστοιχη υποπεριοχή, τότε η έξοδος υπολογίζεται ως:

$$y_{ijc} = \max_{(u,v) \in R_{ij}} F(u, v, c)$$

Με τον τρόπο αυτό όλες οι περιοχές μετατρέπονται σε διανύσματα ίδιων διαστάσεων και μπορούν να χρησιμοποιηθούν από τα πλήρως συνδεδεμένα επίπεδα του δικτύου.

Η σημαντικότερη βελτίωση του Fast R-CNN είναι ότι το μεγαλύτερο μέρος των υπολογισμών πραγματοποιείται μόνο μία φορά ανά εικόνα, γεγονός που οδηγεί σε αύξηση της ταχύτητας σε σχέση με το αρχικό R-CNN.

2.5 Faster R-CNN

Παρότι το Fast R-CNN βελτίωσε σημαντικά την ταχύτητα εκτέλεσης, εξακολουθούσε να εξαρτάται από τον αλγόριθμο selective search για την παραγωγή των περιοχών ενδιαφέροντος. Η διαδικασία αυτή παρέμενε σχετικά αργή και αποτελούσε το βασικό σημείο συμφόρησης του συστήματος.

Ο Faster R-CNN λύνει το πρόβλημα αυτό εισάγοντας το region proposal network (RPN), το οποίο παράγει αυτόματα τις υποψήφιες περιοχές απευθείας πάνω στους χάρτες χαρακτηριστικών του backbone δικτύου.

Για κάθε θέση του feature map δημιουργούνται προκαθορισμένα πλαίσια διαφορετικών διαστάσεων και αναλογιών, τα οποία είναι γνωστά ως anchor boxes. Για κάθε anchor το δίκτυο προβλέπει δύο πράγματα:

- την πιθανότητα να περιέχει κάποιο αντικείμενο,
- διορθώσεις στις συντεταγμένες του πλαισίου.

Οι διορθώσεις αυτές υπολογίζονται μέσω των μεταβλητών:

$$t_x = \frac{x_g - x}{w}$$

$$t_y = \frac{y_g - y}{h}$$

$$t_w = \log \left(\frac{w_g}{w} \right)$$

$$t_h = \log \left(\frac{h_g}{h} \right)$$

όπου (x, y, w, h) αντιστοιχούν στο αρχικό anchor box και (x_g, y_g, w_g, h_g) στο αντίστοιχο ground truth πλαίσιο.

Οι περιοχές που παράγονται από το RPN προωθούνται στο δεύτερο στάδιο του δικτύου, όπου πραγματοποιείται η τελική ταξινόμηση των αντικειμένων και η περαιτέρω βελτίωση των bounding boxes.

Η συνολική συνάρτηση κόστους του Faster R-CNN περιλαμβάνει έναν όρο ταξινόμησης και έναν όρο εντοπισμού:

$$L = L_{cls} + \lambda L_{loc}$$

όπου L_{cls} είναι το classification loss και L_{loc} το localization loss.

Ο όρος L_{cls} αντιστοιχεί στο σφάλμα ταξινόμησης και υπολογίζεται μέσω της συνάρτησης cross entropy. Αν p_{true} είναι η πιθανότητα που αποδίδει το δίκτυο στη σωστή κλάση, τότε:

$$L_{cls} = -\log(p_{true})$$

Η συνάρτηση αυτή παίρνει μικρή τιμή όταν το δίκτυο δίνει μεγάλη πιθανότητα στη σωστή κλάση και μεγάλη τιμή όταν η πιθανότητα αυτή είναι μικρή.

Ο όρος L_{loc} αφορά την ακρίβεια εντοπισμού των bounding boxes και για τον σκοπό αυτό χρησιμοποιείται η smooth L1 loss:

$$SL_1(x) = \begin{cases} x^2, & |x| < 1 \\ |x| - \frac{1}{2}, & |x| \geq 1 \end{cases}$$

Η smooth L1 loss συμπεριφέρεται σαν τετραγωνικό σφάλμα για μικρές αποκλίσεις και σαν απόλυτο σφάλμα για μεγάλες αποκλίσεις. Έτσι επιτρέπεται διόρθωση μικρών λαθών, ενώ ταυτόχρονα είναι λιγότερο ευαίσθητη σε πολύ μεγάλα σφάλματα ή outliers.

Η αρχιτεκτονική αυτή θεωρείται detector δύο σταδίων (two-stage detector), καθώς η διαδικασία παραγωγής περιοχών και η τελική ταξινόμηση πραγματοποιούνται σε δύο διαδοχικά βήματα. Το κύριο πλεονέκτημά της είναι η ακρίβεια εντοπισμού, ιδιαίτερα σε μικρά αντικείμενα ή σε σύνθετες σκηνές.

2.6 SSD (Single Shot Detector)

Σε αντίθεση με τον Faster R-CNN, ο SSD ανήκει στην κατηγορία των one-stage detectors. Η βασική του φιλοσοφία είναι ότι η ανίχνευση και η ταξινόμηση πραγματοποιούνται ταυτόχρονα σε ένα μόνο πέρασμα του δικτύου, χωρίς να προηγείται ξεχωριστό στάδιο παραγωγής περιοχών ενδιαφέροντος.

Για να μπορεί να εντοπίζει αντικείμενα διαφορετικών μεγεθών, ο SSD αξιοποιεί πολλαπλούς χάρτες χαρακτηριστικών διαφορετικής ανάλυσης, όπως:

$$38 \times 38, 19 \times 19, 10 \times 10, 5 \times 5, 3 \times 3, 1 \times 1$$

Οι χάρτες υψηλής ανάλυσης χρησιμοποιούνται κυρίως για μικρά αντικείμενα, ενώ οι χάρτες χαμηλότερης ανάλυσης είναι καταλληλότεροι για μεγαλύτερα αντικείμενα.

Σε κάθε θέση των feature maps ορίζονται προκαθορισμένα πλαίσια, γνωστά ως default boxes. Για κάθε πλαίσιο το δίκτυο προβλέπει τόσο τις πιθανότητες των κλάσεων όσο και τις διορθώσεις των συντεταγμένων του bounding box.

Η συνολική συνάρτηση κόστους γράφεται ως:

$$L = \frac{1}{N} (L_{conf} + \alpha L_{loc})$$

όπου L_{conf} αντιστοιχεί στο classification loss, L_{loc} στο localization loss και N στο πλήθος των θετικών αντιστοιχίσεων.

Το σημαντικότερο πλεονέκτημα του SSD είναι η υψηλή ταχύτητα εκτέλεσης, γεγονός που τον καθιστά κατάλληλο για real time applications.

2.7 Intersection over Union

Για να μπορέσουμε να αξιολογήσουμε πόσο σωστά εντοπίζει ένα μοντέλο τη θέση ενός αντικειμένου, δεν αρκεί να γνωρίζουμε μόνο αν αναγνώρισε τη σωστή κατηγορία. Είναι εξίσου σημαντικό να εξετάσουμε και το πόσο καλά συμπίπτει το προβλεπόμενο bounding box με το πραγματικό bounding box του αντικειμένου.

Η πιο διαδεδομένη μετρική για τον σκοπό αυτό είναι η Intersection over Union (IoU). Η μετρική αυτή συγκρίνει το προβλεπόμενο πλαίσιο με το αντίστοιχο ground truth πλαίσιο και μετρά το ποσοστό επικάλυψης μεταξύ τους.

Αν A είναι το προβλεπόμενο bounding box και B το ground truth bounding box, τότε το IoU ορίζεται ως:

$$IoU = \frac{A \cap B}{A \cup B}$$

όπου ο αριθμητής αντιστοιχεί στην περιοχή τομής των δύο πλαισίων και ο παρονομαστής στη συνολική περιοχή που καλύπτουν μαζί.

Η τιμή του IoU παίρνει τιμές στο διάστημα:

$$0 \leq IoU \leq 1$$

Τιμές κοντά στο μηδέν σημαίνουν ότι τα δύο πλαίσια σχεδόν δεν επικαλύπτονται, ενώ τιμές κοντά στο 1 υποδηλώνουν σχεδόν τέλεια ταύτιση.

Στην πράξη χρησιμοποιείται συνήθως ένα κατώφλι αποδοχής, για παράδειγμα:

$$IoU \geq 0.5$$

ώστε μία ανίχνευση να θεωρηθεί επιτυχής. Αν η επικάλυψη είναι μικρότερη από το κατώφλι, τότε η πρόβλεψη θεωρείται λανθασμένη ακόμη και αν η κατηγορία του αντικειμένου έχει προβλεφθεί σωστά.

2.8 Non-Maximum Suppression

Κατά τη διαδικασία ανίχνευσης ένα αντικείμενο να ανιχνεύεται από πολλά διαφορετικά bounding boxes με παρόμοιες συντεταγμένες.

Για την απομάκρυνση των πλεοναζόντων πλαισίων χρησιμοποιείται ο αλγόριθμος non-maximum suppression (NMS).

Αρχικά επιλέγεται το bounding box με το μεγαλύτερο confidence score και στη συνέχεια υπολογίζεται το IoU του με όλα τα υπόλοιπα bounding boxes της ίδιας κατηγορίας.

Αν:

$$IoU > T$$

όπου T ένα προκαθορισμένο κατώφλι, τότε το αντίστοιχο πλαίσιο απορρίπτεται.

Η διαδικασία επαναλαμβάνεται μέχρι να παραμείνουν μόνο τα σημαντικότερα πλαίσια ανίχνευσης.

Με τον τρόπο αυτό αποφεύγεται η πολλαπλή ανίχνευση του ίδιου αντικειμένου.

2.9 Μετρικές Αξιολόγησης

Η αξιολόγηση ενός ανιχνευτή αντικειμένων δεν βασίζεται μόνο στο πλήθος των σωστών προβλέψεων αλλά και στην ικανότητά του να εντοπίζει όσο το δυνατόν περισσότερα αντικείμενα χωρίς να παράγει μεγάλο αριθμό λανθασμένων ανιχνεύσεων.

Για τον λόγο αυτό χρησιμοποιούνται διάφορες μετρικές αξιολόγησης, με σημαντικότερες τις precision, recall, F1-score και mean average precision (mAP).

Η μετρική precision εκφράζει το ποσοστό των ανιχνεύσεων που είναι πραγματικά σωστές και ορίζεται ως:

$$Precision = \frac{TP}{TP + FP}$$

όπου TP είναι τα True positives και FP τα false positives.

Μεγάλη τιμή precision σημαίνει ότι το μοντέλο παράγει λίγες λανθασμένες ανιχνεύσεις και συνεπώς οι προβλέψεις του είναι πιο αξιόπιστες.

Αντίστοιχα, η recall μετρά το ποσοστό των πραγματικών αντικειμένων που κατάφερε να εντοπίσει το σύστημα:

$$Recall = \frac{TP}{TP + FN}$$

όπου FN είναι τα false Negatives, δηλαδή τα αντικείμενα που υπάρχουν στην εικόνα αλλά δεν ανιχνεύθηκαν.

Μεγάλη τιμή recall σημαίνει ότι το μοντέλο χάνει λίγα αντικείμενα και επομένως έχει καλή ικανότητα εντοπισμού.

Στην πράξη οι δύο αυτές μετρικές συχνά βρίσκονται σε ανταγωνισμό. Ένα μοντέλο μπορεί να αυξήσει το recall ανιχνεύοντας περισσότερα αντικείμενα, αλλά αυτό συνήθως συνοδεύεται από αύξηση των false positives και επομένως από μείωση του precision.

Για τον λόγο αυτό χρησιμοποιείται συχνά η μετρική F1-score, η οποία συνδυάζει precision και recall σε μία ενιαία τιμή:

$$F_1 = 2 \frac{precision \cdot recall}{precision + recall}$$

Η τιμή της F1-score γίνεται μεγάλη μόνο όταν και οι δύο προηγούμενες μετρικές έχουν υψηλές τιμές.

Επίσης η μετρική average precision (AP), υπολογίζεται από την καμπύλη precision-recall που προκύπτει μεταβάλλοντας το confidence threshold του ανιχνευτή.

Η average precision αντιστοιχεί ουσιαστικά στο εμβαδόν κάτω από την καμπύλη precision-recall:

$$AP = \int_0^1 precision(r), dr$$

όπου r είναι το recall.

Όταν το πρόβλημα περιλαμβάνει πολλές διαφορετικές κατηγορίες αντικειμένων, υπολογίζεται η average precision για κάθε κατηγορία ξεχωριστά και στη συνέχεια λαμβάνεται ο μέσος όρος όλων των τιμών.

Η μετρική αυτή ονομάζεται mean average precision (mAP):

$$mAP = \frac{1}{C} \sum_{i=1}^C AP_i$$

όπου C είναι το πλήθος των κατηγοριών.