



UNIVERSITY OF
PATRAS
ΠΑΝΕΠΙΣΤΗΜΙΟ ΠΑΤΡΩΝ

Εργαστηριακή Άσκηση 3 Scale Invariant Fetuare Transform (SIFT)

Μαριάνθη Θώδη

Δεκέμβριος 2025

Contents

1	Abstract	3
2	Αλγόριθμος SIFT	3
2.1	Τα Τέσσερα Στάδια του Αλγορίθμου SIFT	3
2.2	Στάδιο 1 : Χώρος Κλίμακας &DoG	3
2.3	Στάδιο 2 : Ανίχνευση Τοπικών Ακρότατων	4
2.4	Στάδιο 3 : Φιλτράρισμα και Εντόπιση Keypoints	5
2.5	Στάδιο 4 : Διόρθωση Κατεύθυνσης &Descriptor	6
3	Ανάλυση Κώδικα	7
3.1	Ανάλυση του SIFT_feature.m	7
3.1.1	Δημιουργία Scale Space &DoG	7
3.1.2	Ανίχνευση Τοπικών Ακρότατων	9
3.1.3	Φιλτράρισμα και Εντόπιση Keypoints	10
3.1.4	Διόρθωση Κατεύθυνσης &Descriptor	12
3.2	Σχολιασμός SIFT_feature.m	14
3.2.1	Plot 1 – DoG Pyramid	14
3.2.2	Plot 2 – Αρχική εικόνα &candidate keypoints	15
3.2.3	Plot 3 – Τελικά keypoints μετά το φιλτράρισμα	15
3.3	Αριθμός Επιπέδων Ανά Οκτάβα	16
3.4	Εφαρμογή και Αποτελέσματα της Ανίχνευσης SIFT	17
3.4.1	Περιγραφή εικόνων	17
3.4.2	Αποτελέσματα SIFT	17
3.4.3	Σχολιασμός	17
4	Υποκλιμακική Ακρίβεια	18
4.1	Ανάπτυγμα Taylor της DoG στον Χώρο Κλίμακας	18
4.2	Παραβολική Παρεμβολή	19
4.3	Σύγκριση Μεθόδων	19
5	Αντιστοίχιση &RANSAC	19
5.1	Ανάλυση του SIFT (sift.m)	20
5.2	Descriptor Matching (matching.m)	20
5.2.1	Μέθοδοι υπολογισμού ομοιότητας	20
5.3	RANSAC	21
5.3.1	Χρήση του στο SIFT Matching	21
5.4	Πειράματα Αποτελεσμάτων	22
5.4.1	Invariance στην Περιστροφή (Rotation 15° &45°)	22
5.4.2	Invariance στην Κλίμακα (Scale 3.5)	22
5.4.3	Invariance στον Φωτισμό (Brightness +50)	23
5.4.4	Αντοχή στον Θόρυβο (Gaussian Noise 0.01)	23
6	Σύγκριση &Πολυπλοκότητα	24
6.1	SIFT vs GLOH vs SURF	24
6.1.1	SIFT (Scale-Invariant Feature Transform)	24
6.1.2	GLOH (Gradient Location and Orientation Histogram)	25

6.1.3	SURF (Speeded-Up Robust Features)	26
6.2	Υπολογιστικό κόστος	27
6.2.1	SIFT	27
6.2.2	GLOH	28
6.2.3	SURF	28
6.3	Σύγκριση Αλγορίθμων	28

1 Abstract

Η παρούσα εργαστηριακή άσκηση εστιάζει στη μελέτη και υλοποίηση του αλγορίθμου SIFT, για την εξαγωγή χαρακτηριστικών. Σκοπός της άσκησης είναι η κατανόηση της διαδικασίας ανίχνευσης (key-points) που παραμένουν αναλλοίωτα σε μετασχηματισμούς κλίμακας και περιστροφής. Η διαδικασία περιλαμβάνει τη δημιουργία χώρου κλίμακας (Scale Space) μέσω της διαφοράς γκαουσιανών (DoG), τον εντοπισμό τοπικών ακροτάτων και τη δημιουργία μοναδικών descriptors. Τέλος, εξετάζεται η αντιστοίχιση των χαρακτηριστικών μεταξύ διαφορετικών εικόνων και η βελτιστοποίηση των αποτελεσμάτων μέσω του αλγορίθμου RANSAC για την απόρριψη λανθασμένων αντιστοιχιών (outliers). Ο πλήρης κώδικας και τα αρχεία της άσκησης διατίθενται σε repo στο GitHub στον αντίστοιχο σύνδεσμο GitHub Repository.

2 Αλγόριθμος SIFT

Ο αλγόριθμος αυτός ανιχνεύει και περιγράφει interesting points σε εικόνες και εντοπίζει σταθερά χαρακτηριστικά σημεία (keypoints) τα οποία:

1. Scale invariant
2. Rotation invariant
3. Είναι ανθεκτικά σε μεταβολές φωτισμού και μικρές γεωμετρικές παραμορφώσεις

Ο αλγόριθμος SIFT αποτελείται από 2 μέρη:

- Ανιχνευτή (detector) σημείων ενδιαφέροντος
- Περιγραφέα (descriptor) των σημείων αυτών

Η βασική ιδέα του αλγορίθμου είναι η ανίχνευση ακροτάτων στον χώρο κλίμακας της διαφοράς γκαουσιανών (DoG), η οποία αποτελεί προσέγγιση της κανονικοποιημένης λαπλασιανής (LoG).

2.1 Τα Τέσσερα Στάδια του Αλγορίθμου SIFT

Ο αλγόριθμος SIFT χωρίζεται σε τέσσερα βασικά στάδια, τα οποία παρουσιάζονται στη συνέχεια.

2.2 Στάδιο 1 : Χώρος Κλίμακας & DoG

Scale Space

Ο χώρος κλίμακας μιας εικόνας ορίζεται ως:

$$L(x, y, \sigma) = G(x, y, \sigma) * I(x, y)$$

όπου:

- $I(x, y)$: η αρχική εικόνα
- $G(x, y, \sigma)$: ο γκαουσιανός πυρήνας
- σ : η παράμετρος κλίμακας

Για την επίτευξη scale invariant, ο SIFT οργανώνει τον χώρο κλίμακας σε οκτάβες, όπου κάθε οκτάβα αντιστοιχεί σε διπλασιασμό της κλίμακας(blur scale) και υποδειγματοληψία της εικόνας κατά παράγοντα 2.

Difference of Gaussians (DoG)

Η διαφορά γκαουσιανών ορίζεται ως:

$$D(x, y, \sigma) = L(x, y, k\sigma) - L(x, y, \sigma)$$

Η DoG αποτελεί μια προσέγγιση της κανονικοποιημένης λαπλασιανής:

$$\text{DoG} \approx (k - 1)\sigma^2 \nabla^2 L$$

και επιτρέπει την ανίχνευση σημείων ενδιαφέροντος με μικρό υπολογιστικό κόστος διότι:

1. η DoG υπολογίζεται ως αφαίρεση δύο ήδη φιλτραρισμένων εικόνων με γκαουσιανά φίλτρα.
2. Τα gaussian φίλτρα είναι separable, γεγονός που μειώνει την πολυπλοκότητα των συνελίξεων.

Αντίθετα, η χρήση της LoG θα απαιτούσε:

1. Υπολογισμό δευτέρων παραγώγων για κάθε επίπεδο κλίμακας
2. Συνέλιξη της εικόνας με μη διαχωρίσιμα φίλτρα LoG
3. Σημαντικά αυξημένο υπολογιστικό κόστος και μνήμης

Με βάση τα παραπάνω καταλαβαίνουμε ότι τα ακρότατα της DoG συμπίπτουν με τα ακρότατα της NLoG .

2.3 Στάδιο 2 : Ανίχνευση Τοπικών Ακρότατων

Στο δεύτερο στάδιο του αλγορίθμου πραγματοποιείται η ανίχνευση τοπικών ακρότατων της συνάρτησης DoG στον χώρο κλίμακας. Το στάδιο αυτό ονομάζεται ανίχνευση σημείων ενδιαφέροντος και βασίζεται στη θεωρία της NLoG.

Σύμφωνα με τη θεωρία scale-space, τα σταθερά χαρακτηριστικά σημεία (blobs) αντιστοιχούν σε ακρότατα της ποσότητας:

$$\sigma^2 \nabla^2 L(x, y, \sigma)$$

η οποία προσεγγίζεται μέσω της διαφοράς γκαουσιανών όπως αναφέρθηκε παραπάνω. Για τον εντοπισμό αυτών των ακρότατων, κάθε εικονοστοιχείο της εικόνας DoG συγκρίνεται με τα 26 γειτονικά εικονοστοιχεία του στον τρισδιάστατο χώρο (x, y, σ) :

- 8 γείτονες στην ίδια κλίμακα
- 9 στην προηγούμενη κλίμακα
- 9 στην επόμενη κλίμακα

Ένα σημείο χαρακτηρίζεται ως υποψήφιο σημείο-κλειδί (keypoint) αν η τιμή του είναι είτε αυστηρά μεγαλύτερη είτε αυστηρά μικρότερη από όλες τις αντίστοιχες τιμές των γειτονικών του σημείων. Με αυτόν τον τρόπο εξασφαλίζεται ότι το σημείο αποτελεί τοπικό ακρότατο τόσο ως προς τη χωρική θέση (x, y) όσο και ως προς την κλίμακα σ .

2.4 Στάδιο 3 : Φιλτράρισμα και Εντόπιση Keypoints

Τα υποψήφια keypoints φιλτράρονται ώστε να παραμείνουν μόνο τα αξιόπιστα. Περιλαμβάνει τρία κύρια βήματα:

Υπο-πίξελ & Υπο-κλίμακα Εντοπισμός

Κάθε υποψήφιο keypoint μπορεί να βρίσκεται μεταξύ των pixels ή σε ενδιάμεση κλίμακα. Για μεγαλύτερη ακρίβεια, χρησιμοποιείται η τετραγωνική προσέγγιση (Taylor expansion) της DoG γύρω από το keypoint:

$$D(\mathbf{x}) \approx D + \nabla D^T \mathbf{x} + \frac{1}{2} \mathbf{x}^T H \mathbf{x}$$

όπου:

- $D(\mathbf{x})$: τιμή της συνάρτησης DoG στο σημείο $\mathbf{x}$
- $\mathbf{x} = (x, y, \sigma)$: θέση του keypoint (σε x, y και κλίμακα)
- ∇D : διανυσματική παράγωγος της DoG (gradient)
- H : πίνακας Hessian, δηλαδή πίνακας δεύτερων παραγώγων της DoG, που περιγράφει την καμπυλότητα γύρω από το σημείο

Ουσιαστικά, υπολογίζεται η βέλτιστη μετατόπιση ώστε το keypoint να βρεθεί στο ακριβές τοπικό ακρότατο (sub-pixel και sub-scale):

$$\hat{\mathbf{x}} = -H^{-1} \nabla D$$

Αν η μετατόπιση είναι πολύ μεγάλη, το σημείο θεωρείται μη σταθερό και απορρίπτεται.

Low Contrast Rejection

Η τιμή της DoG στο ακριβές σημείο $|D(\hat{x})|$ δείχνει πόσο έντονο είναι το χαρακτηριστικό (keypoint). Αν η τιμή είναι μικρότερη από ένα προκαθορισμένο κατώφλι αντίθεσης, το keypoint απορρίπτεται. Αυτό αφαιρεί:

- Επίπεδες περιοχές (όπου δεν υπάρχει έντονη πληροφορία)
- Ακρότατα που προκαλούνται από θόρυβο

Διατηρούνται μόνο τα σταθερά και έντονα keypoints.

Edge Response Elimination

Ορισμένα keypoints βρίσκονται πάνω σε ακμές αντί για γωνίες ή μοναδικά χαρακτηριστικά. Αυτά τα σημεία είναι ασταθή, γιατί η DoG αλλάζει έντονα μόνο σε μία κατεύθυνση. Για να βρεθούν τα σταθερά σημεία, ο SIFT χρησιμοποιεί τον Hessian πίνακα H στο επίπεδο της εικόνας για να ελέγξει το λόγο των ιδιοτιμών:

$$\frac{(\text{Tr}(H))^2}{\det H} < \frac{(r+1)^2}{r}$$

όπου:

- $\text{Tr}(H)$: άθροισμα των ιδιοτιμών του Hessian (Trace)
- $\det H$: γινόμενο των ιδιοτιμών του Hessian (Determinant)
- r : επιτρεπόμενη αναλογία μεγάλου προς μικρού άξονα στις ακμές

Έτσι, τα keypoints που δεν πληρούν την ανισότητα απορρίπτονται, καθώς αντιστοιχούν σε ασταθείς ή θορυβώδεις ακμές.

2.5 Στάδιο 4 : Διόρθωση Κατεύθυνσης & Descriptor

Orientation Assignment

Για κάθε keypoint υπολογίζεται το μέτρο και η κατεύθυνση της κλίσης (gradient) γύρω από το σημείο:

$$m(x, y) = \sqrt{L_x^2 + L_y^2}, \quad \theta(x, y) = \tan^{-1} \left(\frac{L_y}{L_x} \right)$$

Στην συνέχεια δημιουργείται ιστόγραμμα με 36 bins για τις κατευθύνσεις γύρω από το keypoint. Κάθε pixel της γειτονιάς συμβάλλει στο ιστόγραμμα ανάλογα με:

- Το μέτρο της κλίσης του (gradient magnitude)
- Ένα gaussian βάρος, που μειώνεται όσο πιο μακριά είναι από το κέντρο, δηλαδή από το keypoint

Το παραπάνω γίνεται ώστε να βρεθεί η κυρίαρχη κατεύθυνση που είναι αυτή με το μεγαλύτερο συνολικό σταθμισμένο μέτρο gradient. Ο περιγραφέας περιστρέφεται ώστε να ευθυγραμμιστεί με την κυρίαρχη κατεύθυνση, εξασφαλίζοντας περιστροφική αναλλοιωσιμότητα. Αν υπάρχουν ισχυρά τοπικά μέγιστα σε άλλες κατευθύνσεις, το SIFT δημιουργεί πολλαπλά keypoints στην ίδια θέση με διαφορετικούς προσανατολισμούς, για πλήρη κάλυψη.

SIFT Descriptor

Μετά τη διόρθωση κατεύθυνσης, κατασκευάζεται ο περιγραφέας του keypoint, ο οποίος κωδικοποιεί τη τοπική δομή της εικόνας γύρω από το σημείο.

Η περιοχή γύρω από το keypoint ορίζεται ως τετράγωνο παράθυρο 16×16 pixels στην κλίμακα σ . Το παράθυρο αυτό περιστρέφεται σύμφωνα με τον προσανατολισμό του keypoint, ώστε ο περιγραφέας να είναι ανεξάρτητος από την περιστροφή της εικόνας.

Στη συνέχεια, το παράθυρο διαιρείται σε $4 \times 4 = 16$ υποπεριοχές, καθεμία μεγέθους 4×4 pixels. Για κάθε υποπεριοχή υπολογίζεται ένα ιστόγραμμα 8 κατευθύνσεων κλίσης. Η συνεισφορά κάθε pixel στο ιστόγραμμα σταθμίζεται με:

- το μέτρο της κλίσης του (gradient magnitude)
- ένα Gaussian χωρικό βάρος, ώστε να δίνεται μεγαλύτερη έμφαση στα pixels κοντά στο κέντρο

Ο τελικός περιγραφέας προκύπτει από τη συνένωση όλων των ιστογραμμάτων και έχει συνολικά:

$$4 \times 4 \times 8 = 128$$

διαστάσεις, δηλαδή είναι ένα διάνυσμα:

$$\mathbf{d} \in \mathbb{R}^{128}$$

Ο SIFT descriptor κανονικοποιείται ώστε να είναι ανθεκτικός σε αλλαγές φωτισμού και αντίθεσης. Το διάνυσμα αυτό κωδικοποιεί τοπικό σχήμα, κατευθύνσεις ακμών και πληροφορία υφής, επιτρέποντας αξιόπιστη αντιστοίχιση (matching) keypoints μεταξύ διαφορετικών εικόνων, ακόμη και υπό μεταβολές κλίμακας, περιστροφής και φωτισμού.

3 Ανάλυση Κώδικα

Η παρούσα ενότητα αναλύει τον δοθέντα κώδικα `SIFT_feature.m`, ο οποίος υλοποιεί τον αλγόριθμο SIFT σύμφωνα με τη θεωρία του χώρου κλίμακας και τη μαθηματική προσέγγιση της κανονικοποιημένης λαπλασιανής μέσω difference of gaussians. Η ανάλυση εστιάζει στη σύνδεση κάθε τμήματος του κώδικα με τα αντίστοιχα θεωρητικά και μαθηματικά βήματα που έχουν παρουσιαστεί προηγουμένως.

3.1 Ανάλυση του `SIFT_feature.m`

Γενική Δομή Κώδικα

Ο κώδικας χωρίζεται στις εξής βασικές ενότητες:

1. Ανάγνωση & προεπεξεργασία εικόνας
2. Δημιουργία κλίμακας & DoG πυραμίδας
3. Ανίχνευση τοπικών ακρότατων
4. Εντοπισμός keypoints (φιλτράρισμα)
5. Ανάθεση προσανατολισμού
6. Υπολογισμός περιγραφέα (descriptor)

3.1.1 Δημιουργία Scale Space & DoG

Παράμετροι χώρου κλίμακας

```
sigma0 = sqrt(2);  
octave = 3;  
level = 3;  
D = cell(1, octave);
```

Μεταβλητή	Ρόλος
sigma0	αρχική κλίμακα
octave	αριθμός οκτάβων
level	αριθμός επιπέδων ανά οκτάβα
D{i}	DoG πυραμίδα για κάθε οκτάβα

Table 1: Ορισμός μεταβλητών του αλγορίθμου SIFT

Ο αριθμός επιπέδων ανά οκτάβα καθορίζει πόσα επίπεδα θολώματος υπολογίζονται σε κάθε οκτάβα, επηρεάζοντας την ανίχνευση χαρακτηριστικών διαφορετικού μεγέθους.

Το σ ελέγχει πόσο θολή είναι η εικόνα σε κάθε επίπεδο: μεγαλύτερο σ ανιχνεύει μεγαλύτερα χαρακτηριστικά, ενώ μικρότερο σ ανιχνεύει λεπτομέρειες. Οι σωστές τιμές των δύο παραμέτρων βελτιώνουν την ακρίβεια στην ανίχνευση keypoints, ενώ λάθος τιμές μπορεί να χάσουν χαρακτηριστικά.

Οι παράμετροι αυτές καθορίζουν τη διακριτοποίηση του χώρου κλίμακας, με την αρχική κλίμακα σ_0 να επιλέγεται ώστε να αντιστοιχεί σε αρχικό blurring, ενώ ο αριθμός επιπέδων $level$ συνδέεται με τον παράγοντα

$$k = 2^{1/s}$$

όπου s είναι ο αριθμός ενδιάμεσων επιπέδων ανά οκτάβα. Η σωστή επιλογή αυτών των τιμών διασφαλίζει ότι η διακριτή προσέγγιση του χώρου κλίμακας προσεγγίζει ικανοποιητικά το συνεχές μοντέλο.

Κατασκευή Gaussian Scale Space

```
temp_img = kron(img, ones(2));  
temp_img = padarray(temp_img, [1,1], 'replicate');
```

- temp_image : Η εικόνα διπλασιάζεται σε μέγεθος χρησιμοποιώντας την συνάρτηση **kron**, προκειμένου να δημιουργηθεί η πρώτη οκτάβα(εικόνα που φιλτράρεται σε κάθε οκτάβα).
- Στη συνέχεια, η εικόνα επεκτείνεται κατά ένα pixel σε κάθε πλευρά με την μέθοδο 'replicate'(padding), ώστε να αποφευχθούν προβλήματα στα όρια κατά τη συνέλιξη.

Υπολογισμός DoG

```
scale = sigma0*sqrt(2)^((1/level)^((i-1)*level+j));  
f = fspecial('gaussian', [1, floor(6*scale)], scale);  
L2 = conv2(temp_img, f, 'same');  
temp_D(:, :, j) = L2 - L1;
```

Ο κώδικας υπολογίζει DoG σύμφωνα με τον τύπο:

$$D(x, y, \sigma) = L(x, y, k\sigma) - L(x, y, \sigma)$$

Όπως έχει αναλυθεί θεωρητικά, η DoG προσεγγίζει την κανονικοποιημένη laplacian της εικόνας:

$$\text{DoG} \approx (k - 1) \sigma^2 \nabla^2 L$$

Έτσι, κάθε τιμή της DoG αντιστοιχεί σε μέτρηση της καμπυλότητας της εικόνας στον χώρο κλίμακας, χωρίς να απαιτείται ο υπολογισμός των δεύτερων παραγώγων.

Ο κώδικας αποθηκεύει τις εικόνες DoG σε 3D πίνακες, όπου κάθε πίνακας D_i έχει διαστάσεις:

$$(x, y, \text{scale})$$

Συνεπώς, οι τιμές που υπολογίζονται στον πίνακα D_i αντιπροσωπεύουν μετρήσεις της καμπυλότητας της εικόνας στον χώρο κλίμακας.

Σημαντικές Μεταβλητές

- **scale** → ενεργή κλίμακα Gaussian σε κάθε επίπεδο.
- **temp_D** → αποθηκεύει τις DoG εικόνες για την οκτάβα i .
- **L1** → προηγούμενο Gaussian φιλτραρισμένο επίπεδο, χρησιμοποιείται για τον υπολογισμό της DoG.

3.1.2 Ανίχνευση Τοπικών Ακρότατων

Η διαδικασία βασίζεται στον τρισδιάστατο πίνακα DoG $D(x, y, \sigma)$. Για κάθε υποψήφιο pixel, η περιοχή ελέγχου είναι:

Έλεγχος 3D ακρότατων

```
sub = D{i}(x:x+2, y:y+2, k-1:k+1);  
large = max(max(max(sub)));  
little = min(min(min(sub)));  
if(large == D{i}(x+1, y+1, k))  
    extrema(flag:(flag+3)) = [i, k, j, 1];  
end  
if(little == D{i}(x+1, y+1, k))  
    extrema(flag:(flag+3)) = [i, k, j, -1];  
end
```

Παράμετροι και ανάλυση:

- **sub** -> 3x3x3 κύβος γύρω από κάθε pixel (x, y) και επίπεδο k . Περιλαμβάνει το τρέχον pixel και τους 26 γείτονες στον χώρο $(x \pm 1, y \pm 1, \sigma \pm 1)$.
- **large** -> μέγιστο του κύβου, **little** -> ελάχιστο του κύβου.
- **extrema(flag:(flag+3))** -> καταγράφει κάθε candidate keypoint:
 - Οκτάβα i
 - Επίπεδο κλίμακας k
 - Γραμμική θέση j
 - Πρόσημο ακρότατου (1 για μέγιστο, -1 για ελάχιστο)

Λειτουργία:

Αν το pixel είναι μέγιστο ή ελάχιστο σε σχέση με όλους τους γείτονες, επιλέγεται ως candidate keypoint.

Υπολογισμός rx, ry, rz

```
x = floor((extrema(3:4:end)-1) / (n./(2.^(extrema(1:4:end)-2)))) + 1;  
y = mod((extrema(3:4:end)-1), m./(2.^(extrema(1:4:end)-2))) + 1;  
rx = x ./ 2.^(octave-1-extrema(1:4:end));  
ry = y ./ 2.^(octave-1-extrema(1:4:end));
```

Παράμετροι και ανάλυση:

- **x, y** -> pixel coordinates σε κάθε επίπεδο της οκτάβας.
- **rx, ry** -> συντεταγμένες keypoint στην αρχική ανάλυση της εικόνας (προσαρμογή για down-sampling ανά οκτάβα).
- **rz** -> επίπεδο κλίμακας του keypoint.

Λειτουργία:

Οι συντεταγμένες rx, ry, rz επιτρέπουν τη ανάκτηση της θέσης του keypoint σε σχέση με την αρχική εικόνα και το επίπεδο κλίμακας όπου ανιχνεύτηκε.

Παράδειγμα από τον κώδικα:

Αν το pixel $(x = 50, y = 60)$ σε octave = 1 και level = 2 είναι το μέγιστο σε σχέση με όλους τους 26 γείτονες, τότε:

```
extrema(flag:(flag+3)) = [1, 2, j, 1];
```

Λειτουργία:

- Οι τιμές rx και ry υπολογίζονται ώστε να αντιστοιχούν στην αρχική εικόνα.

3.1.3 Φιλτράρισμα και Εντόπιση Keypoints

Στόχος: Απομάκρυνση keypoints που είναι χαμηλής αντίθεσης ή αντιπροσωπεύουν "edges" με έντονη καμπυλότητα μόνο σε μία διεύθυνση.

Απόρριψη χαμηλής αντίθεσης

```
z = D{extrema(4*(i-1)+1)}(rx, ry, rz);  
if(abs(z) < threshold)  
    extrema(4*(i-1)+4) = 0;  
end
```

Παράμετροι και ανάλυση:

- $z \rightarrow$ τιμή DoG στο candidate keypoint (rx, ry, rz) .
- Αν η απόλυτη τιμή της DoG είναι μικρότερη από το threshold, το keypoint απορρίπτεται.

Λειτουργία:

Κάθε DoG ακρότατο που δεν ξεχωρίζει αρκετά από το περιβάλλον θεωρείται ευαίσθητο σε θόρυβο και διαγράφεται.

Απόρριψη edge responses (Hessian)

```
Dxx = D{...}(rx-1,ry,rz) + D{...}(rx+1,ry,rz) - 2*D{...}(rx,ry,rz);  
Dyy = D{...}(rx,ry-1,rz) + D{...}(rx,ry+1,rz) - 2*D{...}(rx,ry,rz);  
Dxy = D{...}(rx-1,ry-1,rz) + D{...}(rx+1,ry+1,rz) - D{...}(rx-1,ry+1,rz) - D{...}(rx+1,ry-1,rz);  
  
deter = Dxx*Dyy - Dxy*Dxy;  
R = (Dxx + Dyy)^2 / deter;  
R_threshold = (r+1)^2 / r;  
if(deter < 0 || R > R_threshold)  
    extrema(4*(i-1)+4) = 0;  
end
```

Παράμετροι και ανάλυση:

- $Dxx, Dyy \rightarrow$ δεύτερες παράγωγοι κατά μήκος x και y .
- $Dxy \rightarrow$ μικτή δεύτερη παράγωγος.
- **Hessian matrix:**

$$H = \begin{bmatrix} Dxx & Dxy \\ Dxy & Dyy \end{bmatrix}$$

- **deter** -> determinant του Hessian, ελέγχει αν υπάρχει τοπικό extremum.
- **R** -> λόγος ιδιοτιμών Hessian, χρησιμοποιείται για απομάκρυνση keypoints που ανήκουν σε edges.
- **R_threshold** = $(r + 1)^2 / r$.

Λειτουργία:

Απορρίπτονται keypoints που είναι "edges" με πολύ μεγάλη καμπυλότητα σε μία διεύθυνση αλλά όχι και στις δύο. Με τον τρόπο αυτό απορρίπτονται σημεία με έντονη καμπυλότητα μόνο σε μία διεύθυνση, τα οποία αντιστοιχούν σε ακμές και όχι σε blobs.

Ενημέρωση **extr_volume**

Όταν θέλουμε να υπολογίσουμε πόσα έγκυρα keypoints υπάρχουν:

```
extr_volume = length(extrema)/4;
```

Διαιρούμε δια 4, γιατί κάθε keypoint καταλαμβάνει 4 στοιχεία στον πίνακα **extrema** και ουσιαστικά μετράμε πόσα keypoints έχουν απομείνει μετά το φιλτράρισμα.

3.1.4 Διόρθωση Κατεύθυνσης & Descriptor

Ο στόχος είναι η δημιουργία περιστροφικά αναλλοίωτων keypoints με 128-D SIFT descriptors.

Ανάθεση Προσανατολισμού

```
scale = sigma0*sqrt(2)^(1/level)^((extrema(4*(i-1)+1)-1)*level + (extrema(4*(i-1)+1)-1)*level);
width = 2*round(3*1.5*scale);
weight = fspecial('gaussian', width, 1.5*scale);

reg_mag(count) = sqrt((D{octave}(l+1,k,rz)-D{octave}(l-1,k,rz))^2 + ...
                      (D{octave}(l,k+1,rz)-D{octave}(l,k-1,rz))^2);

reg_theta(count) = atan2(D{octave}(l,k+1,rz)-D{octave}(l,k-1,rz), ...
                        D{octave}(l+1,k,rz)-D{octave}(l-1,k,rz)) * (180/pi);

mag_counts = zeros(1,36);
for x=0:10:359
    mag_count = 0;
    mag_counts(x/10+1) = mag_count;
end
```

Παράμετροι και ανάλυση:

- **scale** -> κλίμακα keypoint.
- **width** -> μέγεθος περιοχής γύρω από keypoint για histogram (3σ Gaussian).

- **weight** -> Gaussian weighting για έμφαση στο κέντρο.
- **reg_mag** -> μέτρο gradient σε κάθε pixel της περιοχής.
- **reg_theta** -> κατεύθυνση gradient σε μοίρες.
- Histogram 36 bins (10° ανά bin) για την κατανομή κατευθύνσεων.
- Επιλογή bins με τιμή $\geq 80\%$ του μέγιστου $\rightarrow$ δημιουργία multiple orientation keypoints (kpori).

Δημιουργία 128-D Descriptor

```
d = 4;
pixel = 4;
width = d*pixel;
feature = zeros(d*d*8, extr_volume);
```

Παράμετροι:

- **d** -> αριθμός υποπεριοχών ανά διάσταση (4×4).
- **pixel** -> αριθμός pixels ανά υποπεριοχή.
- **width** -> πλήρες παράθυρο 16×16 γύρω από το keypoint.
- **feature** -> πίνακας τελικών descriptors διαστάσεων $128 \times N$.

Υπολογισμός local gradients για descriptor

```
sub_x = (x-d*pixel/2+1):(x+d*pixel/2);
sub_y = (y-d*pixel/2+1):(y+d*pixel/2);

temp_D = reshape(patch, [width, width]);
temp_D = padarray(temp_D, [1, 1], 'replicate', 'both');

theta_sub = atan((temp_D(2:end-1, 3:end)-temp_D(2:end-1, 1:end-2)) ./ ...
                 (temp_D(3:end, 2:end-1)-temp_D(1:end-2, 2:end-1))) * (180/pi);

mag_sub = weight .* temp_D(2:end-1, 2:end-1);
```

Λειτουργία:

- Υπολογίζονται το μέτρο (magnitude) και η κατεύθυνση (orientation) του gradient για όλα τα pixels της περιοχής γύρω από το keypoint.
- Η περιοχή περιστρέφεται κατά τη γωνία `kpori(i)` ώστε να επιτευχθεί περιστροφική αναλλοιωσιμότητα του descriptor.

Υπολογισμός histogram ανά υποπεριοχή

```
for area = 1:d*d
    magcounts = zeros(1,8);
    for angle = 0:45:315
        magcount = 0;
        magcounts(angle/45 + 1) = magcount;
    end
    descriptor((area-1)*8+1:area*8) = magcounts;
end
```

Λειτουργία:

- Κάθε υποπεριοχή 4×4 δημιουργεί ένα ιστόγραμμα 8 κατευθύνσεων.
- Συνολικά υπάρχουν 16 υποπεριοχές, οπότε ο descriptor έχει διαστάσεις $16 \times 8 = 128$.
- Ο τελικός SIFT descriptor κανονικοποιείται (π.χ. με `normr`) και εφαρμόζεται clipping στις τιμές για ανθεκτικότητα σε μεταβολές φωτισμού.

Ενημέρωση feature matrix

```
feature(:,i) = descriptor ';
```

Λειτουργία:

- Κάθε στήλη του πίνακα `feature` αντιστοιχεί σε έναν SIFT descriptor διαστάσεων 128 για ένα keypoint.
- Ο τελικός πίνακας `feature` έχει διαστάσεις $128 \times \text{extr_volume}$ και περιέχει όλους τους descriptors της εικόνας.

3.2 Σχολιασμός SIFT_feature.m

Σκοπός της ενότητας είναι η εφαρμογή του SIFT σε εικόνες και η οπτική επαλήθευση των keypoints μέσω των plots που παράγει ο κώδικας. Παρακάτω οπτικοποιείται μόνο η by default φωτογραφία `cameraman.tif` αλλά ανάλογα έγινε και στις άλλες 4 images.

3.2.1 Plot 1 – DoG Pyramid

Η DoG Pyramid αποτελείται από εικόνες διαφόρων κλιμάκων και οκτάβες.

Κάθε subplot αντιπροσωπεύει μια DoG εικόνα σε συγκεκριμένη οκτάβα και επίπεδο κλίμακας.

- Φωτεινές περιοχές υποδηλώνουν τοπικά μέγιστα .
- Σκοτεινές περιοχές υποδηλώνουν τοπικά ελάχιστα .

- Καθώς αυξάνεται η κλίμακα, οι λεπτομέρειες χάνουν ένταση και παραμένουν μόνο δομές μεγάλης κλίμακας.

Ο κώδικας παράγει 9 υπο-εικόνες λόγω:

$$3 \text{ οκτάβες} \times 3 \text{ επίπεδα ανά οκτάβα} = 9 \text{ υπο-εικόνες}$$

Η DoG Pyramid δείχνει τις διαφορές καμπυλότητας της εικόνας σε διαφορετικές κλίμακες όπως φαίνεται και παρακάτω.




Figure 1: DoG Pyramid

3.2.2 Plot 2 – Αρχική εικόνα & candidate keypoints

Αριστερά εμφανίζεται η αρχική εικόνα, ενώ δεξιά εμφανίζονται τα candidate keypoints με κόκκινους σταυρούς, όπου κάθε κόκκινος σταυρός αντιστοιχεί σε ένα τοπικό ακρότατο στο DoG. Υπάρχουν πολλοί κόκκινοι σταυροί σε όλη την εικόνα επειδή περιλαμβάνονται σημεία χαμηλής αντίθεσης και σημεία πάνω σε ακμές. Αυτά τα keypoints είναι υποψήφια και εμφανίζονται πριν εφαρμοστεί το φιλτράρισμα για σταθερότητα και αντίθεση.

3.2.3 Plot 3 – Τελικά keypoints μετά το φιλτράρισμα

Στα αριστερά εμφανίζονται πράσινοι σταυροί που υποδεικνύουν τα keypoints με αντίθεση πάνω από το προκαθορισμένο threshold, ενώ τα keypoints χαμηλής αντίθεσης έχουν απορριφθεί. Αυτό οδηγεί σε σημαντική μείωση του πλήθους των σημάτων και αποφεύγονται τα σημεία που είναι ευαίσθητα σε θόρυβο.

Στα δεξιά εμφανίζονται μπλε σταυροί που υποδεικνύουν τα keypoints που παραμένουν μετά τον έλεγχο edge responses. Διατηρούνται μόνο σταθερά γεωμετρικά σημεία, ενώ τα keypoints πάνω σε ευθείες απορρίπτονται. Κάθε keypoint πλέον έχει assigned orientation και είναι έτοιμο για τον υπολογισμό του descriptor, με ακόμη λιγότερα, αλλά πιο αξιόπιστα keypoints.




Figure 2: Αρχικά keypoints πριν το φιλτράρισμα




Figure 3: Keypoints μετά το φιλτράρισμα

3.3 Αριθμός Επιπέδων Ανά Οκτάβα

Κάθε οκτάβα περιέχει εικόνες που έχουν φιλτραριστεί με gaussian blur σε διαφορετικά επίπεδα κλίμακας, τα οποία συμβολίζουμε με s . Το s είναι ο αριθμός των επιπέδων DoG που θέλουμε να

χρησιμοποιήσουμε για τον εντοπισμό ακροτάτων (*extrema*) στο scale space. Κάθε DoG υπολογίζεται ως η διαφορά δύο συνεχόμενων gaussian εικόνων:

$$\text{DoG}_i = G_{i+1} - G_i$$

Για να εντοπιστούν τα *extrema*, δεν χρησιμοποιούμε τα άκρα της οκτάβας, γιατί δεν έχουν γειτονικά επίπεδα πάνω ή κάτω για τον έλεγχο 3D ακροτάτων. Γι' αυτό χρειάζονται $s + 2$ DoG εικόνες ώστε τα εσωτερικά DoG να καλύπτουν όλα τα s επίπεδα.

Κάθε DoG απαιτεί 2 gaussian εικόνες, άρα για $s + 2$ DoG χρειαζόμαστε:

$$\text{Gaussian images} = (\text{DoG count}) + 1 = (s + 2) + 1 = s + 3$$

Τα $s + 3$ Gaussian images εξασφαλίζουν σωστό έλεγχο 3D ακροτάτων και αποφεύγουν τα *boundary errors*, δηλαδή σφάλματα στα άκρα της οκτάβας.

3.4 Εφαρμογή και Αποτελέσματα της Ανίχνευσης SIFT

Χρησιμοποιήθηκε υλοποίηση SIFT (`SIFT_feature.m`) για την ανίχνευση keypoints σε πέντε grayscale εικόνες από τη βιβλιοθήκη του matlab.

3.4.1 Περιγραφή εικόνων

1. `cameraman.tif`

Γκρι εικόνα με άτομο σε πρώτο πλάνο. Παρουσιάζει πολλές ακμές και γωνίες (καθαρά όρια αντικειμένων), καλή αντίθεση και υφές(επαναλαμβανόμενα μοτίβα φωτεινότητας) στο φόντο.

2. `coins.png`

Γκρι εικόνα με κυκλικά αντικείμενα (νομίσματα). Έχει έντονα όρια, δηλαδή απότομη αλλαγή φωτεινότητας μεταξύ νομισμάτων και φόντου, και επαναλαμβανόμενα σχήματα.

3. `pout.tif`

Γκρι εικόνα προσώπου με χαμηλή αντίθεση, όπου η φωτεινότητα αλλάζει ομαλά. Κυριαρχούν μεγάλες ομοιόμορφες περιοχές χωρίς έντονες ακμές.

4. `rice.png`

Γκρι εικόνα με μικρούς φωτεινούς κόκκους σε σκούρο φόντο. Έχει υψηλή αντίθεση, γιατί οι κόκκοι ξεχωρίζουν καθαρά, και πολλές μικρές λεπτομέρειες.

5. `moon.tif`

Γκρι εικόνα με φυσικές υφές και κρατήρες. Περιέχει λεπτομέρειες μέσης κλίμακας και σχετικά ομαλές μεταβάσεις φωτεινότητας.

3.4.2 Αποτελέσματα SIFT

3.4.3 Σχολιασμός

Παρατηρείται σαφής συσχέτιση μεταξύ της υφής της εικόνας και του πλήθους των keypoints:

1. Η εικόνα `rice.png` παρουσιάζει τον μεγαλύτερο αριθμό keypoints , λόγω της έντονης και πυκνής υφής της.

Εικόνα	Αριθμός Keypoints
pout.tif	30
coins.png	1258
cameraman.tif	1517
rice.png	1701
moon.tif	445

Table 2: Αριθμός keypoints που εντοπίστηκαν σε κάθε εικόνα με τον αλγόριθμο `SIFT_feature.m`

2. Η `cameraman.tif` εμφανίζει επίσης μεγάλο αριθμό keypoints, καθώς περιέχει πολλές ακμές και δομές σε διαφορετικές κλίμακες.
3. Η `coins.png` παρουσιάζει αρκετά keypoints κυρίως στα όρια των νομισμάτων.
4. Η `moon.tif` έχει μέτριο αριθμό keypoints, οι οποίοι εντοπίζονται κυρίως στους κρατήρες και στα όρια του φόντου με το φεγγάρι.
5. Η `pout.tif` εμφανίζει πολύ μικρό αριθμό keypoints, γεγονός που οφείλεται στο χαμηλό επίπεδο υφής και στις μεγάλες ομοιόμορφες περιοχές.

4 Υποκλιμακική Ακρίβεια

Στον αλγόριθμο SIFT, τα πιθανά σημεία-κλειδιά βρίσκονται αρχικά ως τοπικά μέγιστα ή ελάχιστα της DoG στον διακριτό χώρο (x, y, σ) . Αυτή η διακριτοποίηση δεν είναι ακριβής, γιατί τα πραγματικά ακρότατα της εικόνας δεν πέφτουν πάντα σε ακριβείς θέσεις ή κλίμακες. Γι' αυτό γίνεται βελτίωση σε υποχωρικό και υποκλιμακικό επίπεδο, ώστε τα σημεία-κλειδιά να εντοπίζονται πιο σωστά και να είναι πιο σταθερά.

4.1 Ανάπτυγμα Taylor της DoG στον Χώρο Κλίμακας

Ουσιαστικά είναι η προσέγγιση της τιμής της DoG γύρω από ένα αρχικό ακρότατο με πολυώνυμο δεύτερης τάξης (2nd order Taylor expansion) σε τρεις διαστάσεις (x, y, σ) :

$$D(\mathbf{x}) \approx D + \nabla D^T \mathbf{x} + \frac{1}{2} \mathbf{x}^T H \mathbf{x}$$

όπου:

- $\mathbf{x} = (x, y, \sigma)^T$ είναι η μετατόπιση από τη διακριτή θέση του keypoint.
- ∇D είναι το διάνυσμα των πρώτων παραγώγων της DoG σε x, y, σ .
- H είναι ο πίνακας Hessian, που περιέχει τις δεύτερες παραγώγους της DoG.

Υπολογισμός Ακρότατου

Η ακριβής θέση του ακρότατου υπολογίζεται με:

$$\frac{\partial D}{\partial \mathbf{x}} = 0 \quad \Rightarrow \quad \hat{\mathbf{x}} = -H^{-1} \nabla D$$

Αυτό το διάνυσμα $\hat{\mathbf{x}}$ δίνει την subpixel & subscale θέση του keypoint.

Απόρριψη Ασταθών Keypoints

Η τιμή της DoG στο subscale ακρότατο είναι:

$$D(\hat{\mathbf{x}}) = D + \frac{1}{2} \nabla D^T \hat{\mathbf{x}}$$

Εάν η απόλυτη τιμή αυτής της DoG είναι μικρότερη από προκαθορισμένο κατώφλι, το keypoint απορρίπτεται. Αυτή η διαδικασία συνδέεται με τη θεωρία *scale-space*: η DoG προσεγγίζει την κανονικοποιημένη λαπλασιανή, και η τιμή στο ακρότατο εκφράζει την καμπυλότητα της εικόνας στον χώρο κλίμακας.

4.2 Παραβολική Παρεμβολή

Μία άλλη μέθοδος είναι η παραβολική παρεμβολή είναι μια μέθοδος που χρησιμοποιείται για υπο-πίξελ και υπο-κλίμακα ακρίβεια στον εντοπισμό των keypoints. Αντί να μένουμε στο πιο κοντινό pixel ή επίπεδο κλίμακας, η μέθοδος αυτή προσεγγίζει τη θέση της κορυφής (local maximum) με μια παραβολή. Σε μία διάσταση, η θέση της κορυφής εκτιμάται με τον τύπο:

$$x_{\text{peak}} = x_0 - \frac{f'(x_0)}{f''(x_0)}$$

όπου:

- x_0 = αρχική θέση (pixel ή επίπεδο)
- $f'(x_0)$ = πρώτη παράγωγος στο x_0
- $f''(x_0)$ = δεύτερη παράγωγος στο x_0

Η μέθοδος αυτή εφαρμόζεται ξεχωριστά στις τρεις διαστάσεις (x, y, σ) .

4.3 Σύγκριση Μεθόδων

Μέθοδος	Ακρίβεια	Κόστος	Σταθερότητα	SIFT
Ανάπτυγμα Taylor	Υψηλή	Μεσαίο-Υψηλό	Πολύ Υψηλή	✓
Παραβολική Παρεμβολή	Μεσαία	Χαμηλό	Περιορισμένη	✗

Table 3: Σύγκριση μεθόδων υποκλιμακικής εκτίμησης keypoints στον SIFT

Για ακριβή και σταθερά keypoints, το Taylor expansion είναι προτιμότερο, ενώ η παραβολική παρεμβολή είναι καλή σε περιπτώσεις που θέλουμε ταχύτητα.

5 Αντιστοίχιση & RANSAC

Παρουσιάζεται η διαδικασία αντιστοίχισης των σημείων κλειδιών που εντοπίστηκαν με τον αλγόριθμο SIFT μεταξύ δύο εικόνων, καθώς και η εφαρμογή του αλγορίθμου RANSAC για την απομάκρυνση των outliers και την εξαγωγή ενός γεωμετρικού μοντέλου μεταξύ των εικόνων.

5.1 Ανάλυση του SIFT (sift.m)

Σε αυτή την υποενότητα αναλύουμε τις τεχνικές που ενσωματώθηκαν για τη μεγιστοποίηση της ακρίβειας.

1. **Subpixel Localization & Taylor Expansion:** Τα extrema στο DoG εντοπίζονται αρχικά σε διακριτό επίπεδο pixel. Για να βρούμε την πραγματική κορυφή ανάμεσα στα pixels, χρησιμοποιούμε ανάπτυγμα Taylor 2ης τάξης.
2. **Edge Rejection (Hessian Matrix):** Για την απόρριψη σημείων κατά μήκος ακμών, υπολογίζεται ο πίνακας Hessian.
3. **Trilinear Interpolation (Descriptor):** Η τιμή κάθε κλίσης (magnitude) παρεμβάλλεται σε τρεις διαστάσεις (θέση x,y και bin κατεύθυνσης), αυτό αποτρέπει απότομες αλλαγές στον περιγραφητή όταν το keypoint μετατοπίζεται ελάχιστα.
4. **Gaussian Weighting & Normalization:**
 - Εφαρμόζεται ένα gaussian window στον περιγραφητή ώστε τα pixels μακριά από το κέντρο να έχουν μικρότερη βαρύτητα.
 - Clipping (0.2): Έστω ότι τα στοιχεία του 128-διάστατου descriptor είναι $\mathbf{v} = [v_1, v_2, \dots, v_{128}]$. Εφαρμόζουμε *clipping*:

$$v_i \leftarrow \min(v_i, 0.2), \quad \forall i = 1, \dots, 128$$

και στη συνέχεια κανονικοποιούμε ξανά τον descriptor:

$$\mathbf{v} \leftarrow \frac{\mathbf{v}}{\|\mathbf{v}\|}, \quad \text{όπου} \quad \|\mathbf{v}\| = \sqrt{\sum_{i=1}^{128} v_i^2}.$$

Αυτό εξασφαλίζει ότι ο descriptor παραμένει ανθεκτικός σε αλλαγές φωτεινότητας.

5.2 Descriptor Matching (matching.m)

Κάθε keypoint της εικόνας περιγράφεται από έναν 128-D SIFT descriptor, ο οποίος κωδικοποιεί την κατανομή των gradients στην τοπική περιοχή γύρω από το keypoint. Για την αντιστοίχιση μεταξύ δύο εικόνων, κάθε keypoint της εικόνας 1 συγκρίνεται με όλα τα keypoints της εικόνας 2 ώστε να βρεθεί το πιο παρόμοιο.

5.2.1 Μέθοδοι υπολογισμού ομοιότητας

Euclidean Distance

Η ευκλείδεια απόσταση μεταξύ δύο descriptors f_1 και f_2 δίνεται από:

$$d = \sum_{i=1}^{128} (f_1(i) - f_2(i))^2$$

Μικρότερη απόσταση σημαίνει μεγαλύτερη ομοιότητα.

Ratio Test

Υπολογίζονται οι δύο μικρότερες αποστάσεις d_1 και d_2 από όλα τα keypoints της δεύτερης εικόνας. Διατηρούμε την αντιστοιχία μόνο αν ισχύει:

$$\frac{d_1}{d_2} < 0.7$$

Αυτό σημαίνει ότι η καλύτερη αντιστοιχία πρέπει να είναι καλύτερη από τη δεύτερη καλύτερη και γενικά η μέθοδος αυτή απομακρύνει λάθος αντιστοιχίσεις

5.3 RANSAC

Ακόμα και με το Ratio Test, πολλές αντιστοιχίσεις θα είναι λανθασμένες (outliers). Ο RANSAC (Random Sample Consensus) είναι ένας επαναληπτικός αλγόριθμος που εκτιμά τις παραμέτρους ενός μαθηματικού μοντέλου (π.χ. affine transformation) από ένα σύνολο παρατηρήσεων που περιέχει θόρυβο.

5.3.1 Χρήση του στο SIFT Matching

Μετά την αρχική αντιστοίχιση των keypoints με βάση τους SIFT descriptors και το ratio test, έχουμε ένα σύνολο πιθανών αντιστοιχιών. Κάποια από αυτά μπορεί να είναι λανθασμένα, λόγω επαναλαμβανόμενων μοτίβων, θορύβου ή αλλαγών στην προβολή της σκηνής.

Βήματα εφαρμογής RANSAC (rasnac.m)

1. **Ελάχιστο Δείγμα:** Επιλέγονται τυχαία n ζεύγη σημείων. Για την εκτίμηση ενός affine μετασχηματισμού απαιτούνται τουλάχιστον $n = 3$ σημεία, ώστε να προσδιοριστούν οι παράμετροι του μετασχηματισμού, δηλαδή η μετατόπιση, η περιστροφή, η κλιμάκωση και η στρέβλωση.
2. **Model Estimation:** Ένα σημείο (x, y) της πρώτης εικόνας μετασχηματίζεται στο σημείο (x', y') της δεύτερης εικόνας μέσω του πίνακα M :

$$\begin{bmatrix} x' \\ y' \end{bmatrix} = \begin{bmatrix} m_{11} & m_{12} \\ m_{21} & m_{22} \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix} + \begin{bmatrix} t_x \\ t_y \end{bmatrix}$$

Για την επίλυση, ο RANSAC επιλέγει 3 τυχαία ζεύγη σημείων και λύνει το σύστημα:

$$\mathbf{p}' = M\mathbf{p}$$

όπου ο πίνακας M υπολογίζεται με τη μέθοδο Least Squares πάνω στο τυχαίο δείγμα.

3. **Υπολογισμός Σφάλματος:** Για να κριθεί αν μία αντιστοίχιση i είναι **inlier**, υπολογίζεται η ευκλείδεια απόσταση:

$$\varepsilon_i = (x'_i - \hat{x}'_i)^2 + (y'_i - \hat{y}'_i)^2$$

Αν ισχύει $\varepsilon_i < \text{threshold}$ (π.χ. 5 pixels), τότε η αντιστοίχιση θεωρείται έγκυρη.

4. **Consensus:** Αν η απόσταση είναι μικρότερη από ένα max distance (π.χ. 5 pixels), το σημείο θεωρείται inlier.
5. **Επαναλήψεις και επιλογή καλύτερου μοντέλου:**
 - Το βήμα επαναλαμβάνεται για N επαναλήψεις (π.χ., 2000).
 - Κρατάμε το μοντέλο M με τα περισσότερα inliers.

5.4 Πειράματα Αποτελεσμάτων

Δοκιμή	Συνθήκη Μετασχηματισμού	Keypoints (Img 1 / 2)	Total Matches	RANSAC Inliers	Inlier Ratio
1	Rotation (15°) & Scale (0.8)	445 / 268	123	120	97.56%
2	Rotation (45°)	445 / 422	232	228	98.28%
3	Scale (3.5)	445 / 1866	184	178	96.74%
4	Gaussian Noise (0.01)	445 / 1042	126	124	98.41%
5	Brightness (+50)	445 / 441	410	410	100.00%

Table 4: Αποτελέσματα δοκιμών αντιστοίχισης keypoints με RANSAC

5.4.1 Invariance στην Περιστροφή (Rotation 15° & 45°)

Αποτελέσματα : Inlier Ratio 97.56% και 98.28%.

Γιατί δουλεύει:

- Ο SIFT υπολογίζει το ιστόγραμμα προσανατολισμού (orientation histogram) για κάθε keypoint.
- Η κυρίαρχη γωνία κάθε keypoint χρησιμοποιείται για να περιστραφεί ο περιγραφητής στη “κανονική” του μορφή (rotation normalization).

Γιατί όχι 100%:

- **Quantization:** Τα pixels είναι διακριτά (0–255 ή 0–1), οπότε μικρές μετατοπίσεις δημιουργούν στρογγυλοποιήσεις.
- **Interpolation Artifacts:** Όταν περιστρέφουμε μια ψηφιακή εικόνα, τα pixels δεν πέφτουν ακριβώς πάνω στο αρχικό πλέγμα, οπότε οι τιμές τους υπολογίζονται μέσω παρεμβολής. Αυτή η διαδικασία αλλάζει ελαφρώς τις τιμές των pixels και συνεπώς τους gradients, με αποτέλεσμα κάποιοι keypoints να διαφοροποιούνται.

5.4.2 Invariance στην Κλίμακα (Scale 3.5)

Αποτελέσματα : Inlier Ratio 96.74%.

Γιατί δουλεύει:

- Ο SIFT δημιουργεί μια gaussian & DoG πυραμίδα σε πολλές κλίμακες.
- Keypoints ανιχνεύονται ως extrema σε πολλαπλές οκτάβες, οπότε αν μια λεπτομέρεια είναι μικρή ή μεγάλη, εξακολουθεί να αναγνωρίζεται.

Γιατί όχι 100%:

- **Απώλεια πληροφορίας:** Όταν μεγαλώνουμε μια εικόνα, γίνεται interpolation, δηλαδή προσθέτουμε νέα pixel values που δεν υπήρχαν.
- Όταν μικραίνουμε, χάνεται λεπτομέρεια.
- **Subpixel Localization:** Χρησιμοποιεί Taylor expansion, δηλαδή μια προσέγγιση, που μπορεί να δώσει ελαφρώς διαφορετικές συντεταγμένες.

5.4.3 Invariance στον Φωτισμό (Brightness +50)

Αποτελέσματα : Inlier Ratio 100.00%.

Γιατί δουλεύει:

- Ο SIFT βασίζεται σε gradients, δηλαδή διαφορές μεταξύ γειτονικών pixels, που είναι ανεξάρτητες από ομοιόμορφη αύξηση φωτεινότητας.
- **Descriptor Normalization** ($\|v\| = 1$) καθιστά τις τιμές των gradients σχετικές και όχι απόλυτες, διασφαλίζοντας ότι η συνολική τους ένταση είναι 1.

5.4.4 Αντοχή στον Θόρυβο (Gaussian Noise 0.01)

Αποτελέσματα : Inlier Ratio 98.41%.

Γιατί δουλεύει:

- Ο SIFT εφαρμόζει gaussian blur πριν την εξαγωγή των χαρακτηριστικών, που λειτουργεί σαν φίλτρο και μειώνει τον θόρυβο.
- Το RANSAC απορρίπτει τα περισσότερα λανθασμένα extrema που δημιουργεί ο θόρυβος, κρατώντας μόνο τα αληθινά keypoints.

Γιατί όχι 100%:

- Όταν προσθέτουμε θόρυβο, δημιουργούνται νέα τοπικά maxima/minima (extrema), κάποια από τα οποία δεν αντιστοιχούν σε πραγματικές λεπτομέρειες της εικόνας.
- Μερικά keypoints αλλάζουν ελαφρά θέση ή orientation λόγω του θορύβου, μειώνοντας ελαφρά τον αριθμό των inliers.

6 Σύγκριση & Πολυπλοκότητα

Εξετάζουμε τη σύγκριση και την υπολογιστική πολυπλοκότητα των αλγορίθμων ανίχνευσης και περιγραφής τοπικών χαρακτηριστικών εικόνας, όπως οι SIFT, GLOH και SURF, αναλύοντας τα πλεονεκτήματα, τις αδυναμίες τους και το κόστος εκτέλεσής τους σε σχέση με την αποτελεσματικότητα στην αναγνώριση και αντιστοίχιση χαρακτηριστικών.

6.1 SIFT vs GLOH vs SURF

Αυτές οι μέθοδοι είναι local feature descriptors, δηλαδή τρόποι να περιγράψουμε τα keypoints μιας εικόνας για σύγκριση, αναγνώριση ή αντιστοίχιση.

6.1.1 SIFT (Scale-Invariant Feature Transform)

Ανίχνευση και περιγραφή χαρακτηριστικών ανεξάρτητα από κλίμακα, περιστροφή ή φωτεινότητα.

Βασικά βήματα:

1. Detection of extrema:

- Υπολογισμός DoG:

$$D(x, y, \sigma) = L(x, y, k\sigma) - L(x, y, \sigma)$$

όπου $L(x, y, \sigma)$ είναι η εικόνα με Gaussian blur.

2. Keypoint localization:

- Ακριβής προσδιορισμός θέσεων και απόρριψη ασταθών ή χαμηλής αντίθεσης keypoints.

3. Orientation assignment:

- Ανάθεση κατεύθυνσης στο keypoint για ανθεκτικότητα σε περιστροφές.

4. Descriptor computation:

- Δημιουργία 128-D διανύσματος από orientation histograms.

Πλεονεκτήματα

- **Υψηλή ανθεκτικότητα σε αλλαγές κλίμακας και περιστροφής:** Προκύπτει γιατί χρησιμοποιείται DoG pyramid για διαφορετικές κλίμακες και οι προσανατολισμοί των histograms είναι ανεξάρτητοι από την περιστροφή.
- **Ανθεκτικό σε αλλαγές φωτεινότητας:** Ο SIFT χρησιμοποιεί normalized gradient magnitudes, άρα μικρές αλλαγές στην ένταση δε αλλοιώνουν τους descriptors.
- **Ακριβές matching:** Τα 128 στοιχεία του descriptor περιγράφουν το περιβάλλον του keypoint.

Μειονεκτήματα

- **Υψηλή υπολογιστική πολυπλοκότητα:** Ο DoG σε πολλαπλές κλίμακες και η κατασκευή των 128-διάστατων histograms απαιτούν μεγάλο αριθμό υπολογισμών.
- **Αργή εκτέλεση σε μεγάλες εικόνες:** Πολλά keypoints και μεγάλες εικόνες αυξάνουν γραμμικά τον χρόνο.
- **Μεγάλη χρήση μνήμης:** Κάθε keypoint έχει 128 αριθμούς floating point.

6.1.2 GLOH (Gradient Location and Orientation Histogram)

Βελτιωμένος SIFT descriptor

Βασικά βήματα:

1. Χωρίζει την περιοχή γύρω από το keypoint σε *log-polar grid* (ένα πλέγμα που χωρίζει την περιοχή σε κυκλικά και ακτινικά τμήματα αντί για απλά τετράγωνα 4×4).
2. Ο αρχικός descriptor έχει 272 διαστάσεις και μειώνεται σε 128 μέσω PCA.
3. Βασίζεται στην ίδια ανίχνευση keypoints όπως ο SIFT.

Πλεονεκτήματα

- **Καλύτερη διάκριση:** Το log-polar grid καταγράφει περισσότερες λεπτομέρειες στις περιοχές κοντά στο keypoint.
- **Περισσότερο ανθεκτικό σε περιστροφές και μικρές παραμορφώσεις:** Η κυκλική και ακτινική διάταξη του grid μειώνει τις παραμορφώσεις, καθώς οι αλλαγές θέσης ή κλίσης των pixels επηρεάζουν λιγότερο τα συνολικά τμήματα.
- **Ιδανικό για εφαρμογές με υψηλή ακρίβεια:** Το μεγάλο αρχικό descriptor καταγράφει περισσότερη πληροφορία.

Μειονεκτήματα

- **Πιο αργό από SIFT:** Περισσότεροι υπολογισμοί ανά keypoint (272 στοιχεία αντί 128).
- **Απαιτεί PCA για μείωση διαστάσεων:** Διαφορετικά, η μνήμη και ο χρόνος matching αυξάνονται σημαντικά.
- **Πολύπλοκη υλοποίηση:** Το log-polar grid απαιτεί περισσότερους υπολογισμούς για κάθε keypoint.

6.1.3 SURF (Speeded-Up Robust Features)

Γρήγορος descriptor για real time εφαρμογές.

Βασικά βήματα:

1. Keypoint detection:

- Χρησιμοποιείται Hessian matrix

$$H(x, \sigma) = \begin{bmatrix} L_{xx} & L_{xy} \\ L_{xy} & L_{yy} \end{bmatrix}$$

όπου L_{xx}, L_{xy}, L_{yy} είναι οι δεύτερες παράγωγοι της εικόνας μετά από gaussian φίλτρο κλίμακας σ .

- Για γρήγορο υπολογισμό χρησιμοποιούνται τα *integral images*, δηλαδή εικόνα όπου κάθε σημείο αποθηκεύει το άθροισμα όλων των pixel από την πάνω αριστερή γωνία μέχρι εκείνο το σημείο, ώστε να υπολογίζονται γρήγορα τα αθροίσματα τμημάτων της εικόνας.

2. Descriptor computation:

- Ο descriptor έχει 64 διαστάσεις και υπολογίζεται από Haar wavelets, δηλαδή απλά φίλτρα που μετρούν τις διαφορές έντασης σε οριζόντια και κατακόρυφα μοτίβα.
- Η περιοχή γύρω από το keypoint χωρίζεται σε μικρά τετράγωνα.
- Σε κάθε υπο-περιοχή υπολογίζονται οι αθροιστικές αποκρίσεις Haar wavelets σε x και y κατεύθυνση, δημιουργώντας γρήγορα υπολογιζόμενο descriptor.

Πλεονεκτήματα

- **Γρήγορο:** Integral images επιτρέπουν υπολογισμούς περιοχών σε σταθερό χρόνο, μειώνοντας τον αριθμό των operations.
- **Καλή ανθεκτικότητα σε φωτεινότητα:** Όπως SIFT, χρησιμοποιεί gradients.
- **Μικρή χρήση μνήμης:** 64-διάστατος descriptor αντί 128, λιγότερη αποθήκευση.

Μειονεκτήματα

- **Λιγότερο ανθεκτικό σε μεγάλες περιστροφές ή αλλαγές κλίμακας:** Η χρήση box filters αποτυπώνει γενικά μοτίβα φωτεινότητας και όχι λεπτομέρειες, οπότε η αναγνώριση δυσκολεύει όταν η εικόνα περιστρέφεται ή αλλάζει μέγεθος.
- **Λιγότερη ακρίβεια σε πολύπλοκες σκηνές:** Ο μικρότερος descriptor χάνει σημαντικές λεπτομέρειες, με αποτέλεσμα να μειώνεται η ακρίβεια σε εικόνες με πολλαπλά αντικείμενα ή πολύπλοκες υφές.

6.2 Υπολογιστικό κόστος

Το υπολογιστικό κόστος εξαρτάται από δύο κύρια στάδια: keypoint detection και descriptor computation.

6.2.1 SIFT

1. Keypoint Detection – DoG Pyramid

- Ο SIFT ανιχνεύει keypoints κατασκευάζοντας μια πυραμίδα κλίμακας με DoG.
- Η διαδικασία περιλαμβάνει:
 - υπολογισμό gaussian blur σε κάθε κλίμακα,
 - αφαίρεση διαδοχικών gaussian εικόνων για την παραγωγή DoG,
 - έλεγχο τοπικών ακροτάτων σε χώρο και κλίμακα.
- Για εικόνα διαστάσεων $N \times N$ και S κλίμακες:
 - κάθε γκαουσιανή συνέλιξη έχει κόστος $O(N^2)$,
 - για S κλίμακες το συνολικό κόστος είναι $O(S \cdot N^2)$.
- Το στάδιο αυτό είναι το πιο υπολογιστικά απαιτητικό και κυριαρχεί στον συνολικό χρόνο εκτέλεσης.

2. Descriptor Computation

- Για κάθε ένα από τα K keypoints:
 - αναλύεται ένα τοπικό patch 16×16 pixel,
 - υπολογίζονται οι προσανατολισμοί κλίσης,
 - παράγεται descriptor 128 διαστάσεων.
- Το κόστος ανά keypoint είναι σταθερό, καθώς το μέγεθος του patch και ο αριθμός των bins είναι προκαθορισμένα.
- Συνεπώς, το συνολικό κόστος του σταδίου είναι $O(K)$.

3. Συνολικό Κόστος SIFT

$$O(S \cdot N^2 + K)$$

Η πλειονότητα του χρόνου εκτέλεσης δαπανάται στη δημιουργία της DoG πυραμίδας, ιδιαίτερα για εικόνες υψηλής ανάλυσης.

6.2.2 GLOH

1. Keypoint Detection

- Ίδιος μηχανισμός με τον SIFT (DoG pyramid).
- Κόστος: $O(S \cdot N^2)$

2. Descriptor Computation

- Χρησιμοποιεί log-polar grid.
- Παράγει αρχικό descriptor 272 διαστάσεων.
- Εφαρμόζεται PCA για μείωση σε 128 διαστάσεις.
- Κόστος μεγαλύτερο από SIFT λόγω πυκνότερου grid και PCA.

6.2.3 SURF

1. Integral Images

- Κάθε pixel περιέχει άθροισμα όλων των pixels πάνω και αριστερά του.
- Υπολογίζεται μία φορά με κόστος $O(N^2)$.
- Επιτρέπει υπολογισμό αθροισμάτων σε οποιοδήποτε ορθογώνιο τμήμα σε χρόνο $O(1)$.

2. Box Filters & Haar Wavelets

- Box filters για γρήγορη προσέγγιση Gaussian φίλτρων.
- Haar wavelets μετρούν διαφορές έντασης μεταξύ γειτονικών περιοχών.
- Χάρη στις integral images, υπολογίζονται με λίγες πράξεις.

3. Keypoint Detection

- Εξετάζονται S κλίμακες.
- Θεωρητικό κόστος $O(S \cdot N^2)$.
- Στην πράξη, τα box filters κάνουν τον SURF πιο γρήγορο από τον SIFT.

4. Descriptor Computation

- Descriptor 64 διαστάσεων.
- Υπολογίζεται σε patch σταθερού μεγέθους.
- Κόστος ανά keypoint σταθερό $\rightarrow$ συνολικά $O(K)$.

5. Συνολικό Κόστος SURF

- Χάρη σε integral images, box filters και μικρότερο descriptor, ο SURF έχει χαμηλότερο υπολογιστικό κόστος.

6.3 Σύγκριση Αλγορίθμων

Μέθοδος	Descriptor	Ανθεκτικότητα	Ταχύτητα	Κόστος	Επιλογή
SIFT	128	Υψηλή (κλίμακα, περιστροφή και φωτεινότητα)	Αργή	Υψηλό λόγω DoG pyramid σε πολλές κλίμακες και μεγάλου descriptor	Ακρίβεια
GLOH	128 (μετά PCA)	Πολύ υψηλή, (καλύτερη διάκριση χαρακτηριστικών)	Πολύ αργή	Πολύ υψηλό - log polar grid, descriptor 272 διαστάσεων & PCA	Υψηλή ακρίβεια
SURF	64	Καλή (φωτεινότητα και μικρές περιστροφές, λιγότερο σε μεγάλες αλλαγές κλίμακας)	Γρήγορη	Χαμηλό χάρη σε integral images, box filters και μικρό descriptor	Ταχύτητα

Table 5: Σύγκριση SIFT - GLOH - SURF